分类号 TP391.4 学号 23053013

UDC 004.8 密级 公开

硕士学位论文

（专业学位）

面向受限场景的域泛化迁移与轻量化方法研究

硕士生姓名 黎拓新

专业学位类别 电子信息

专业学位领域 人工智能

研究方向 模式识别与智能系统

指导教师 项凤涛 副教授

国防科技大学

二〇二六年六月

论文书脊

面向受限场景的域泛化迁移与轻量化方法研究

国防科技大学

Research on Domain Generalization Transfer and Lightweight Methods for Constrained Scenarios

Candidate：Tuoxin Li

Supervisor：Assoc. Prof. Fengtao Xiang

A dissertation

Submitted in partial fulfillment of the requirements

for the degree of Master of Engineering

in Artificial Intelligence

National University of Defense Technology

June，2026

独 创 性 声 明

本人声明所是文的学位论文是我本人在导师指导下进行的研究工作及取得的研究成果．尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表和撰写过的研究成果，也不包含为获得国防科技大学或其它教育机构的学位或证书而使用过的材料，与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文题目：面向受限场景的域泛化迁移与轻量化方法研究

学位论文作者签名：黎招新 日期：2026 年 4 月 23 日

学位论文版权使用授权书

本人完全了解国防科技大学有关保留、使用学位论文的规定，本人授权国防科技大学可以保留并向国家有关部门或机构送交论文的复印件和电子文档，允许论文被查阅和借阅；可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

（保密学位论文在解密后适用本授权书．）

学位论文题目：面向受限场景的域泛化迁移与轻量化方法研究

学位论文作者签名：黎招新 日期：2026 年 4 月 23 日

作者指导教师签名：项凤涛 日期：2026 年 4 月 23 日

目 录

摘 要 i

Abstract ii

第一章 绪论 1

1.1 研究背景与意义 1

1.2 国内外研究现状 2

1.2.1 基于域不变表示的方法 3

1.2.2 基于数据增强的方法 5

1.2.3 基于因果启发与表示解耦的方法 7

1.2.4 知识蒸馏轻量化方法 9

1.2.5 现有研究的不足 11

1.3 研究内容 12

1.4 章节安排 13

第二章 理论基础与相关技术 15

2.1 深度残差网络 15

2.2 迁移学习与域泛化内涵 16

2.2.1 迁移学习基本概念与方法 16

2.2.2 域泛化 17

2.3 域泛化关键技术 19

2.3.1 跨域特征对齐与不变性约束技术 19

2.3.2 注意力机制 20

2.3.3 特征正则化技术 22

2.3.4 频域分析与数据增强技术 23

2.4 知识蒸馏与模型轻量化技术 24

2.5 本章小结 24

第三章 基于多尺度注意力与推理一致性的域泛化方法 26

3.1 引言 26

3.2 方法设计 26

3.2.1 总体网络结构 26

3.2.2 基于跨空间多尺度信息聚合注意力机制的域鉴别器 28

3.2.3 基于动量更新的推理一致性损失 30

3.3 实验结果与分析 31
3.3.1 数据集与实验设置 31
3.3.2 方法对比分析 32
3.3.3 消融实验 37
3.3.4 参数敏感性分析 39
3.3.5 特征通道稳定性分析 40
3.3.6 可视化分析 43
3.4 本章小结 45
第四章 基于多阶段分层表示建模的域泛化方法 47
4.1 引言 47
4.2 方法设计 47
4.2.1 总体框架介绍 47
4.2.2 频率自适应傅里叶增强 49
4.2.3 面向增强特征的域敏感通道重标定 52
4.2.4 对抗性表示解耦 53
4.3 实验结果与分析 55
4.3.1 数据集与实验设置 55
4.3.2 对比实验 55
4.3.3 消融实验 57
4.3.4 可视化分析 58
4.3.5 特征统计分布分析 61
4.3.6 参数敏感性分析 62
4.4 本章小结 64
第五章 面向边缘部署的域泛化模型轻量化方法研究 65
5.1 引言 65
5.2 方法设计 66
5.2.1 总体框架介绍 66
5.2.2 基于跨头知识蒸馏的轻量化迁移方法 67
5.3 实验结果与分析 70
5.3.1 实验设置 70
5.3.2 蒸馏层位置分析 70
5.3.3 对比实验 71
5.3.4 复杂度与部署代价分析 72
5.3.5 参数敏感性分析 73

5.4 本章小结 74
第六章 总结与展望 75
6.1 工作总结 75
6.2 研究展望 76
致 谢 78
参考文献 79
作者在学期间取得的学术成果 87
公开评阅信息 88
答辩委员会 89

表 目 录

表 1.1 域泛化领域主流方法 3
表 3.1 以 ResNet-18 为主干网络在 PACS 中对比实验结果 34
表 3.2 以 ResNet-50 为主干网络在 PACS 中对比实验结果 34
表 3.3 以 ResNet-18 为主干网络在 OfficeHome 数据集中对比实验结果 36
表 3.4 以 ResNet-50 为主干网络在 OfficeHome 数据集中对比实验结果 36
表 3.5 以 ResNet-18 为主干网络在 VLCS 数据集中对比实验结果 37
表 3.6 以 ResNet-50 为主干网络在 VLCS 数据集中对比实验结果 37
表 3.7 以 ResNet-18 为主干网络消融实验结果 38
表 3.8 以 ResNet-50 为主干网络消融实验结果 38
表 3.9 注意力模块对比实验结果 39
表 3.10 不同目标域设置下 Baseline 与 CLEAR 的通道跨域波动统计结果 42
表 4.1 ResNet-18 主干网络下与现有方法的平均准确率对比 56
表 4.2 ResNet-50 主干网络下与现有方法的平均准确率对比 56
表 4.3 MS-DE 消融实验 57
表 5.1 不同蒸馏层位置下学生模型准确率 71
表 5.2 PACS 上不同方法对比实验 71
表 5.3 复杂度与部署代价 72

图 目 录

图 1.1 基于相关性感知的对抗性域泛化框架[23] 4
图 1.2 FACT 模型框架[6] 6
图 1.3 论文组织结构图 14
图 2.1 网络层数增加引起退化 15
图 2.2 两种残差结构 16
图 2.3 域泛化示意图 18
图 2.4 梯度反转层示意图 20
图 2.5 通道注意力与空间注意力[89] 21
图 3.1 CLEAR 整体架构 27
图 3.2 跨空间多尺度信息聚合注意力示意图 28
图 3.3 参数敏感性实验 39
图 3.4 Sketch 域通道跨域波动对比 41
图 3.5 不同目标域下关键统计指标对比分析 42
图 3.6 不同目标域设置下两种方法通道跨域波动分布对比 43
图 3.7 不同目标域典型样本上的 Grad-CAM 可视化总览图 44
图 3.8 不同目标域典型错误样本上的 Grad-CAM 可视化对比 45
图 4.1 MS-DE 框架 48
图 4.2 普通幅度混合与本章方法增强结果的可视化比较 58
图 4.3 t-SNE 可视化比较 60
图 4.4 不同方法在源域与目标域上的高层特征统计分布结果 61
图 4.5 不同参数下频率自适应效果比较 63
图 4.6 参数敏感性分析 64
图 5.1 基于知识蒸馏的轻量化跨域学习框架 66
图 5.2 不同蒸馏损失权重下的模型准确率与标准差 73

摘　要

面向受限场景的智能感知模型通常同时面临训练条件受限和部署资源受限两类约束。训练条件受限主要表现为目标域数据在训练阶段难以预先获取，模型只能依赖有限源域样本学习未知域泛化能力，由此容易出现域敏感特征干扰、特征响应不稳定和跨域判别依据漂移等问题；部署资源受限主要表现为边缘设备在算力、存储、功耗和实时性方面存在限制，使得参数量大、推理开销高的高性能模型难以直接应用。因此，本文围绕受限场景下未知域鲁棒识别和轻量化高效部署两个核心需求，开展域泛化与模型轻量化方法研究。

（1）针对域间分布差异和决策依据不稳定问题，本文提出一种基于多尺度注意力与推理一致性的域泛化方法。该方法通过跨空间多尺度信息聚合机制识别并抑制域敏感通道，减少环境风格和背景纹理等非稳健因素对特征表示的干扰；同时，利用基于动量更新的推理一致性约束增强同类样本判别依据的稳定性。实验结果表明，该方法以 ResNet-18 主干网络在 PACS、OfficeHome、VLCS 数据集上分别达到了 85.95%、66.19%、78.07%的平均准确率，优于当前主流域泛化方法。

（2）针对复杂域偏移在输入风格、深层特征和高层表示中同时存在的问题，本文提出一种基于多阶段分层表示建模的域泛化方法。该方法在输入层引入频率自适应傅里叶增强以扩展源域风格分布，在特征层进行域敏感通道重标定以削弱不稳定响应，在表示层构建对抗性表示解耦机制以分离稳定判别信息和环境相关干扰。实验结果表明，该方法在 PACS、OfficeHome、VLCS 数据集上的平均准确率进一步提升，其中在 ResNet-18、ResNet-50 主干网络设置下平均准确率分别达到 77.42%、81.13%。

（3）针对高性能域泛化模型参数量大、推理开销高的问题，本文提出一种基于跨头知识蒸馏的轻量化方法。该方法将学生网络中间表示送入教师模型后续任务头生成跨头预测，以构建更适合分类判别知识迁移的蒸馏约束，从而提升轻量学生模型对教师跨域判别知识的吸收效率。实验结果表明，蒸馏后的学生模型在参数量降低 85.9%的同时，平均准确率由 86.50%提升至 88.23%，接近教师模型 89.73%的性能。

综上，本文围绕受限场景下智能感知模型面临的未知域泛化与资源受限部署问题，分别从抑制域敏感通道、多阶段分层表示建模和轻量化知识迁移三个方面提出相应方法。相关研究在提升模型跨域鲁棒性的同时兼顾了边缘部署需求，可为复杂开放环境下智能感知模型的设计与应用提供方法参考。

关键词：域泛化；模型轻量化；多尺度注意力；分层表示建模；知识蒸馏；边缘部署

Abstract

Intelligent perception models for constrained scenarios usually face two types of limitations simultaneously: restricted training conditions and limited deployment resources. Restricted training conditions are mainly reflected in the difficulty of obtaining target-domain data in advance during the training stage. As a result, models can only rely on limited source-domain samples to learn generalization capability for unseen domains, which may lead to domain-sensitive feature interference, unstable feature responses, and drifting discriminative evidence across domains. Limited deployment resources are mainly reflected in the constraints of edge devices in terms of computing power, storage capacity, power consumption, and real-time requirements, making it difficult to directly deploy high-performance models with a large number of parameters and high inference costs. Therefore, focusing on the two core requirements of robust recognition in unseen domains and lightweight efficient deployment under constrained scenarios, this thesis investigates domain generalization and model lightweighting methods.

First, to address inter-domain distribution discrepancies and unstable decision evidence, this thesis proposes a domain generalization method based on multi-scale attention and inference consistency. The proposed method identifies and suppresses domain-sensitive channels through a cross-space multi-scale information aggregation mechanism, thereby reducing the interference of non-robust factors such as environmental styles and background textures on feature representations. Meanwhile, a momentum-updated inference consistency constraint is introduced to enhance the stability of discriminative evidence for samples of the same category. Experimental results show that, with ResNet-18 as the backbone, the proposed method achieves average accuracies of 85.95%, 66.19%, and 78.07% on the PACS, OfficeHome, and VLCS datasets, respectively, outperforming current mainstream domain generalization methods.

Second, to address the problem that complex domain shifts exist simultaneously in input styles, deep features, and high-level representations, this thesis proposes a domain generalization method based on multi-stage hierarchical representation modeling. The proposed method introduces frequency-adaptive Fourier augmentation at the input level to expand the style distribution of source domains, performs domain-sensitive channel recalibration at the feature level to weaken unstable responses, and constructs an adversarial representation disentanglement mechanism at the representation level to separate stable discriminative information from environment-related interference. Experimental results demonstrate that the proposed method further improves the average accuracy on the PACS, OfficeHome, and VLCS datasets, achieving overall average accuracies of 77.42% and 81.13% under the ResNet-18 and ResNet-50 backbone settings, respectively.

Third, to address the large number of parameters and high inference cost of high-performance domain generalization models, this thesis proposes a lightweight method based on cross-head knowledge distillation. The method feeds the intermediate representations of the student network into the subsequent task head of the teacher model to generate cross-head predictions, thereby constructing a distillation constraint that is more suitable for transferring classification-discriminative knowledge. This improves the efficiency with which the lightweight student model absorbs the teacher model's cross-domain discriminative knowledge. Experimental results show that, while reducing the number of parameters by 85.9%, the distilled student model improves the average accuracy from 86.50% to 88.23%, approaching the teacher model's performance of 89.73%.

In summary, this thesis addresses the challenges of unseen-domain generalization and resource-constrained deployment for intelligent perception models in constrained scenarios. Corresponding methods are proposed from three perspectives: domain-sensitive channel suppression, multi-stage hierarchical representation modeling, and lightweight knowledge transfer. The proposed research improves the cross-domain robustness of models while taking edge deployment requirements into account, providing a methodological reference for the design and application of intelligent perception models in complex open environments.

Key Words：Domain Generalization，Lightweight Modeling，Multi-Scale Attention，Hierarchical Representation Modeling，Knowledge Distillation，Edge Deployment

第一章　绪论

1.1　研究背景与意义

随着深度学习方法在图像分类、目标识别和环境感知等任务中的广泛应用，智能感知模型已经逐渐从受控数据集走向开放复杂环境。然而，在真实应用中，模型部署环境往往难以在训练阶段完整预知，测试数据可能受到成像风格、光照条件、背景纹理、传感器类型和采集平台差异等因素影响，导致训练分布与测试分布之间存在明显偏移。对于依赖训练样本统计规律的深度模型而言，这种分布失配容易引起特征响应不稳定和分类性能下降，进而影响模型在未知场景中的可靠性。

与此同时，许多智能感知任务需要部署在无人平台、嵌入式设备或边缘感知节点上，这类平台通常受到计算能力、存储空间、功耗预算和实时性要求的限制，难以直接承载参数量大、推理开销高的复杂模型。因此，面向实际受限场景的智能感知模型不仅需要具备对未知目标域的泛化能力，还需要满足轻量化部署需求。如何在目标域数据不可见的训练条件下学习稳定判别特征，并在资源受限平台上实现高效推理，成为域泛化与模型轻量化研究中需要重点解决的问题。

然而，尽管深度学习方法在公开数据集和受控环境中已经取得了优异的性能，但当其被迁移到真实作业环境时，往往会出现明显的精度下降和稳定性退化。这种差异的根本原因在于，现有模型普遍建立在训练数据和测试数据满足独立同分布假设的基础上，而真实环境中的目标域分布在训练阶段通常无法获取，模型往往需要在目标域不可访问的条件下完成跨域迁移。与此同时，真实环境具有显著的非结构化特征，极端气象、动态光照、复杂背景以及跨平台传感器差异都会引发输入分布的剧烈变化，导致模型在训练阶段学到的特征难以直接泛化到未知场景中。对于依赖历史样本统计规律进行识别的模型而言，这种分布失配将直接削弱其在实战环境中的判别能力。

除了训练分布与测试分布不一致带来的整体性能下降外，复杂开放环境中的感知模型还容易受到背景、纹理、光照、视角和成像条件等非核心因素的影响。在训练数据规模有限或源域分布覆盖不足的情况下，深度模型可能会将某些偶然出现的背景线索、局部纹理或风格统计误认为类别判别依据，从而形成对源域特定信息的依赖。当测试环境发生变化时，这些表面相关信息可能不再稳定，导致模型特征响应发生漂移，分类依据不一致，最终影响模型在未知场景中的泛化性能。因此，如何在目标域不可见的条件下削弱模型对域相关干扰信息的依赖，引导其关注更加稳定的判别特征，是提升复杂环境下智能感知模型可靠性的关键问题。

与此同时，实际应用中的智能感知模型还需要满足部署效率方面的要求。许多感知任务需要在嵌入式平台、移动终端或边缘感知节点上完成本地推理，这类设备

通常受到计算能力、存储空间、功耗预算和实时性要求的限制，难以直接部署参数量大、计算开销高的复杂模型。在通信条件受限或对响应时延要求较高的场景中，模型往往也无法完全依赖远端服务器进行推理。因此，感知模型不仅需要具备较强的未知域泛化能力，还需要在参数规模、计算复杂度和推理效率之间取得平衡，以满足资源受限条件下的实际应用需求。

基于上述分析，本文所研究的受限场景并非单一应用环境的限定，而是对智能感知模型在训练与部署过程中所面临约束条件的概括。一方面，训练条件受限表现为目标域数据在训练阶段不可访问，模型只能依赖有限源域样本学习未知环境下的泛化能力，由此容易产生域敏感特征干扰、决策依据不稳定以及多层级域偏移难以充分处理等问题；另一方面，部署资源受限表现为实际应用平台在计算能力、存储空间和推理时延方面存在约束，使得高性能但复杂度较高的域泛化模型难以直接应用。

因此，围绕受限场景开展域泛化与轻量化方法研究，具有一定的理论价值和工程参考意义。在理论层面，针对目标域不可访问条件下的复杂分布偏移问题，研究鲁棒特征提取、多阶段分层表示建模和跨域知识迁移机制，有助于降低深度学习模型对特定训练分布的依赖，推动复杂环境下稳健感知方法的发展。在工程层面，通过提升模型在未知域中的识别稳定性，并进一步降低高性能模型的参数规模和推理开销，可为资源受限条件下的智能感知算法部署提供技术支撑。

1.2 国内外研究现状

近年来，随着深度学习技术在封闭集任务上的性能逐渐提升，如何应对开放、复杂且未知的真实环境，成为智能感知技术进一步应用的重要问题。域泛化技术旨在使模型在无需接触目标域数据的前提下，仍能够在未知目标场景中保持较稳定的识别能力。从国内外研究进展来看，国外研究起步相对较早，主要围绕域不变表示学习、数据增强、稳定机制建模、大规模预训练模型和模型轻量化等方向展开，并在公开数据集上形成了较为系统的评测体系；国内研究近年来发展较快，更多结合复杂天气、工业缺陷检测、道路场景感知、时序预测和资源受限部署等实际应用需求，对特征过滤、表示解耦、数据增广和轻量化迁移等问题进行了有针对性的探索。综合来看，目前该领域的主流技术路线主要有三个方面，如表 1.1 所示：一是以对齐多个源域分布、提取跨域共享基础特征为基础的域不变表示方法；二是通过在像素、频域或深层特征空间显式扩充样本以模拟未知分布为基础的数据增强方法；三是探寻数据背后本质生成机理的因果启发方法。以下将围绕这三个方面，对现有的域泛化研究现状与发展趋势进行梳理与分析。

表 1.1 域泛化领域主流方法

域泛化分类	经典模型
基于域不变表示的方法	MMD[1]，MMD-AAE[2]，RSC[3]
基于数据增强的方法	Mixup[4]，AugMix[5]，FACT[6]，MixStyle[7]
基于因果启发与表示解耦的方法	IRM[8]，Fishr[9]，StableNet[10]

1.2.1 基于域不变表示的方法

域泛化的研究历程最早可追溯至统计学习理论分析阶段。早期的研究[11–14]多基于核方法对分布偏移问题进行建模，并通过传统的机器学习算法进行泛化误差的理论边界推导。然而，随着深度学习的快速发展，仅靠理论边界的推导已难以满足复杂视觉任务的需求，研究重心逐渐向如何利用深度神经网络提取鲁棒的底层特征转移。

目前，学习域不变表示已成为解决域泛化问题最主流且有效的核心范式。其基本假设是：不同域的数据虽然在表层上存在显著差异，但在高层语义空间中共享着决定目标本质属性的不变特征。因此，这类方法致力于通过特定的对齐机制，使多个源域和目标域在特征空间中的分布尽可能保持一致。在具体实现上，显式的分布距离度量被广泛应用，其中最小化最大均值差异距离（Minimizing Maximum Mean Discrepancy, MMD）是最经典的指标。MMD 通过将样本特征映射到再生核希尔伯特空间（Reproducing Kernel Hilbert Spaces, RKHS），并计算分布的均值差异来量化源域间的距离。例如，Li 等人[2]结合自动编码器架构，通过最小化隐藏层特征间的 MMD 距离来实现分布对齐；Li 等人[15]则提出了一种端到端的条件不变深度神经网络，旨在最小化跨域的条件分布差异。Huang 等人[3]提出的 RSC（Representation Self-Challenging）引入了一种迭代式的特征抑制机制，通过在训练过程中随机置零高梯度的特征通道，强迫模型利用剩余的非显著特征进行预测。这种训练方式不仅提升了模型挖掘目标本质特征的能力，而且不需要引入任何额外的网络参数。

除了显式度量，对比损失[16]和对抗学习[17,18]同样被广泛引入，通过优化特定的极小极大博弈目标函数，隐式地拉近不同源域的分布边界，从而迫使网络提取无法区分域标签的通用特征。Matsuura 等人[19]提出了一种方法，通过聚类将样本迭代地划分为潜在域，并通过对抗性学习训练域不变的特征提取器。其他工作在此基础上扩展了对抗性学习的方法，采用不同的分歧度量和正则化技术。例如，Lin 等人[20]基于对抗性自动编码器提出了一种多数据集特征泛化网络，通过基于领域的对抗学习来学习通用表示，能够从多个源数据集中提取域不变特征，并使用 MMD 度量来调整多个域之间的分布。Deng 等人[21]研究了对抗性屏蔽技术，以学习多个域中的不变表示。Akuzawa 等人[22]提出了基于准确性约束的域不变性概念，并开发

了一种对抗性特征学习方法，明确提供了对抗性训练的约束不变性。Rahman 等人[23]提出了基于相关性感知的对抗性域泛化框架，如图 1.1 所示。该方法将对抗学习与相关性对齐相结合，在共享网络结构下同时引入域判别器和相关性约束模块，一方面利用梯度反转机制促使特征提取器学习难以被域分类器区分的域不变表示，另一方面通过对齐不同域特征的协方差统计进一步减小域间分布差异。与仅依赖对抗训练的方法相比，该框架不仅关注特征在判别器层面的域混淆效果，还显式考虑了不同域在二阶统计特性上的一致性，从而增强了特征表示的稳定性与可迁移性。

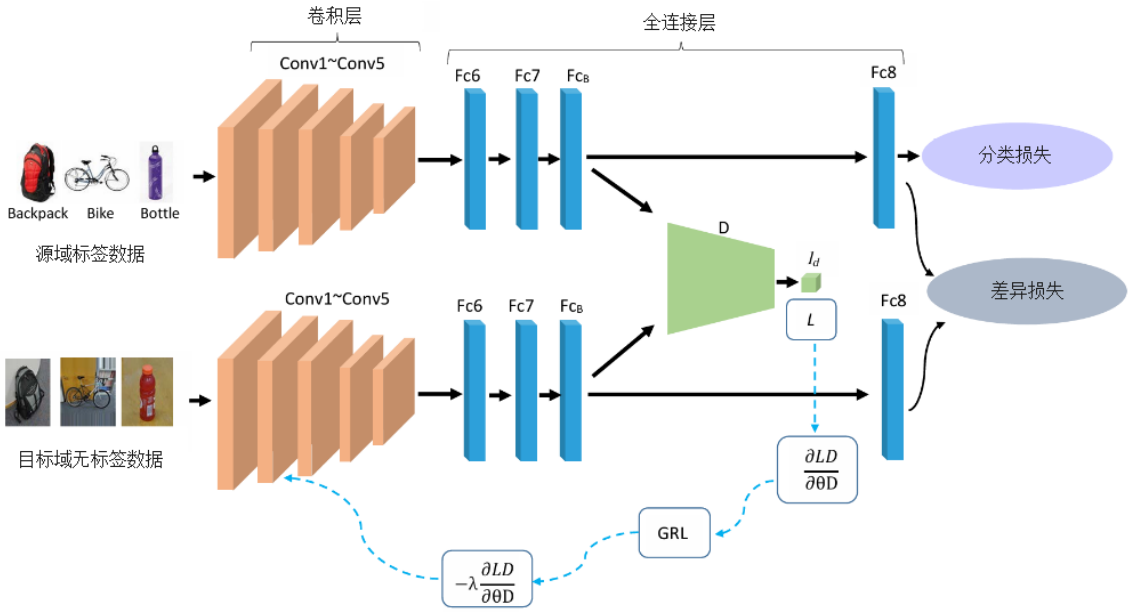


图 1.1　基于相关性感知的对抗性域泛化框架[23]

随着研究的深入，研究者发现仅仅进行粗粒度的整体分布对齐容易导致负面迁移，即忽略了特征本身的语义逻辑与重要性差异。因此，近年来的不变表示方法开始向细粒度的特征过滤与推理一致性约束方向发展。例如，Ghifary 等人[24]通过构建多任务自动编码器网络，在重建任务的约束下提取源域之间共享的底层特征，从而减少单一数据集的偏差；Arjovsky 等人[8]和倪云浩等人[25]则引入了不变风险最小化（Invariant Risk Minimization, IRM）的思想，强制最优分类器在所有观测域上保持严格的推理一致性，这为跨域不变性学习提供了新的视角。更进一步，针对特征通道中掺杂的冗余干扰信息，Guo 等人[26]提出通过选择性地限制域特定通道，从而更为纯粹地提取域不变特征；刘坤等人[27]针对跨场景亮度变化导致的缺陷检测性能退化问题，提出基于特征过滤与特征解耦的域泛化模型，通过亮度过滤—残差模块削弱亮度变化干扰，并利用对比白化损失解耦亮度变换特征和缺陷纹理特征，从而增强模型在跨场景亮度变化条件下的泛化能力。类似地，王云亭等人[28]面

向复杂天气条件下的道路场景目标检测任务，从域内不变特征和域间不变特征生成两个层面出发构建域泛化模型，并结合自蒸馏机制进一步丰富特征表达，以提升模型在未知天气条件下的检测精度与泛化能力。这些工作说明，域不变表示学习正在从通用分布对齐逐步转向面向具体干扰因素的结构化建模，从而更有效地增强模型在复杂场景中的稳健性。

在此基础上，近期研究进一步反思了传统直接特征对齐策略在大域差条件下可能带来的局限。相关工作指出，若仅通过刚性压缩方式强行拉近跨域同类样本，容易破坏样本之间原有的自然关系结构，进而引发特征错位与表示扭曲问题。为此，Wei 等人[29]提出了 SDK-SCA（Sample Difference Keeping and Sample Consistency Alignment）方法，一方面通过样本差异保持模块维护同域同类、跨域同类以及跨域异类样本之间的自然序关系，另一方面通过样本一致性对齐模块建模类间关系一致性与域间关系一致性，实现基于结构关系的间接对齐。该研究表明，域不变表示学习正在从早期的整体分布重合，逐步发展到兼顾关系保持与结构一致性的更细粒度建模阶段。这些从通道过滤到特征解耦的探索，不仅显著提升了模型对复杂环境的鲁棒性，也为本文后续提出的方法奠定了坚实的理论基础与启发。

1.2.2 基于数据增强的方法

数据增强（Data Augmentation）作为缓解深度学习模型过拟合、提升泛化能力的核心技术，在域泛化领域中扮演着举足轻重的角色。与传统封闭环境下的监督学习不同，域泛化面临的主要挑战在于源域与目标域之间存在显著的分布偏移，因此，该领域的增强策略不再局限于简单地扩充样本数量，而是旨在通过对源域数据施加特定的扰动、变换或生成操作，显式地模拟出更多样化的未知分布，从而迫使模型学习到具有跨域鲁棒性的不变特征[30–34]。根据增强操作所处的层级与作用机制，现有的研究工作主要沿着图像级（Image-level）、域级（Domain-level）以及特征级（Feature-level）三个维度展开深入探索，并逐渐呈现出从像素空间向特征空间、从随机扰动向对抗性生成的演进趋势。

在图像级数据增强方面，早期的研究主要依赖于几何变换（如翻转、旋转、裁剪）和光度变换（如颜色抖动、灰度化），旨在模拟物体形态和光照条件的基础变化。然而，这类简单的变换难以覆盖复杂的非结构化环境差异。为了解决这一问题，基于混合的策略应运而生并成为主流。Zhang 等人[4]提出的 Mixup 通过在输入空间或隐藏层空间对不同样本及其标签进行线性插值，有效地平滑了模型的决策边界，增强了模型对对抗样本的防御能力。在此基础上，Hendrycks 等人[5]提出的 AugMix 进一步引入了一致性约束机制，通过级联多种增强操作并将结果进行混合，迫使模型对同一图像的不同增强视图保持预测一致性，显著提升了模型在 CIFAR-10-C 等

损坏数据集上的鲁棒性。

相比于在单一域内进行变换，域级数据增强旨在通过生成全新的合成域来填补源域分布之间的空白，从根本上扩展训练数据的多样性[35–38]。这一方向的早期突破主要得益于生成对抗网络（Generative adversarial network, GAN）的发展，例如 CycleGAN（Cycle-consistent Adversarial Networks）[39]被广泛用于将源域图像转换到多种潜在的风格空间，试图覆盖所有可能的目标域风格。Volpi 等人[40]和 Zhao 等人[41]利用对抗训练的思想，通过最大化模型的预测误差或熵值来生成困难样本，使得模型在训练过程中不断接触分布边界上的极端情况，从而显著提升其在未知目标域上的泛化潜力。随着扩散模型（Diffusion Models）的兴起，其强大的分布拟合能力使得生成高质量、高保真的跨域样本成为可能[42]。如童煜钧等[43]提出了一种基于扩散模型数据增广的域泛化方法，在隐空间中引入扩散模型实现对特征的精细控制和多样性生成，使增广焦点由图像级转移到特征级，从而提升目标域上的泛化性能，但昂贵的采样与训练成本限制了其实时应用。

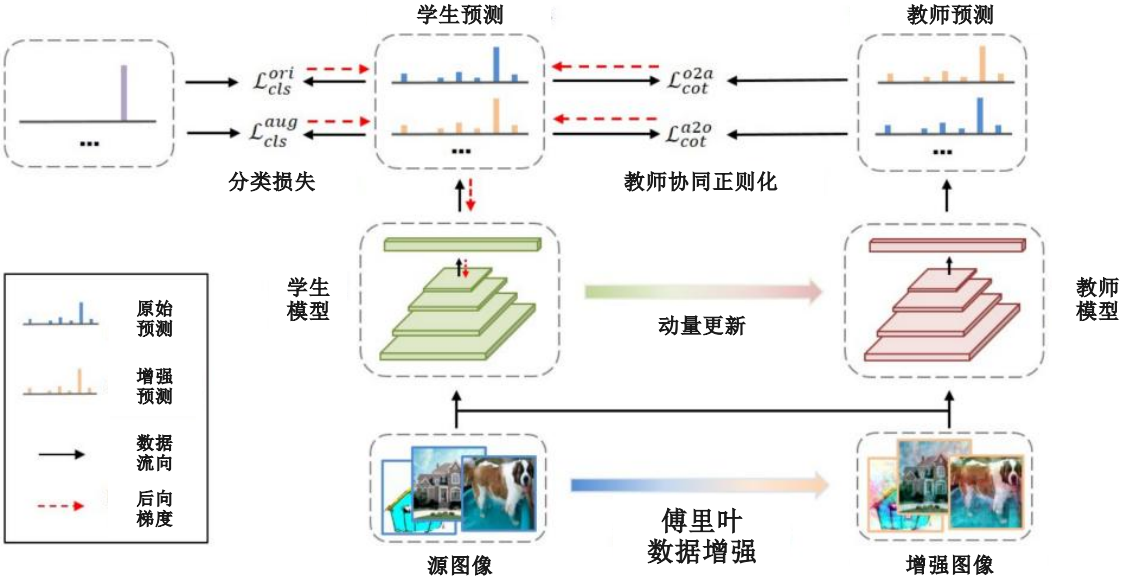


图 1.2　FACT 模型框架[6]

为了在增强效果与计算效率之间取得平衡，基于频域的数据增强方法逐渐受到关注。该类方法通常利用傅里叶变换将图像分解到频域空间，并通过扰动或混合幅度谱来改变图像风格统计，同时尽量保持图像的空间结构信息不变。代表性方法如 Xu 等人提出的 FACT（Fourier Augmented Co-Teacher）[6,44]，如图 1.2 所示，以及 Wang 等人提出的分解频率修正方法[45]，创新性地通过交换不同域图像的幅度谱或对特定频段进行扰动，同时保持相位谱不变，从而在不破坏语义结构的前提下实现了极其高效的风格迁移。这种方法无需训练额外的生成网络，仅需通过快速傅里叶变换（Fast Fourier Transform, FFT）即可完成，极大地降低了计算开销。

除了在像素与频域空间进行操作外，特征级数据增强因其直接作用于深层语义空间且计算代价低廉，正逐渐成为连接高精度与轻量化部署的重要桥梁。该类方法的核心逻辑是模拟不同域在特征空间中的分布差异。Zhou 等人[7,46]提出的 MixStyle 基于特征统计量代表图像风格的假设，通过在卷积神经网络的中间层混合不同样本的统计量，实现了隐式的风格迁移，有效防止了模型对源域特定风格的过拟合。Li 等人[30]进一步提出了 EFDM（Exact Feature Distribution Matching），通过匹配更高阶的特征分布矩来对齐域分布。此外，为了解决模型过度依赖背景纹理等虚假相关特征的问题，在单源域泛化场景下，孙灿等[47]也提出基于域增强和特征对齐的元学习方案，利用背景替换与视觉损害为每张图像生成多样且有效的增强样本，并通过多通道特征对齐模块强化源域与增强域之间的语义一致性和可迁移知识提取能力。

与此同时，近年来研究者也开始意识到，数据增强方法的有效性不仅取决于增强策略本身，还与域泛化基准数据集对真实分布变化的刻画能力密切相关。针对现有数据集域数量有限、普遍采用留一域（Leave-One-Domain-Out, LODO）评测策略所带来的评估不足问题，Zhang 等人[48]提出了更大规模的域泛化基准 NICO++，并从协变量偏移和概念偏移两个角度分析了数据集的评测能力。这一工作从数据构建与评测协议层面为域泛化研究提供了新的思考，也从侧面说明了通过扩展训练分布和提升环境变化覆盖度来增强模型泛化能力的重要性。

1.2.3 基于因果启发与表示解耦的方法

传统深度学习模型在域泛化任务中通常依赖训练数据中的统计相关性完成分类决策，当训练域与测试域之间存在显著分布差异时，模型容易受到背景纹理、成像风格、上下文线索等表面相关信息的干扰，导致在未知域中的泛化性能明显下降。为缓解这一问题，近年来研究者开始将因果推理思想引入域泛化领域，尝试从单纯的分布对齐与样本扩展，进一步转向对跨环境稳定判别机制的建模[49–53]。与传统方法主要关注整体分布差异不同，这类研究更加重视在不同环境变化下仍能保持一致的预测依据，旨在降低模型对环境相关统计模式的依赖，增强其在未知场景中的鲁棒性。

现有相关研究大体可以分为两类。一类是基于稳定机制约束的方法，其核心思想是通过跨域一致性约束，引导模型学习在不同训练环境中共享的稳定预测规则。IRM[8]是这一方向的重要代表方法之一，它通过约束模型在多个训练域中保持一致的最优分类机制，推动表征学习从相关性向稳定性转变。随后，研究者进一步提出了一系列更具可操作性的近似方法，例如 Fishr[9]通过匹配不同域之间梯度统计量的差异来逼近稳定预测器，StableNet[10]则通过稳定学习思想减轻模型对伪相关模

式的依赖。这类方法通常并不直接恢复完整的因果生成结构，而是通过风险一致性、梯度一致性或稳定性正则等形式，促使模型逼近跨环境共享的判别机制，从而提升分布外泛化能力。

另一类方法则进一步从高层表示的内部结构出发，借助表示解耦、对抗干预和结构建模等方式，对模型的判别依据进行更细粒度的优化。该类方法认为，单纯依赖整体分布一致性约束，仍可能使模型保留与环境共现的干扰成分，因此需要在表示空间中进一步区分更稳定的判别信息与受背景、纹理或上下文影响较大的非稳健成分。在这一思路下，部分研究引入因果图或结构因果模型来显式建模类间关系与环境因素之间的联系，如 CauRDG（Causal-Driven Semantic Consistency Reasoning）[54]引入原型引导的因果解耦模块，通过原型层级上的结构关系来区分更稳定的跨域机制与域特定变化；同时设计双空间语义辨析策略，在局部类别清晰性与全局概念一致性之间建立协同约束。明水根等[55]提出了一种基于因果关系和特征对齐的图像分类域泛化模型，将域泛化问题转化为特征相关分布的偏移问题，先利用变分自编码器框架将输入特征解耦为域信息因子、标签信息因子和残余信息因子，再通过特征对齐与对抗训练减弱潜在因子中的混淆信息，以兼顾理论可解释性和实际性能。此外，在非视觉分类任务中，相关思想也开始向更广泛的数据类型延伸。王祥波等[56]面向时序预测场景提出基于场景不可知学习的时序数据域泛化方法，不再显式划分训练环境，而是通过核心样本选择与正则化机制平衡模型在不同样本上的表现，以学习更稳定的可迁移特征。

总体来看，基于因果启发与表示解耦的方法推动了域泛化研究向稳定机制建模演进，为解决复杂环境下模型易受表面相关模式干扰的问题提供了新的研究思路。然而，现有研究仍多聚焦于单一层级的约束或分离过程，对于输入风格扩展、特征响应调制以及高层表示分离之间的协同建模考虑仍不充分。基于此，本文在后续研究中进一步从输入层、特征层和表示层出发，探索多阶段分层表示建模方法，以增强模型在复杂分布变化条件下对稳定判别表示的提取与利用能力。

除围绕域不变表示、数据增强和表示解耦等方向不断提出新方法外，也有研究开始重新审视强基线与训练策略在域泛化中的真实作用。代表性工作 ERM++（Empirical Risk Minimization）[57]指出，简单经验风险最小化框架之所以在不少评测中被低估，一个重要原因在于以往研究往往只调节了有限的超参数，而忽视了训练数据利用方式、初始化策略以及正则化设计对跨域泛化性能的显著影响。该工作表明，若在训练步数选择、训练—验证数据使用方式、初始化质量以及防止过拟合和灾难性遗忘等方面进行更充分的优化，改进后的基线也可在多个标准基准上取得非常有竞争力的结果。上述现象说明，域泛化性能的提升并不完全依赖额外模块或复杂机制设计，训练范式本身以及对过拟合行为的控制同样是影响模型跨域泛

化能力的重要因素。这也提示后续研究在强调方法创新的同时，应更加重视与强基线之间的公平比较以及训练策略设计的系统性。

近年来，随着大规模视觉预训练模型和视觉—语言模型的发展，域泛化研究开始从传统的分布对齐、数据增强和表示解耦方法，进一步扩展到利用大规模预训练先验提升未知域鲁棒性的方向。Wen 等人[58]提出通过学习多样化文本提示来提升 CLIP 在域泛化任务中的表现，利用不同文本提示模拟潜在域变化，并结合域敏感特征抑制、一致性约束和特征多样化正则，引导模型学习更加稳定的域不变表示。Zhang 等人[59]进一步从视觉基础模型与视觉—语言模型融合角度出发，提出基于 Mamba 结构的跨模型特征融合框架，用于域泛化语义分割任务，说明不同类型大规模预训练模型在跨域感知中具有互补利用价值。Zhao 等人[60]则关注视觉基础模型在域泛化任务中的鲁棒微调问题，通过 Fisher 信息刻画不同参数对域变化的敏感程度，并对参数更新进行选择性约束，以在适配下游任务的同时尽量保持预训练模型的泛化能力。此外，Kritikos 等人[61]提出 CrossFlowDG，利用跨模态流匹配将带有域偏差的图像表示向更加稳定的文本语义表示迁移，进一步体现了多模态表征在域泛化任务中的应用潜力。上述研究表明，基于大规模预训练模型的域泛化方法已成为近年来的重要前沿方向，其优势在于能够利用更丰富的视觉语义先验提升未知域适应能力，但同时也带来了模型规模大、计算开销高和部署成本较高等问题。

1.2.4 知识蒸馏轻量化方法

随着深度学习模型在移动终端、嵌入式设备和无人系统中的广泛应用，模型部署已不再只关注识别精度，还受到存储容量、计算资源、推理时延和能耗预算等多重约束。因此，在尽量保持模型判别能力和泛化性能的前提下实现轻量化，已成为边缘智能研究中的重要方向。围绕这一问题，研究者提出了轻量化网络设计、参数剪枝、量化压缩、低秩分解以及知识蒸馏等多种方法。其中，知识蒸馏通过教师—学生框架将高容量模型中的判别知识迁移到轻量化学生网络中，不需要直接改变学生模型的基本结构形式，在兼顾性能保持与部署效率方面表现出较强优势[62–65]。

知识蒸馏最早由软标签学习发展而来，其基本思想是利用教师模型输出的类别概率分布为学生提供额外监督，使学生在拟合真实标签之外进一步学习教师模型输出中所蕴含的类别间关系信息[62]。这类基于输出分布的蒸馏方法实现简单、适用广泛，是轻量化迁移中最常见的技术路径之一。随后，针对师生容量差距较大时蒸馏效率下降的问题，研究者进一步提出了教师辅助蒸馏等改进策略，通过引入中间规模模型缓解大教师与小学生之间的知识传递障碍[66]。近年的一些工作则开始从输出分布本身进行改进，例如通过对 logits 进行归一化或解耦处理来提升蒸馏

稳定性，如 NormKD（Normalized Logits for Knowledge Distillation）[67]和 DKL（Decoupled Kullback-leibler Divergence Loss）[68]等。这些研究说明，仅依赖最终输出层进行蒸馏虽然具有较好的工程可行性，但在模型结构差异较大或知识复杂度较高时，单一输出监督往往难以充分完成有效迁移。

为进一步提升知识迁移质量，研究者开始关注教师网络中间层所蕴含的表征信息，由此形成了基于中间特征的蒸馏方法。这类方法通过约束教师与学生在隐藏层表示上的一致性，使学生能够学习教师逐层提取到的判别信息。典型工作如 Attention Transfer[69]通过注意力映射传递教师网络关注的关键区域，Heo 等人[70]进一步从激活边界角度刻画了更细粒度的表征迁移方式。近年来，特征蒸馏继续朝着更灵活的变换和更强的判别强化方向发展，例如通过简单多层感知机完成特征映射的做法[71]，通过注意力机制先对教师和学生特征进行显著性筛选再蒸馏的 AttnFD（Attention-guided Feature Distillation）[72]，以及从频域角度增强蒸馏判别性的 FreeKD（Knowledge distillation via semantic frequency prompt）[73]。相较于仅依赖最终 logits 的方法，特征蒸馏能够提供更丰富的中间监督，因此更适合将高性能教师模型中的表示能力迁移到轻量学生网络中。

在输出分布和中间特征之外，研究者还注意到教师模型所形成的结构关系信息同样具有重要迁移价值，由此发展出基于关系约束的蒸馏方法。这类方法不再局限于点对点模仿单个样本的输出或特征，而是进一步传递样本之间、通道之间或类别之间的相对关系。例如，Yim 等人[74]提出通过层间特征内积建模求解过程中的流动关系，RKD（Relational Knowledge Distillation）[75]和 SPKD（Similarity-preserving Knowledge Distillation）[76]分别从样本间距离、角度和相似性关系出发进行知识迁移，后续又扩展到了通道级和类别级关系建模[77]。近两年的工作进一步强化了这一方向，例如 Cheng 等人[78]继续从样本间与样本内关系传递角度改进蒸馏效果，AICSD（Adaptive Inter-class Similarity Distillation）[79]则通过自适应类间相似性蒸馏增强类别结构信息的迁移。相较于传统点对点蒸馏，关系蒸馏更强调保持教师模型在特征空间中的整体组织方式，因此在提升学生模型类内紧致性和类间分离性方面具有独特优势。

除了知识类型本身，近年的研究还开始更加重视蒸馏过程中不同监督信号的协调问题。已有工作表明，教师监督并非始终对学生有益，蒸馏强度需要随训练阶段、样本难度或类别特性进行动态调节，否则可能削弱学生对任务本身的拟合能力[80]。围绕这一问题，研究者提出了多种自适应蒸馏策略，例如 Cho 等人[80]通过动态损失缩放调节教师监督作用，Zhang 等人[81]通过元学习或多教师权重分配实现更灵活知识融合，Wang 等人[82]进一步关注蒸馏过程中真实标签监督与教师预测监督之间的冲突问题，将学生模型任务头中的中间特征送入教师任务头后续层生成

跨头预测，并以此构建蒸馏约束，为本文后续开展跨头知识蒸馏提供了参考。这类研究对于受限场景下的轻量化迁移具有现实意义，因为轻量学生模型容量有限，若真实标签监督与教师知识监督之间缺乏有效协调，往往更容易出现优化冲突。

从轻量部署角度看，知识蒸馏的优势不仅在于能够压缩高性能教师模型的知识，还在于它适合作为一种迁移机制，将大模型中已有的判别能力、表示结构和决策规律传递到更小的学生模型中。这一点在视觉基础模型和视觉—语言模型快速发展的背景下尤为突出。随着教师模型表征能力不断增强，其直接部署成本也同步升高，使得蒸馏成为连接模型能力与工程部署之间的重要桥梁。近年的 CLIP-KD[83] 和 Clip-Embed-KD[84]等工作，也从侧面说明了高性能预训练模型向更轻量任务模型迁移已成为一条重要趋势。

近期研究进一步将大规模视觉—语言模型和视觉基础模型中的通用知识迁移到轻量网络中，以缓解高性能模型难以直接部署的问题。Jang 等人[85]提出 VL2Lite，通过任务特定知识蒸馏将大规模视觉—语言模型中的多模态表征知识直接迁移到轻量学生网络中，使学生模型在不增加推理阶段额外开销的情况下获得性能提升。Lv 等人[86]进一步指出，传统知识蒸馏方法往往更关注源域或域内性能保持，而容易忽视分布偏移条件下的域外泛化能力；为此，其提出面向语义分割任务的可泛化知识蒸馏框架，通过分阶段表示蒸馏和查询式软蒸馏机制，引导学生模型学习更具域泛化能力的表示。

从这一角度看，大规模预训练模型方案与本文面向边缘受限场景的轻量化方案并非替代关系，而是具有互补性。一方面，近年的大规模视觉预训练和视觉—语言模型能够提供更丰富的跨域视觉语义知识，在开放环境和未知域任务中具有较强潜力；另一方面，此类模型通常计算复杂度和存储开销较高，直接部署到无人系统、嵌入式设备和前沿感知节点时仍会受到算力、功耗和实时性条件限制。因此，在边缘受限场景下，更可行的技术路径是将高性能模型作为教师模型或知识源，通过知识蒸馏、特征迁移和任务头适配等方式，将其判别知识压缩到轻量学生模型中。本文第五章提出的跨头知识蒸馏方法正是围绕这一问题展开，旨在提升轻量学生模型在未知目标域上的泛化性能，并在性能保持与部署代价之间取得平衡。

1.2.5 现有研究的不足

综上所述，现有域泛化与模型轻量化研究已从域不变表示学习、数据增强、因果启发与表示解耦、大规模预训练模型以及知识蒸馏等方向开展了大量探索，并在公开基准数据集上取得了较好效果。然而，面向本文所关注的受限场景，相关研究仍面临若干难点：首先，在目标域不可见条件下，模型无法利用目标环境数据进行分布估计或自适应调整，只能依赖有限源域样本学习可迁移表示，因此如何从源域

中准确区分稳定判别信息与域特定干扰信息，是提升未知域泛化能力的核心难点；其次，复杂环境中的域偏移通常同时体现在输入风格、深层特征响应和高层语义表示等多个层级，背景纹理、成像风格、光照变化和上下文线索容易与目标类别信息发生耦合，仅依赖单一层级的特征对齐、数据增强或表示解耦，难以充分削弱多层次域相关干扰；再次，面向边缘部署时，高性能域泛化模型往往具有较大的参数量和推理开销，而轻量学生模型容量有限，难以完整继承教师模型中的跨域判别知识，如何在性能保持与复杂度控制之间取得平衡，也是资源受限场景下需要解决的重要问题。总体来看，现有方法在域敏感信息识别、跨域推理稳定性、多层级协同建模以及轻量化知识迁移方面仍存在进一步研究空间。

基于上述分析，本文围绕受限场景下的域泛化与轻量化问题展开研究。针对域敏感特征干扰和推理依据不稳定问题，提出基于多尺度注意力与推理一致性的域泛化方法；针对复杂域偏移在输入层、特征层和表示层同时存在的问题，提出基于多阶段分层表示建模的域泛化方法；针对高性能模型难以直接部署于资源受限平台的问题，提出面向边缘部署的跨头知识蒸馏轻量化方法。通过上述研究，本文试图在未知域泛化能力提升与轻量化部署需求之间建立更加紧密的联系，为复杂开放环境下的智能感知模型设计提供方法参考。

1.3 研究内容

围绕受限场景下智能感知模型面临的训练条件受限与部署资源受限问题，本文将研究内容进一步分解为三个相互关联的子问题。首先，在目标域不可见且源域样本有限的条件下，模型容易学习到与背景纹理、成像风格等因素相关的域敏感特征，并在未知域中出现判别依据漂移，因此需要研究能够抑制域敏感响应并保持推理稳定性的域泛化方法。其次，复杂域偏移并不只存在于单一层级，而是可能同时体现在输入风格、深层特征响应和高层语义表示中，因此需要从多个阶段协同削弱域相关干扰。最后，在资源受限平台上，高性能域泛化模型往往存在参数量大、推理开销高的问题，因此需要进一步研究面向部署效率的轻量化知识迁移方法。基于上述分析，本文主要开展以下三方面研究。

（1）基于多尺度注意力与推理一致性的域泛化方法研究

针对复杂环境下域间分布差异明显、模型特征提取能力退化以及决策边界不稳定的问题，本文提出了一种基于多尺度注意力与推理一致性的域泛化方法。该方法从特征层建模出发，首先设计跨空间多尺度信息聚合注意力判别器，通过融合多尺度空间注意力与通道筛选机制，自动识别并抑制对域变化敏感的冗余特征通道，从而降低环境噪声与成像风格差异对特征表示的干扰。随后，针对跨域训练过程中类内表示漂移和决策准则不稳定的问题，引入基于动量更新的推理一致性约束，通过维护跨批次的类别原型表示，增强模型在不同域和不同训练阶段下对同类目标

判别依据的一致性。该研究旨在从特征选择与判别约束两个方面提升模型在复杂环境下的稳定识别能力，为后续更深层次的表示建模奠定基础。

（2）基于多阶段分层表示建模的域泛化方法研究

针对复杂环境中目标语义与背景纹理、成像风格及上下文线索深度耦合，导致模型容易依赖表面相关信息进行预测的问题，本文提出了一种基于多阶段分层表示建模的域泛化方法。该方法围绕“输入层—特征层—表示层”的分层表示建模思路，构建逐级递进的域泛化方法。在输入层，设计频率自适应傅里叶增强策略，通过对幅度谱进行受控混合与调节，在保持目标结构信息的同时扩展环境风格多样性，提高训练分布对未知域变化的覆盖能力。在特征层，进一步引入域敏感特征调制机制，对深层表示中与域变化显著相关的通道响应进行抑制，减少环境相关信息在高层特征中的残留。在表示层，构建对抗性表示解耦模块，通过可学习掩码将高层表示划分为优势特征分量与互补特征分量，并借助交替对抗优化强化二者在分类作用上的差异，从而降低模型对伪相关线索的依赖。该研究旨在将域泛化过程由单一特征层处理推进到多阶段分层表示建模层面，进一步提升模型在复杂未知环境下的跨域泛化能力。

（3）面向边缘部署的域泛化模型轻量化方法研究

针对高性能域泛化模型参数规模较大、计算开销较高，而轻量模型又难以充分保持跨域判别能力的问题，本文进一步研究面向资源受限场景的轻量化知识迁移方法。本方法以高性能域泛化模型作为教师模型，以轻量化网络作为学生模型，重点探索如何在不显著增加学生模型部署代价的前提下，将教师模型中蕴含的稳定判别知识有效迁移至学生模型。为此，本文构建基于跨头知识蒸馏的迁移框架，通过将学生模型中间表示送入教师任务头后续层生成跨头预测，形成更适合高层判别知识传递的蒸馏约束，从而提升轻量学生模型在未知目标域上的识别性能。该研究旨在兼顾模型跨域泛化能力与部署效率，为资源受限条件下的智能感知模型应用提供轻量化方法支撑。

1.4 章节安排

本文围绕受限场景下的域泛化与轻量化方法研究展开，共分为六章，组织结构如图 1.3 所示。

第一章绪论。本章介绍研究背景与意义，分析复杂开放环境下智能感知模型面临的未知域泛化和资源受限部署问题，梳理域泛化与模型轻量化相关研究现状，并概述本文的主要研究内容。

第二章理论基础与相关技术。本章介绍本文研究所涉及的基础理论和关键技术，包括深度残差网络、迁移学习与域泛化、跨域特征对齐、注意力机制、特征正则化、频域增强以及知识蒸馏等内容，为后续方法设计提供理论基础。

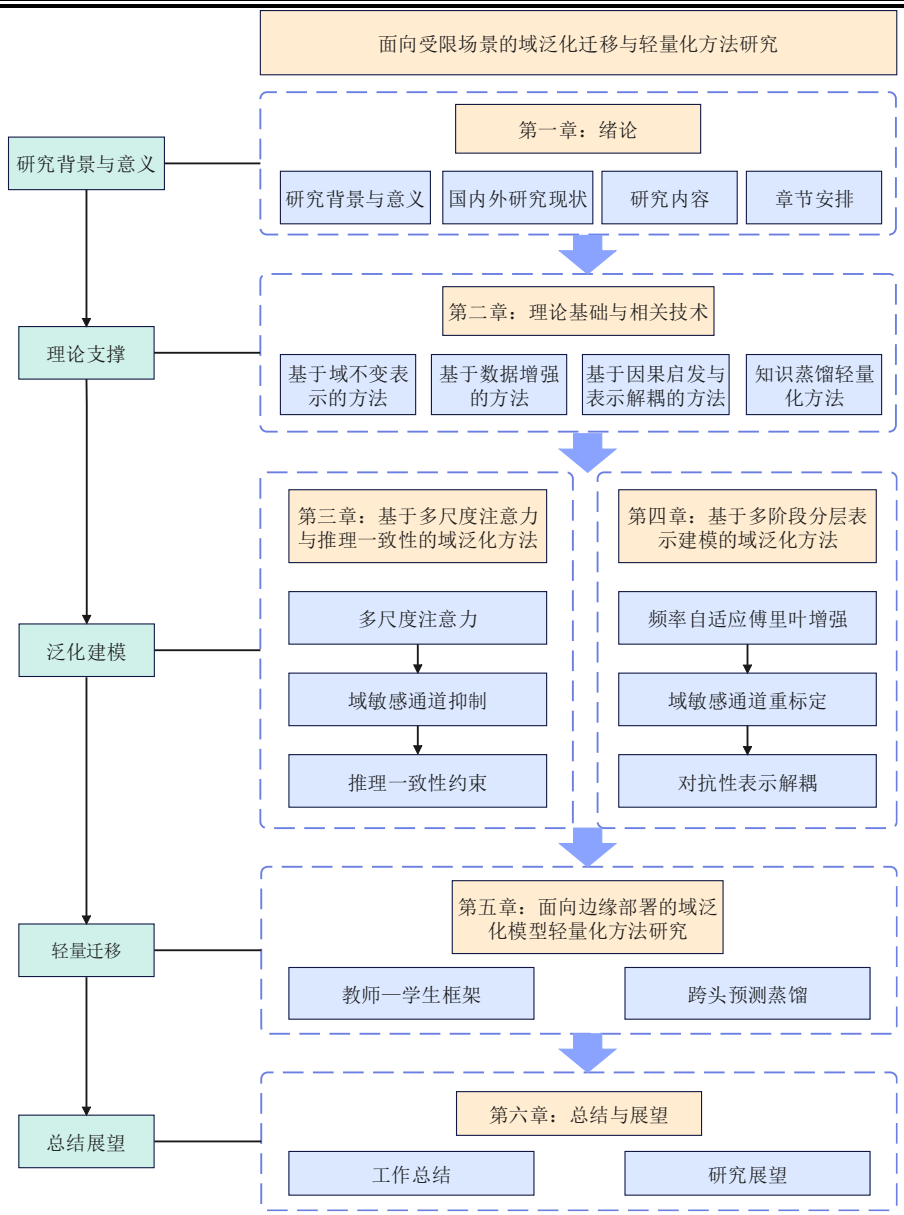


图 1.3　论文组织结构图

第三章基于多尺度注意力与推理一致性的域泛化方法。本章提出 CLEAR 方法，并通过对比实验、消融实验、参数敏感性分析和可视化分析验证其在未知目标域上的泛化性能。

第四章基于多阶段分层表示建模的域泛化方法。本章提出 MS-DE 方法，从输入、特征和表示三个层面对域泛化模型进行优化，并通过多组实验分析其有效性。

第五章面向边缘部署的域泛化模型轻量化方法研究。本章提出基于跨头知识蒸馏的轻量化迁移方法，研究高性能教师模型向轻量学生模型的知识迁移问题，并分析其性能与部署代价。

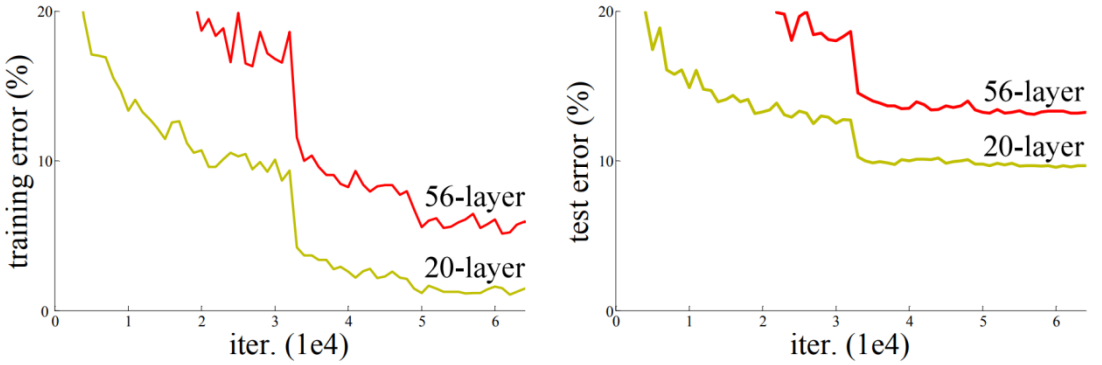
第六章总结与展望。本章总结全文主要研究工作，分析当前研究的不足，并对后续可进一步开展的研究方向进行展望。

第二章　理论基础与相关技术

为了深入开展面向复杂环境的无人系统域泛化感知与轻量化部署研究，本章将对本文涉及的核心理论与关键技术进行系统性的回顾与梳理。首先，本章将介绍深度学习与卷积神经网络的基础构成与信息流转机制，阐明其在多层级视觉特征提取中的核心作用；其次，从统计学习的角度形式化定义迁移学习与域泛化问题，明确本文旨在解决的跨域分布偏移难题与应用边界；最后，深入剖析跨域特征对齐与不变性约束、频域分析与数据增强等前沿关键技术。本章所涵盖的理论基础，将为后续章节提供理论依据与技术支撑。

2.1　深度残差网络

卷积神经网络作为深度学习在计算机视觉领域的核心基石，其特征提取能力通常与网络的深度呈正相关。理论上，随着网络层数的增加，模型应当能够捕获更加丰富的高层语义特征，从而提升在复杂环境下的识别精度。然而，在实际训练过程中，研究者发现随着网络深度的不断堆叠，模型不仅面临梯度消失或梯度爆炸的风险，更会出现一种反直觉的退化：即在网络收敛达到饱和后，继续增加层数反而会导致训练误差和测试误差的双重上升，如图 2.1 所示。为了解决这一优化难题，He 等人[87]提出了深度残差网络（ResNet），通过引入残差学习框架，成功打破了深度网络的训练瓶颈，使其成为目前域泛化研究中最为主流的主干特征提取网络。



(a)　　(b)

图 2.1　网络层数增加引起退化

残差网络的核心创新在于改变了深层网络的学习目标。传统的卷积网络试图让堆叠的非线性层直接拟合目标映射函数，而在深层结构中寻找恒等映射极其困难。残差网络则引入了跳跃连接结构，将学习目标转化为拟合输入与输出之间的残差映射。在这种结构下，输入信号可以直接跨过中间的卷积层，与卷积层的输出进行逐元素相加。这种设计使得网络在极端情况下只需将残差部分的权重学习为零，即可轻松实现恒等映射，保证了网络性能不会因层数增加而下降。更重要的是，跳

跃连接使得反向传播时的梯度能够无损地传导至浅层网络，有效缓解了梯度消失现象，使得训练数百层甚至上千层的超深网络成为可能。

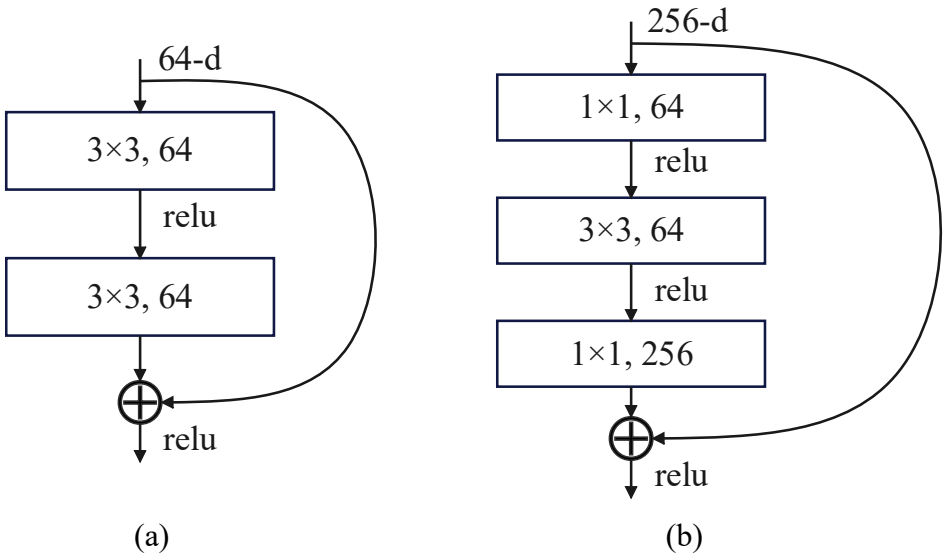


图 2.2　两种残差结构

针对不同深度的网络需求，残差单元的设计主要分为基础残差块和瓶颈残差块两种形式，这也对应了本文实验中采用的两种主干网络架构，如图 2.2 所示。对于层数较少的网络（如 ResNet-18），主要采用由两个连续卷积层组成的基础残差块，其结构简单且易于提取局部纹理特征，适合对推理延迟敏感的边缘侧应用。而对于层数较深的网络（如 ResNet-50 及以上），为了在提升深度的同时控制参数量与计算复杂度，设计采用了包含三层卷积的瓶颈结构。该结构利用首尾两个小卷积核分别进行通道降维与升维，中间层在低维空间进行特征卷积。这种设计在大幅降低计算开销的同时，保持了强大的特征抽象能力，使其能够有效提取出具有高度语义不变性的目标特征，为解决跨域感知中的分布偏移问题提供了坚实的特征基础。

2.2　迁移学习与域泛化内涵

2.2.1　迁移学习基本概念与方法

传统的机器学习与深度学习算法通常建立在训练数据与测试数据服从独立同分布（Independent and Identically Distributed, i.i.d.）这一核心假设之上，然而在实际的环境感知任务中，受气象变化、地域差异等非结构化因素影响，这一假设往往难以成立，导致模型在面对分布偏移的数据时性能急剧下降。迁移学习（Transfer Learning）旨在打破这一限制，通过利用一个或多个源域（Source Domain）中积累的知识，改善模型在相关但分布不同的目标域（Target Domain）上的泛化能力，其本质是解决数据分布差异导致的性能下降问题以及目标域标注样本匮乏的难题。

为了形式化描述迁移学习过程，通常将域（Domain）定义为由特征空间$\mathcal{X}$和边

缘概率分布$P(X)$两部分组成，记为$\mathcal{D}=\{\mathcal{X},P(X)\}$，其中$X=\{x_1,\ldots,x_n\}\in\mathcal{X}$；将任务（Task）定义为由标签空间$\mathcal{Y}$和预测函数$f(\cdot)$组成，记为$\mathcal{T}=\{\mathcal{Y},f(\cdot)\}$。

基于此定义，迁移学习的目标即是在给定源域$\mathcal{D}_S$和源任务$\mathcal{T}_S$，以及目标域$\mathcal{D}_T$和目标任务$\mathcal{T}_T$的情况下，利用源域知识提升目标预测函数$f_T(\cdot)$的性能，其中$\mathcal{D}_S\neq\mathcal{D}_T$或$\mathcal{T}_S\neq\mathcal{T}_T$。在视觉感知等实际应用中，最常见的情形是源任务与目标任务相同（即$\mathcal{T}_S=\mathcal{T}_T$），但由于环境变化导致数据分布不同（$P(X_S)\neq P(X_T)$），这类问题被称为域适应（Domain Adaptation, DA）。域适应假设在训练阶段可以访问到全部或部分无标签的目标域数据，通过对齐源域与目标域的特征分布来实现知识迁移。

然而，在诸如无人侦察等强对抗、高动态的应用场景下，模型在部署前往往无法预知并获取目标域的数据，这种更为严苛的约束条件催生了域泛化（Domain Generalization, DG）的研究，如图 2.3 所示。域泛化可以被视为迁移学习的一种特殊且更具挑战性的形式，其目标是利用多个不同的源域数据进行训练，学习到能够跨越不同分布的内在不变机理，从而使得模型能够直接在完全未知的目标域上保持良好的预测性能。与域适应不同，域泛化严格遵循训练与测试分离原则，即训练过程中完全不可见目标域数据，这要求算法必须具备更深层次的特征解耦与因果推理能力，以剥离特定域的虚假相关性。

针对上述问题，基于深度神经网络的迁移学习方法主要通过不同的机制来实现知识的跨域共享与适配。基于特征的迁移方法假设源域和目标域在高层语义空间中存在公共的特征表示，通过学习一个特征变换将不同域的数据映射到同一子空间，并利用 MMD 等统计指标或引入对抗性判别器来最小化分布差异，从而提取出域不变特征，这一思路构成了解决域泛化特征对齐问题的基础。基于模型的迁移方法则假设源域和目标域的模型之间共享某些参数或先验知识，通常利用在源域大数据上预训练的强力模型作为初始点，或者通过知识蒸馏（Knowledge Distillation，KD）技术，利用“教师—学生”网络架构，将源域模型学到的复杂知识压缩并传递给目标域模型或轻量化模型。此外，基于数据的迁移方法通过对源域样本进行重加权或利用生成对抗网络进行风格增强，在数据层面模拟目标域分布，从而提升模型的鲁棒性。这些方法从特征、模型参数及数据样本三个维度，共同构成了现代深度迁移学习与域泛化的技术体系。

2.2.2 域泛化

域泛化是为了解决目标域数据在训练阶段完全不可见这一极端情形而提出的机器学习范式，其核心挑战在于如何从有限的源域分布中学习到能够外推至未知分布的通用决策函数，如图 2.3 所示。与域适应不同，域泛化不依赖于目标域的任何统计信息，而是假设虽然不同域的边缘概率分布$P(X)$存在显著差异，但它们之

间共享某种本质的条件概率分布$P(Y|X)$或因果机制。在无人系统的实际应用中，这意味着算法必须从多个已知训练场景中，提炼出独立于背景环境的目标固有属性，从而在未知的实战场景中保持稳定的识别能力。

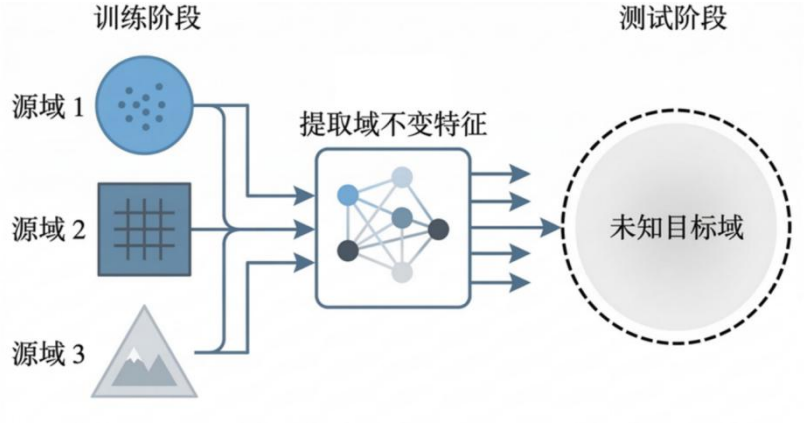


图 2.3　域泛化示意图

在数学形式上，假设存在K个分布各异但在语义上相关的源域，记为$\mathcal{S}=\{\mathcal{D}_S^k\}_{k=1}^K$，其中第$k$个源域$\mathcal{D}_S^k=\{(x_i^k,y_i^k)\}_{i=1}^{N_k}$包含$N_k$个标记样本。所有源域共享相同的标签空间$\mathcal{Y}$和任务$\mathcal{T}$，但它们的边缘分布互不相同，即$P_{S_i}(X)\neq P_{S_j}(X),\forall i\neq j$。

域泛化的目标是利用这K个源域的数据集$\mathcal{S}$训练一个预测模型$f_\theta:\mathcal{X}\to\mathcal{Y}$，使得该模型在完全未知的目标域$\mathcal{D}_T$上能够达到最小的期望风险。值得注意的是，目标域$\mathcal{D}_T$的数据分布$P_T(X)$与任意源域均不相同($P_T(X)\neq P_{S_k}(X)$)，且在训练过程中$\mathcal{D}_T$对模型是完全不可知的。

由于目标域的真实分布$P_T(X,Y)$在训练阶段未知，无法直接对目标域风险进行优化，因此现有方法通常将优化目标表示为所有源域上的经验风险与泛化正则项的加权和，以期学习到在跨域条件下更具稳定性和迁移性的特征表示。其优化目标函数可以表示为：

$$\min_\theta \sum_{k=1}^{K}\mathcal{L}\left(\mathcal{D}_S^k;f_\theta\right)+\lambda\mathcal{R}(\mathcal{D}_S^1,\dots,\mathcal{D}_S^K;f_\theta) \tag{2.1}$$

其中，$\mathcal{L}(\cdot)$表示在特定源域上的监督损失函数，用于保证模型在已知域上的基础分类能力；λ是平衡系数；$\mathcal{R}(\cdot)$表示面向跨域泛化的正则化约束项，用于引导模型学习更加稳定的域不变特征表示。根据$\mathcal{R}(\cdot)$设计思路的不同，域泛化方法旨在寻找一个特征映射$\phi(\cdot)$，使得映射后的特征在所有源域之间满足某种不变性约束。这种约束可以是分布层面的统计对齐，即最小化不同源域特征分布之间的距离，以学习域不变特征表示；也可以是因果层面的机制对齐，即追求在不同环境干预下保持恒定的因果预测机制。通过优化上述目标，模型期望能够剥离掉源域中与标签产生虚假相关的环境特异性信息，仅保留具有跨域鲁棒性的语义内容，从而实现对未知目标

域的有效泛化。

2.3 域泛化关键技术

2.3.1 跨域特征对齐与不变性约束技术

在面临未知复杂环境下的分布偏移问题时，提取跨越不同环境的域不变特征是域泛化技术最核心的理论基石。其基本假设是：尽管不同源域的数据在底层像素空间存在剧烈的光度、几何或气象噪声差异，但它们在高维语义空间中应当共享决定目标类别的本质特征。因此，跨域特征对齐技术致力于在深度神经网络的特征提取阶段，施加特定的约束函数，强制将多个异构源域的数据映射到一个公共的特征子空间中，使得不同域的边缘概率分布或条件概率分布相互重合。实现这一目标的关键技术主要分为显式统计距离度量与隐式对抗博弈对齐两大类。

在显式特征对齐中，MMD 是最为经典且广泛使用的非参数化距离度量技术。MMD 的核心思想是通过寻找一个映射函数，将不同分布的样本投射到一个再生核希尔伯特空间（Reproducing Kernel Hilbert Space, RKHS）中，并计算两个分布在该空间中的均值距离。假设存在两个源域的特征分布P和Q，从中采样的观测集分别为$X^s = \{x_1^s, \ldots, x_n^s\}$和$X^t = \{x_1^t, \ldots, x_m^t\}$，定义映射函数$\phi: \mathcal{X} \to \mathcal{H}$。则$P$和$Q$之间的 MMD 平方距离的经验估计可表示为：

$$\mathrm{MMD}^2(X^s, X^t) = \left\| \frac{1}{n}\sum_{i=1}^{n} \phi\left(x_i^s\right) - \frac{1}{m}\sum_{j=1}^{m} \phi\left(x_j^t\right) \right\|_{\mathcal{H}}^2 \tag{2.2}$$

由于直接计算高维甚至无限维空间$\mathcal{H}$中的映射$\phi(\cdot)$是极其困难的，实际计算中通常引入核函数，利用核函数$k(x, y) = \langle \phi(x), \phi(y) \rangle_{\mathcal{H}}$将内积运算转化为低维空间中的核评估。在域泛化网络的训练过程中，将网络提取的多源域特征间的 MMD 距离作为正则化损失项加入到总目标函数中进行最小化，即可显式地迫使网络学习到平滑且对域偏移鲁棒的表征。除了显式的统计度量，受 GAN 的启发，基于对抗学习的隐式不变性约束技术展现出了更强的特征对齐能力。对抗对齐机制引入了一个极小极大博弈框架，该框架包含三个主要组件：特征提取器$G_f\left(\cdot; \theta_f\right)$、类别预测器$G_y\left(\cdot; \theta_y\right)$以及域判别器$G_d(\cdot; \theta_d)$。特征提取器的目标是提取能够最小化类别预测损失$\mathcal{L}_{\text{cls}}$的特征，同时试图最大化域判别器的分类误差；而域判别器的目标则是尽可能准确地分辨输入特征来源于哪一个具体的源域。这一对抗过程的目标函数可以形式化为：

$$E\left(\theta_f, \theta_y, \theta_d\right) = \sum_{i=1}^{N} \mathcal{L}_{\text{cls}}\left(G_y\left(G_f(x_i)\right), y_i\right) - \lambda \sum_{i=1}^{N} \mathcal{L}_{\text{domain}}\left(G_d\left(G_f(x_i)\right), d_i\right) \tag{2.3}$$

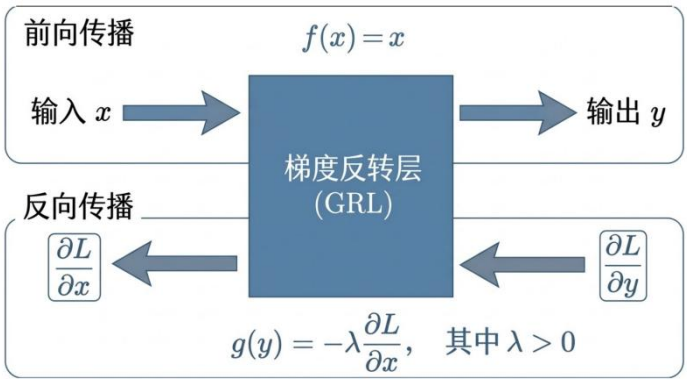


图 2.4　梯度反转层示意图

为了在标准的反向传播算法中实现这种对抗训练，研究人员提出了梯度反转层（Gradient Reversal Layer, GRL）[88]，如图 2.4 所示。GRL 被插入在特征提取器与域判别器之间。在前向传播阶段，GRL 将特征无损地传递给域判别器；而在反向传播阶段，GRL 会将其接收到的梯度乘以一个负常数$-\lambda$后再回传给特征提取器。通过这种机制，网络迫使特征提取器不断擦除特征中的域特异性信息，当域判别器完全无法区分特征的域来源时，网络便隐式地掌握了跨域不变表示。

2.3.2　注意力机制

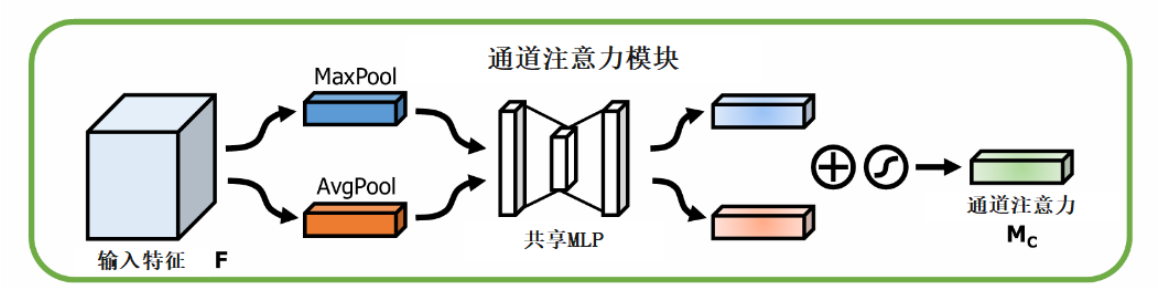
注意力机制（Attention Mechanism）是近年来深度学习中广泛应用的一类特征增强方法，其核心思想是对不同位置、不同通道或不同特征成分赋予差异化权重，使模型能够更加关注与当前任务相关的关键信息，而抑制无关背景、噪声干扰和冗余响应。对于复杂视觉场景而言，输入图像中往往同时包含目标主体、背景纹理、光照变化以及局部遮挡等多种信息，若模型对所有特征进行均匀处理，容易受到非关键因素的影响。引入注意力机制后，网络能够在特征提取过程中主动突出更具判别性的语义成分，从而提升特征表达能力和模型鲁棒性。

对于卷积神经网络提取到的特征图，设其表示为$F \in \mathbb{R}^{C\times H\times W}$，其中，$C$、$H$和$W$分别表示特征图的通道数、高度和宽度。注意力机制本质上可以看作一种对特征进行自适应重标定的过程，即通过学习得到注意力权重，并将其作用于原始特征，从而得到更加突出的特征表示。

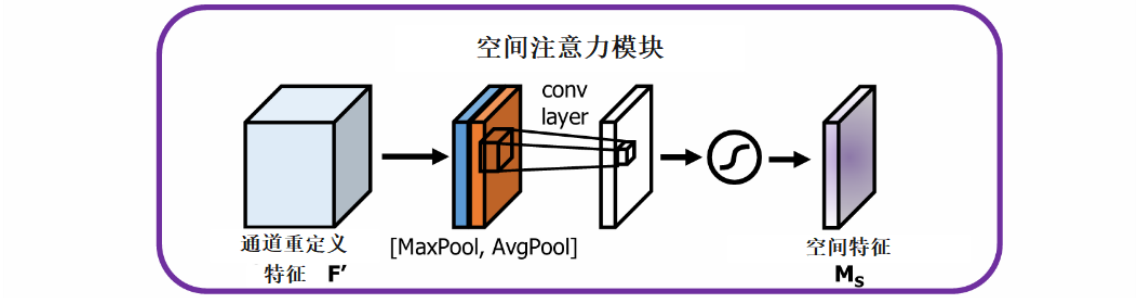
在视觉任务中，注意力机制通常包括空间注意力和通道注意力两种基本形式，如图 2.5 所示。空间注意力主要关注图像中空间位置的重要程度，通过在空间维度上为不同位置分配不同权重，引导模型聚焦于目标主体及关键区域，减弱背景区域和局部干扰的影响。通道注意力则更关注建模不同特征通道对任务的贡献程度，增强更具判别性的语义响应，抑制冗余或低相关通道。无论是空间注意力还是通道注意力，其基本作用都可以统一表示为：

$$F' = A \odot F \tag{2.4}$$

其中，A表示注意力权重，$\odot$表示逐元素乘法，F'为经过注意力调制后的特征。通过这种方式，网络能够在特征提取过程中更加突出关键区域和有效响应，提高特征表达能力与判别能力。



(a)



(b)

图 2.5　通道注意力与空间注意力[89]

在实际应用中，空间注意力和通道注意力往往结合使用，以实现对空间位置和语义通道的联合建模。对于通道注意力而言，通常先利用全局平均池化对空间信息进行压缩，得到每个通道的全局统计描述，即：

$$Z_c = \frac{1}{H \times W} \sum_{i=1}^{H} \sum_{j=1}^{W} F_c(i,j) \tag{2.5}$$

其中，Z_c表示第c个通道的统计特征。基于这一描述，模型可以进一步学习各通道的重要性权重，从而对原始特征图进行重标定。类似地，空间注意力一般通过对通道信息进行聚合后生成二维权重图，以突出图像中的显著区域。两类注意力机制从不同维度对特征进行调制，能够在一定程度上弥补传统卷积网络对关键特征选择能力不足的问题。

对于域泛化任务而言，注意力机制具有重要意义。由于不同域之间在背景风格、纹理统计和成像条件等方面通常存在明显差异，模型在训练过程中容易依赖背景线索或局部表面特征进行判别，从而影响其在未知域中的泛化性能。引入注意力机制后，模型能够更加关注目标主体及稳定的判别信息，减弱背景噪声和域相关干扰对特征表示的影响，为后续进一步开展鲁棒特征建模提供良好的基础。因此，注意力机制已经成为复杂环境视觉感知和跨域识别任务中的重要技术手段。

2.3.3 特征正则化技术

在深度学习模型训练过程中，随着网络容量和表达能力不断提升，模型在源域数据上虽然能够获得较高的拟合精度，但也更容易对训练样本中的局部纹理、背景线索以及偶然共现关系产生过度依赖，从而导致泛化能力下降。尤其是在复杂环境视觉任务和域泛化场景中，不同域之间往往存在显著的外观差异与统计偏移，若模型在训练阶段过于依赖某些局部显著特征或域特定信息，则在面对未知场景时容易出现性能退化。为缓解这一问题，研究者提出了多种特征正则化技术，通过在训练过程中主动扰动特征表达、抑制冗余响应或限制特征共适应现象，引导模型学习更加稳定、更加鲁棒的表示。

特征正则化的基本思想是在模型训练阶段对部分神经元、特征通道或局部响应进行随机抑制，使网络不能仅依赖少量强响应特征完成预测，而必须综合利用更加广泛和稳定的判别信息。其中，最经典的方法是 Dropout。设某一层输入特征表示为h，则 Dropout 可表示为：

$$\tilde{h} = m \odot h \tag{2.6}$$

其中，m为服从伯努利分布的随机掩码向量，$\odot$表示逐元素乘法。训练过程中，部分特征单元会以一定概率被随机置零，从而削弱神经元之间的复杂共适应关系，降低模型对特定局部响应的依赖。通过这种方式，模型在每次迭代中实际上都在不同的子网络上进行学习，因此能够在一定程度上提升整体泛化性能。

随着研究的深入，传统 Dropout 逐单元随机失活的方式逐渐扩展到更加结构化的特征正则化形式。例如，部分方法不再独立地丢弃单个神经元，而是直接对连续区域、整组通道或局部特征块进行随机抑制，以更符合卷积特征在空间和语义上的相关结构。这类方法能够更有效地削弱模型对局部纹理和显著区域的过拟合，促使网络从更广泛的上下文中提取判别信息。此外，还有一些方法通过对特征统计量进行扰动、对中间表示进行混合或对高响应区域进行擦除，进一步提升模型对输入变化和分布偏移的适应能力。

对于视觉识别任务而言，特征正则化技术的重要作用在于抑制模型对局部最强响应的过度依赖。卷积网络在训练过程中往往倾向于优先利用最容易学习的表面特征，例如高频纹理、局部背景或某些显著但不稳定的区域，而这些信息在跨域场景下往往缺乏稳定性。特征正则化通过随机失活或扰动机制打破这种单一路径依赖，迫使模型更多关注主体轮廓、整体结构以及更具迁移性的语义特征，从而改善模型在未知环境中的鲁棒性和泛化能力。

对于本文所研究的域泛化问题，特征正则化同样具有重要意义。由于不同域之间在背景风格、成像条件和纹理统计等方面存在明显差异，模型在训练阶段若过于依赖某些域特定特征，便容易在测试阶段受到分布偏移的影响。引入特征正则化技

术后，模型能够在训练过程中主动削弱对局部强相关特征的依赖，降低表面统计规律对分类决策的主导作用，为后续进一步开展鲁棒特征提取与跨域稳定表示建模提供良好的基础。因此，特征正则化技术已成为提升复杂环境视觉模型泛化性能的重要手段之一。

2.3.4 频域分析与数据增强技术

在域泛化任务中，由于源域数据的多样性往往受限于实际采集条件，如何通过数据增强技术显式地扩充训练集分布、模拟未知的目标域环境，成为了提升模型泛化能力的关键途径。传统的空间域增强方法虽然能在一定程度上增加数据丰富度，但往往难以解耦图像中的语义内容与环境风格，容易在增强过程中破坏目标的物理几何结构。为了实现更加本质的风格与内容分离，研究者开始将目光转向频域分析。频域分析的核心优势在于，它能够将复杂的图像信号分解为不同频率的正弦和余弦波的叠加，从而在另一个维度上揭示图像的底层生成机制。

在离散图像处理中，最常用的频域转换工具是二维离散傅里叶变换。假设存在一幅尺寸为$H \times W$的单通道空间域图像$f(x,y)$,其中$x \in [0, H-1]$且$y \in [0, W-1]$,其对应的二维离散傅里叶变换$\mathcal{F}(u,v)$可表示为：

$$\mathcal{F}(u,v) = \sum_{x=0}^{H-1} \sum_{y=0}^{W-1} f\,(x,y) e^{-j2\pi\left(\frac{ux}{H}+\frac{vy}{W}\right)} \tag{2.7}$$

其中，u和v分别表示空间频率的坐标，j为虚数单位。经过傅里叶变换后，原始图像被映射到复数频域空间。该复数矩阵可以进一步极坐标化，分解为幅度谱$\mathrm{A}(u,v)$和相位谱$\mathrm{P}(u,v)$两个独立分量：

$$\mathrm{A}(u,v) = \sqrt{\mathrm{R}\big(\mathcal{F}(u,v)\big)^2 + \mathrm{S}\big(\mathcal{F}(u,v)\big)^2} \tag{2.8}$$

$$\mathrm{P}(u,v) = \arctan\left[\frac{\mathrm{S}\big(\mathcal{F}(u,v)\big)}{\mathrm{R}\big(\mathcal{F}(u,v)\big)}\right] \tag{2.9}$$

其中，$\mathrm{R}(\cdot)$和$\mathrm{S}(\cdot)$分别表示复数的实部和虚部。相位谱P主要记录了不同频率正弦波的相对位移信息，它决定了图像中边缘、轮廓和空间位置等高频突变区域的分布。因此，相位谱编码了目标的高级语义，这正是域泛化模型需要提取的域不变特征。相反，幅度谱反映了不同频率成分在图像中的能量分布，主要控制图像的宏观光照、色彩分布、纹理质感以及平滑的背景区域。因此，幅度谱高度耦合了图像的统计特性和环境风格，这对应着需要被克服的域特定特征。基于上述频域解耦特性，频域数据增强技术应运而生。其核心操作是在频域空间内，保持源图像的相位谱完全不变，同时对其幅度谱进行扰动、插值或与其他随机源域图像的幅度谱进行交换。最后，通过二维逆离散傅里叶变换将混合后的频域信号重构回空间域。

2.4 知识蒸馏与模型轻量化技术

随着深度学习模型在无人系统、边缘计算以及实时感知场景中的广泛应用，高性能模型通常伴随大量参数和高计算开销，这在资源受限的环境中严重制约了实时部署和能耗控制。因此，如何在保持模型预测性能的前提下有效降低模型复杂度成为轻量化研究的核心问题。模型轻量化的实现策略主要包括三个方面。第一，轻量化网络结构设计，通过引入小卷积核、深度可分离卷积、瓶颈模块以及注意力引导的通道选择等方法，在保持网络表达能力的前提下大幅降低参数量和计算量。第二，参数压缩与数值量化，通过剪枝和权重量化减少冗余参数及计算精度，从而降低存储占用和推理时间。第三，知识蒸馏，通过教师—学生架构将大模型中学到的判别知识迁移至轻量化学生模型，使其在较低参数量下仍能保持较高预测性能，同时提高跨域泛化能力。

知识蒸馏技术通常由教师模型T和学生模型S组成，教师模型为高容量、高性能网络，学生模型为轻量化网络。学生模型的训练目标不仅包括传统任务损失$\mathcal{L}_{task}$，还需最小化与教师模型输出或中间表示的差异，实现知识传递。设教师模型输出为p^T,学生模型输出为p^S,常见的蒸馏损失可定义为：

$$\mathcal{L}_{KD} = \frac{1}{N}\sum_{i=1}^{N} D\left(p_i^S, p_i^T\right) \tag{2.10}$$

其中N表示样本数量，$D(\cdot)$为衡量学生预测与教师预测差异的度量函数，例如 KL 散度或 L2 距离。学生模型的整体训练损失则可以表示为：

$$\mathcal{L} = \mathcal{L}_{task} + \lambda\mathcal{L}_{KD} \tag{2.11}$$

其中λ为平衡系数，用于调节任务监督与蒸馏监督的重要性。通过这种联合优化，学生模型不仅能够拟合原始任务目标，还能吸收教师模型的高层判别知识，实现轻量化与性能的双重优化。

此外，知识蒸馏方法可以分为多种范式，包括响应蒸馏、特征蒸馏和关系蒸馏。响应蒸馏主要对齐教师和学生的输出概率分布；特征蒸馏关注中间层特征表示的对齐；关系蒸馏则通过样本间或通道间关系来传递知识。这些蒸馏策略可单独或组合使用，以适应不同轻量化场景和任务需求。对于带有复杂任务头的模型，还可以采用预测蒸馏方式，即将学生中间特征输入教师后续层生成跨头预测，以缓解直接对齐最终输出可能带来的监督冲突，从而在轻量化条件下获得更稳定的性能提升。

2.5 本章小结

本章围绕本文后续研究所需的理论基础与关键技术进行了系统梳理。首先，介绍了深度残差网络的基本结构与优势，分析了其通过残差连接缓解深层网络退化、提升特征提取能力的机制，说明了 ResNet 作为主干网络在复杂视觉任务中的适用

性。其次，从迁移学习的基本概念出发，进一步阐述了域泛化问题的研究内涵、形式化定义及其与域适应的区别，明确了本文面向目标域不可访问条件下跨域稳健感知的研究边界。

在此基础上，本章重点分析了域泛化相关的几类关键技术，包括跨域特征对齐与不变性约束、注意力机制、特征正则化以及频域分析与数据增强方法。其中，跨域特征对齐技术为学习域不变表示提供了基本思路；注意力机制能够增强模型对关键区域和有效通道的关注；特征正则化技术有助于抑制模型对局部表面特征和域特定信息的过度依赖；频域分析与数据增强技术则为扩展训练分布、提升模型对未知环境变化的适应能力提供了有效手段。最后，本章还对知识蒸馏与模型轻量化技术进行了介绍，说明了其在保持模型性能的同时降低计算复杂度、满足边缘部署需求方面的重要作用。

综上，本章从主干网络、问题定义到关键方法构成了本文研究的理论基础。其中，注意力机制与特征正则化为第三章开展面向域敏感特征抑制与推理一致性约束的研究提供了思路支撑，频域分析与特征建模相关内容为第四章开展多阶段分层表示建模方法奠定了方法基础，而知识蒸馏与轻量化技术则为第五章面向边缘部署的轻量化迁移研究提供了理论依据。

第三章　基于多尺度注意力与推理一致性的域泛化方法

3.1　引言

在训练条件受限的域泛化场景中，目标域数据无法提前获得，模型只能从有限源域中学习可迁移特征，因此其关键难点在于如何削弱源域特有信息对判别过程的干扰。如何在多源异构条件下提取更加稳定的域不变特征，是实现鲁棒跨域识别的关键问题。传统的深度卷积神经网络在封闭式的理想数据集中表现优异，但当测试环境（目标域）的分布与训练环境（源域）不一致时，模型往往会退化并过度拟合源域特征，导致实战条件下的识别性能发生灾难性下降。因此，如何在这种多源异构且存在明显分布差异的恶劣环境中，提取出鲁棒的域不变目标特征，是实现无人系统全天候可靠感知的核心挑战。

现有的域泛化方法虽然在一定程度上缓解了跨域分布偏移问题，但仍存在两方面显著的局限性。首先，在特征提取阶段，多数网络结构对所有通道的特征图一视同仁，忽略了不同通道对域偏移的敏感度差异。事实上，深层特征中的某些特定通道往往包含与环境风格、背景统计或域变化相关的非稳健信息，如果不对其加以显式的甄别与过滤，将严重干扰模型对目标核心物理结构的聚焦。其次，在特征对齐阶段，现有的基于原型的方法通常局限于单一的训练批次内进行约束，缺乏在整个训练周期内的时序连贯性，导致模型在推理阶段面对高度动态且未知的对抗环境时，表现出极大的不稳定性。

针对上述痛点，本章提出了一种基于多尺度注意力与推理一致性的域泛化方法（Cross-domain Learning with Enhanced Attention and Reasoning-consistency, CLEAR）。该方法从域敏感特征抑制和跨域判别稳定性约束两个方面入手：一方面，通过跨空间多尺度注意力机制辅助域鉴别器（Cross-space Multi-scale Attention Domain Discriminator, CMADD）识别对域变化敏感的特征通道，并在训练过程中对其进行抑制，从而减少环境风格、背景纹理等域相关因素对特征表示的干扰；另一方面，引入基于动量的推理一致性损失（Momentum-based Inference Consistency loss, MICL），通过维护跨批次的类别原型表示，使不同源域中同类样本的判别依据更加稳定。通过上述设计，CLEAR 能够在不依赖目标域数据的条件下增强模型对未知域分布变化的适应能力。

3.2　方法设计

3.2.1　总体网络结构

为了在非结构化的复杂战场中提取域不变目标特征，本章提出了一种基于多

尺度注意力与推理一致性的域泛化方法（CLEAR），如图 3.1 所示。该方法首先在空间维度上锁定目标区域，随后在通道维度上剔除对域标签高度敏感的环境风格特征，最后在时序训练过程中保持类条件特征的一致性演进。CLEAR 的总体网络结构主要由四个关键部分组成：主干特征提取网络（Backbone）、CMADD、MICL 以及分类器。

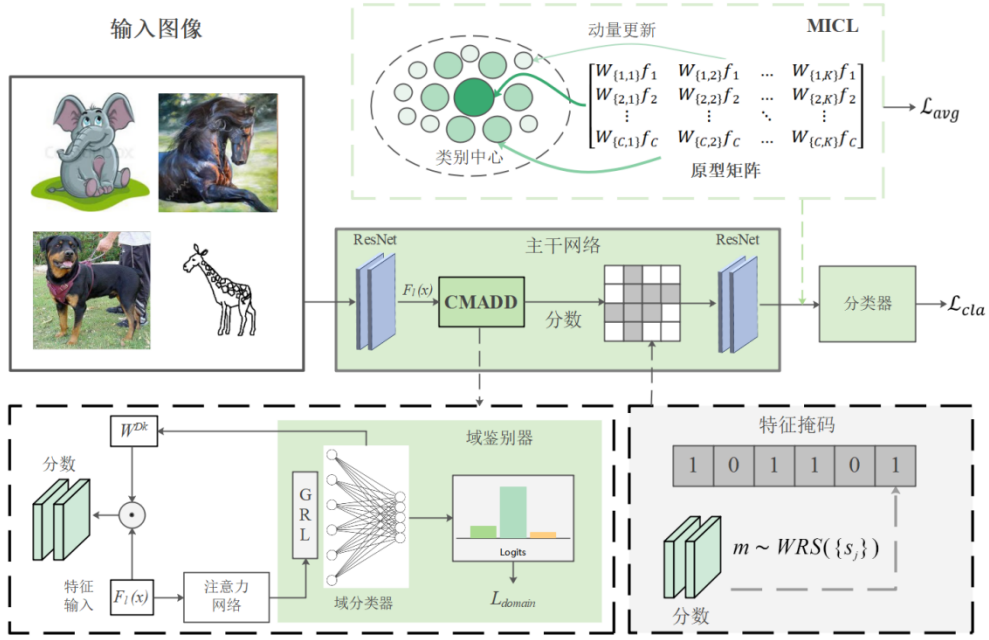


图 3.1　CLEAR 整体架构

在网络的前向传播过程中，给定来自多个不同源域的训练样本，首先将其输入到主干特征提取网络（ResNet-18 或 ResNet-50）中。主干网络通过多层卷积与池化操作，将原始的像素级图像映射为高维的深度特征图。然而，此时的特征图中既包含了目标的物理结构等域不变特征，也充斥着大量与特定采集环境相关的域特定特征。

为了提纯这些特征，高维特征图随后被送入 CMADD 模块。该模块首先并行地应用多个具有不同感受野的注意力分支，聚合生成一个融合的多尺度空间注意力图。这一注意力图能够敏锐地捕捉到图像中与任务高度相关的显著性区域，并以此作为指导先验。接着，模块计算每个特征通道在这些显著性区域内的激活强度，评估其对域标签的敏感度。对于那些在不同域之间表现出剧烈波动、且高度依赖环境背景的通道，网络将其判定为域特定噪声通道，并生成一个二值化的通道掩码将其阻断。经过这一阶段的过滤，网络输出了被提纯的鲁棒特征图。

单纯的通道过滤能够在单次前向传播中削弱域敏感噪声，但在多源域分布差异较大的情况下，模型对各类别判别原型的学习仍可能受到批次采样波动的影响。为此，MICL 模块引入动量更新机制，为每个类别维护跨批次的历史原型表示。该

原型由历史样本的推理证据平滑更新得到，能够较稳定地刻画同一类别在训练过程中的判别依据。通过约束当前样本的推理表示与对应类别的动量原型保持一致，MICL 能够拉近不同源域中同类样本的表示距离，减弱单个批次样本分布差异带来的优化抖动，从而提升模型跨域判别过程的稳定性。

在训练阶段，经过 CMADD 模块过滤后的特征被送入分类器生成类别预测，模型通过联合优化域分类损失、类别分类损失和 MICL 一致性损失进行端到端更新。其中，域分类损失用于辅助识别域敏感通道，类别分类损失保证模型的基本判别能力，MICL 一致性损失进一步约束跨域推理过程的稳定性。在推理阶段，MICL 相关的动量更新分支不再参与计算，仅保留主干网络、CMADD 模块和分类器完成前向传播。因此，该设计不会额外增加推理开销，同时能够保留训练阶段形成的域敏感通道抑制能力和跨域鲁棒表示，更适合部署在算力受限的无人系统边缘平台上。

3.2.2 基于跨空间多尺度信息聚合注意力机制的域鉴别器

在多源域的域泛化场景中，源域上训练的模型通常包含许多特定于源域的非鲁棒特征，当域发生变化时，这些非鲁棒的敏感特征会在未训练的目标域上产生负面影响，从而导致条件分布发生变化。传统的域泛化方法并未明确指导模型去除中间网络层中的特定域敏感特征，可能导致模型学习过多与域相关的信息。

因此，本方法的目标在于显式地去除域敏感的特征，同时增强域不变特征的提取能力。为此，本章提出了一种基于跨空间多尺度信息聚合注意力机制的域鉴别器，来识别并删除域敏感特征通道。

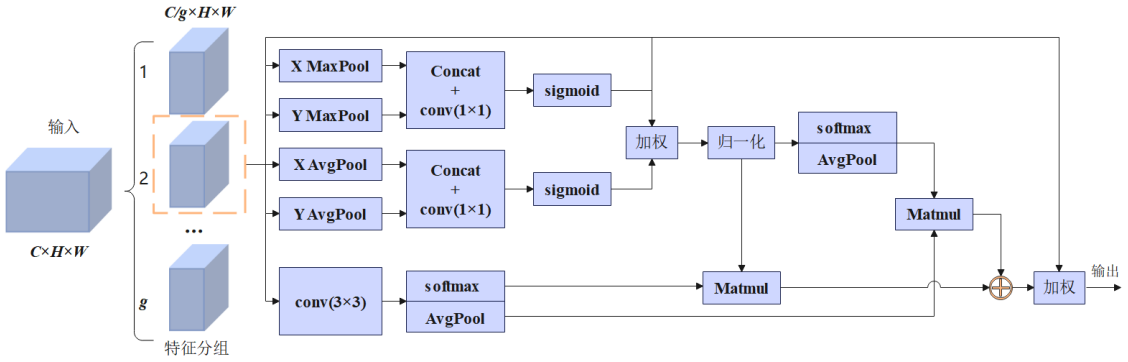


图 3.2 跨空间多尺度信息聚合注意力示意图

在本任务中，需要识别并删除每个域中最具特异性的特征。注意力机制有助于完成这一任务，因为不同通道特征对最终分类的贡献程度不同，而每个通道特征在深度特征图中对应于输入图像的特定信息，这些信息往往包含了域敏感特征。

基于此，本方法提出了一种跨空间多尺度信息聚合的注意力机制，具体结构如图 3.2 所示，与坐标注意力（Coordinate Attention, CA）[90]相比，本方法将特征通

道分组为多个子特征，使得空间语义信息在每个特征组内分布均匀，减少计算开销。同时利用多尺度卷积配合全局池化操作，通过1×1和3×3两个不同大小的卷积核，并采用1D全局平均池化和全局最大池化，有效捕捉局部和全局的空间特征，建立不同方向上的短程和长程依赖。最后将不同尺度的注意力信息进行聚合，调整不同特征通道的重要性，将精确的空间结构信息保留在特征通道中，这种跨空间的信息聚合能力使得模型可以在域泛化任务中更有效地捕捉域特定特征。

为了在训练过程中使模型准确地去除特定于域的特征，本方法在特征提取网络的多个中间层引入了域鉴别器来定位域特定特征。给定一个来自源域D_n的输入x_i^n及其标签y_i^n，i代表源域中第i个数据。本方法首先提取由第l个中间层产生的特征$F_l(x_i^n) \in \mathbb{R}^{C\times H\times W}$，其中$C$是通道数，$H$和$W$分别表示高度和宽度维度。$F_l(x_i^n)$后接域鉴别器$F_d^l$，以预测域标签并计算区分损失，其中$F_d$表示域鉴别器，$F_d^l$表示第$l$个中间层的域鉴别器。同时，本方法在域鉴别器之前使用GRL[88]来进行对抗训练，使得特征提取器提取出更加通用的特征。

CMADD与传统的域泛化方法的不同之处在于，本方法不断过滤掉对特定域识别贡献大的特征通道，以防止模型保留太多与域相关的特征。通过在训练过程中去除域敏感特征，本方法减少了由域偏移引起的特征通道不稳定性，并促进了域不变特征的学习。为了确定哪些特征包含特定于域的信息，本方法使用中间层中的域鉴别器的预测结果作为特征通道重要性的衡量指标。具体来说，本方法假设对域预测贡献最大的通道可能包含较多的特定于域的信息。首先进行域标签预测：

$$y_k = W^{D_n} \cdot GAP\left(F_l(x_i^n)\right) \tag{3.1}$$

其中，x_i^n为输入，$F_l(x_i^n)$为特征，W^{D_n}为域分类器权重，GAP代表全局平均池化。同时进行域预测损失的计算：

$$\mathcal{L}_{domain} = CrossEntropy(y_k, y_n) \tag{3.2}$$

其中，$CrossEntropy$为交叉熵损失，y_k和y_n分别为预测标签和域标签。之后通过计算正确的域预测的加权激活来量化第j个通道和域特定信息之间的相关性：

$$s_j = W_j^{D_n} \odot GAP(F_l(x_i^n))_j \tag{3.3}$$

其中，$W_j^{D_n}$为域鉴别器对应于域D_n的全连接层权重。权重值越高，相应的特征通道对于域预测的贡献越大。

在对相应的特征通道进行识别后，为了显式地减少特征图中的特定于域的信息，训练过程中将选择并删除对域识别贡献最大的通道。具体来说，首先计算去除特征通道的数目：

$$M = C \times P_{drop} \tag{3.4}$$

其中，P_{drop}为特征通道去除率。随后，基于每个特征通道的得分生成二进制特征掩码m。根据掩码的值是否为1决定相应的通道是否被去除。其中，$m_j = 0$表示第

j个通道被抑制，$m_j = 1$表示第j个通道被保留。域敏感性得分越高的通道，被采样为丢弃通道的概率越大。为了降低计算成本，本方法采用加权随机采样（Weighted Random Sampling, WRS）算法[91]来生成二进制掩码m。具体地，对于分数为s_j的第j个通道，本方法首先生成随机数$r_j \sim U(0,1)$并计算关键值$k_j = r_j^{1/s_j}$。然后，本方法选择具有最大键值的M个值，并将掩码m的相应m_j设置为 0：

$$m_j = \begin{cases} 0, & \text{if } j \in \text{TOP}(\{k_1, k_2, \dots, k_C\}, M) \\ 1, & \text{否则} \end{cases} \tag{3.5}$$

其中$\text{TOP}(\{k_1, k_2, \dots, k_C\}, M)$表示具有最大关键值的$M$个值。最后，将特征掩码作用于原有的特征得到新特征$f$：

$$f = m \cdot F_l(x_i^n) \tag{3.6}$$

3.2.3 基于动量更新的推理一致性损失

在先前的步骤中，本方法通过特征掩码得到了新特征$f \in \mathbb{R}^C$。如果只关注特征，而不充分考虑与特征相对应的分类器权重，会导致最后的分类结果不准确。例如，一个较为重要的特征可能对应一个较小的分类权重，这种对特征重要性的有偏估计不是我们希望看到的。

与特征相比，logits 涉及到对特征加权，一定程度地考虑了分类权重。然而，logits 只提供了一个粗略的分类决策值，仅仅依靠 logits 可能无法控制决策过程，导致无法有效获得可靠的结果。因此，为了得到泛化性更强的模型，需要同时考虑特征和分类权重。假设有k个类别，logits 可以表示为$o = W^T f$，其中W为分类器权重。为了更深入地研究特征和分类器权重对最终分类的影响，可以表示由特征和分类器权重之间的元素乘积之和生成的第k类 logit 值o_k如下：

$$o_k = \sum_{j=1}^{C} W_{\{j,k\}} f_j \tag{3.7}$$

在上面的等式中，第k类的 logit 值由各特征维度的贡献项$W_{\{j,k\}} f_j$累加得到，每个贡献项可视为该特征维度对第k类判别结果的支持证据。直观地，$W_{\{j,k\}} f_j$提供了一条证据来支持具体的决定。因此，可以收集所有$W_{\{j,k\}} f_j$作为矩阵$R \in \mathbb{R}^{C \times K}$来表示对样本进行分类的准则，本方法称之为原型矩阵，其形式定义如下：

$$R = \begin{bmatrix} W_{\{1,1\}} f_1 & W_{\{1,2\}} f_1 & \cdots & W_{\{1,K\}} f_1 \\ W_{\{2,1\}} f_2 & W_{\{2,2\}} f_2 & \cdots & W_{\{2,K\}} f_2 \\ \vdots & \vdots & \ddots & \vdots \\ W_{\{C,1\}} f_C & W_{\{C,2\}} f_C & \cdots & W_{\{C,K\}} f_C \end{bmatrix} \tag{3.8}$$

本方法的主要目的是让模型可以在不同的环境下保持可靠的输出，原型矩阵

克服了基于特征和基于 logits 分析的局限性，从一个更细粒度的角度来表示分类决策过程，即确保来自同一类别的样本的原型矩阵与其对应类别的平均值一致。这种方法意味着，对象进行分类的决策应该基于相同的推理，而不考虑样本或域的变化，因为决策的因果因素通常是跨样本和跨域持续存在的稳定模式。形式上，本方法施加推理一致性损失项，以强制样本的原型矩阵接近其对应的平均值。表示为$\mathcal{L}_{avg}$，该正则化术语可写为：

$$\mathcal{L}_{avg} = \frac{1}{N_b}\sum_{k}\sum_{\{n|y_n=k\}} \| R_n - \bar{R}_k \|^2 \tag{3.9}$$

其中，N_b是一个批次中的样本数量；R_n表示第n个样本的原型矩阵。$\bar{R}_k$表示对应于第k类的原型矩阵的平均矩阵。然而，计算$\bar{R}_k$直接涉及对所有样本求平均，这会占用大量的计算时间。因此，本方法在每个迭代步骤中以动量方式在线更新$\bar{R}_k$：

$$\bar{R}_k^t = (1-m)\times \bar{R}_k^{t-1} + m \times \frac{1}{|y_n=k|}\sum_{\{n|y_n=k\}} R_n \tag{3.10}$$

其中，t表示训练迭代步，k表示类别索引，m是动量值。总的损失函数可以表示为：

$$\mathcal{L}_{all} = \mathcal{L}_{domain} + \mathcal{L}_{cla} + \lambda\mathcal{L}_{avg} \tag{3.11}$$

其中，$\mathcal{L}_{cla} = CE(\hat{y}_i, y_i)$，$\hat{y}_i$为分类器预测结果，$y_i$为真实类别标签。

3.3 实验结果与分析

3.3.1 数据集与实验设置

本研究基于 PACS、OfficeHome 和 VLCS 3 个基准数据集对方法进行评估：

（1）PACS[92]由来自 4 个不同域的图像组成，Photo、Art、Cartoon 和 Sketch，包括 7 个不同的类别和 9 991 张图像，本研究采用 PACS 提供的官方划分进行训练和验证。

（2）OfficeHome[93]由 4 个不同域组成，艺术（Art）、剪贴画（Clipart）、产品（Product）和现实世界（RealWorld），包含 65 个类别和约 15500 张图像。参考 JiGen[94]的设置，本研究将每个源域随机划分 90%用于训练，10%用于验证。

（3）VLCS[95]由 5 个类别的 10729 张图像构成，包含 4 个不同域，VOC 2007（Pascal）、LabelMe、Caltech 和 Sun。参考 JiGen 的设置，本研究以 7∶3 的比例将数据集划分为训练集和验证集。

上述三个公开数据集与本文所关注的受限场景之间具有一定的对应关系。PACS 中不同域之间存在明显的绘画风格、纹理表现和结构抽象程度差异，可用于模拟复杂环境下成像风格变化对模型泛化能力的影响；OfficeHome 包含更多类别和更复杂的背景上下文，可用于考察模型在多类别、复杂背景条件下的跨域稳定性；VLCS 来源于不同视觉数据集，能够反映跨采集条件和跨数据来源带来的分布差

异。本文采用留一域评估策略，即训练阶段完全不使用目标域数据，仅利用有限源域数据进行模型训练，这与真实无人系统部署前难以获得目标环境数据的训练受限条件相一致。因此，本文使用上述公开基准数据集，并非将其等同于真实战场或无人系统数据，而是将其作为验证未知域泛化能力的标准化实验载体。

本章分别使用 ImageNet 预训练的 ResNet-18 和 ResNet-50 作为三种数据集的主干网络。学习率设置为 0.002，Batch size 为 64。对于 CMADD，特征通道去除率P_{drop}设置为 0.33，域鉴别器之前的梯度反转层的权重设置为 0.25。对于 MICL，将动量值m设置为 0.1，损失权重λ设置为 0.1。

本章采用分类准确率（Accuracy, %）作为主要评价指标，模型仅利用源域训练集进行训练，超参数基于验证集进行选择，并在所有源域验证集上选取性能最优的模型，最终报告目标域上的 Top-1 准确率。为保证实验结果的统计可靠性，所有实验均采用不同随机种子重复 3 次，最终报告的结果为 3 次独立实验的平均值。除本文方法外，对比方法结果均引用自原论文或公开基准结果，并未直接采用 DomainBed 统一代码框架对所有方法进行重新复现。除特殊说明外，表中加粗结果表示对应列中的最优结果。

本章将不引入额外域泛化模块、仅采用经验风险最小化（Empirical Risk Minimization, ERM）训练的主干网络记为基线，即仅利用训练样本及其类别标签最小化分类损失的标准监督训练方式。所有实验均采用单张 RTX 4070 显卡在 Windows 11、PyTorch2.2.0、CUDA11.8 的环境下完成。

3.3.2 方法对比分析

3.3.2.1 对比基线模型

本章分别以 ResNet-18 和 ResNet-50 作为主干网络，在 PACS 数据集上与之前的域泛化工作进行了比较：

• InfoDrop（Informative Dropout）[96]：从形状偏置视角出发，通过对低信息量区域施加更高概率的丢弃，减少模型对局部纹理的依赖，增强其对分布偏移的鲁棒性。

• RSC[3]：一种特征正则化方法，核心思想是在训练过程中根据特征梯度识别对当前预测贡献较大的表征分量，并对其进行主动抑制，迫使模型转而挖掘其余仍与类别相关的辅助特征。

• DMG（Domain-specific Masks for Generalization）[97]：通过学习域特定掩码，在域不变特征与域特有特征之间建立平衡，使模型在保留共享信息的同时适当利用与测试样本相近源域的特征。

• MMLD（Mixture of Multiple Latent Domains）[19]：面向未知域标签场景，通

过对样本风格特征进行聚类划分潜在域，并在伪域基础上学习共享的域不变表示，从而实现无显式域标签的域泛化。

• FACT[6]：从傅里叶视角出发，利用幅度谱混合进行数据增强，并结合双教师一致性约束，引导模型更多关注对域偏移不敏感的相位语义信息。

• StableNet[10]：从稳定学习角度出发，通过学习样本权重削弱特征间的伪相关依赖，引导模型更关注与类别相关的稳定判别因素。

• MixStyle[7]：在网络浅层随机混合不同样本的实例级特征统计量，以隐式合成新的风格域，从而扩大训练分布的多样性并提高模型泛化能力。

• EFDM[30]：通过精确匹配特征经验累积分布函数来实现特征分布混合，在保留语义的同时生成更丰富的风格扰动特征，用于增强模型的域泛化能力。

• LRDG（Learning and Removing Domain-specific features for Generalization）[98]：显式学习并去除输入中的域特定特征，借助编码器—解码器将样本映射到去除域相关因素的新空间，再利用域不变分类器完成识别。

• CDG（Cross-Domain Gated Learning for Domain Generalization）[99]：通过跨域门控机制自适应抑制与域相关的激活响应，以蒸馏更具对象本质特征的域不变表示，减少模型对域特定细节的过拟合。

•ALOFT（Dynamic Low-Frequency Spectrum Transform）[100]：一种轻量化 MLP-like 域泛化框架，通过动态低频谱变换扰动局部纹理信息、保留全局结构信息，从而增强模型对未知域的鲁棒性。

• Fishr[9]：通过匹配不同训练域之间的梯度方差统计量，在梯度空间中施加不变性约束，使模型在不同域上的局部损失景观更加一致。

• SagNet（Style-Agnostic Networks）[101]：提出风格偏置导致域移位的观点，分别构建内容分支和风格分支，并通过风格随机化和对抗学习降低模型对纹理风格的依赖。

• SWAD（Stochastic Weight Averaging Densely）[102]：通过密集随机权重平均搜索更平坦的损失极小值，以减弱模型对源域的过拟合，从而提升在未知目标域上的泛化性能。

• CCFP（Cross Contrasting Feature Perturbation）[103]：一种在线单阶段特征扰动方法，通过在隐空间中构造可学习的特征扰动来模拟潜在域偏移，同时引入语义一致性约束以保持扰动特征的判别语义。

• DMDA（Discriminative Microscopic Distribution Alignment）[104]：兼顾判别性与泛化性，通过选择性通道剪枝去除不稳定因素，并采用类内微观分布对齐提升特征的泛化性与区分性。

•SWAD-NU（Stochastic Weight Averaging Densely Nuclear norm regularization）

[105]：在 SWAD 框架基础上结合核范数正则化，其中 SWAD 通过随机权重密集平均寻找更平坦的极小值，NU 则进一步约束特征矩阵的核范数，以减少环境相关信息对表示学习的干扰。

•ERM++[57]：在传统经验风险最小化基础上改进得到的强基线方法，通过更充分地优化训练数据利用、初始化和正则化策略，缓解过拟合与灾难性遗忘问题，从而显著提升域泛化性能。

3.3.2.2 PACS 数据集上对比实验结果

表 3.1 和表 3.2 分别给出了不同方法以 ResNet-18 和 ResNet-50 为主干网络在 PACS 数据集上的实验结果。总体来看，本章提出的 CLEAR 方法在两种主干网络设置下均取得了最高的平均准确率，说明所提方法在不同网络容量条件下均具有较好的稳定性和泛化能力。

表 3.1 以 ResNet-18 为主干网络在 PACS 中对比实验结果

方法	Art	Cartoon	Photo	Sketch	平均
InfoDrop[96]	80.27	76.54	96.11	76.38	82.23
RSC[3]	83.43	80.31	95.99	80.85	85.15
DMG[97]	80.38	76.90	93.35	75.21	81.46
FACT[6]	**85.37**	78.38	95.15	79.15	84.51
StableNet[10]	81.74	79.91	96.53	80.50	84.69
MixStyle[7]	84.10	78.80	96.10	75.90	83.70
EFDM[30]	83.90	79.40	**96.80**	75.00	83.90
LRDG[98]	81.88	80.20	95.21	**84.65**	85.48
CDG[99]	83.50	80.10	95.60	83.80	85.80
ALOFT[100]	84.81	79.05	96.11	80.55	85.13
CLEAR	83.50±0.35	**81.06**±0.50	96.13±0.16	83.10±0.78	**85.95**

表 3.2 以 ResNet-50 为主干网络在 PACS 中对比实验结果

方法	Art	Cartoon	Photo	Sketch	平均
FACT[6]	89.63	81.77	96.75	84.46	88.15
RSC[3]	87.89	82.16	97.92	83.85	87.83
EFDM[30]	**90.60**	82.50	**98.10**	76.40	86.90
Fishr[9]	88.40	78.70	97.00	77.80	85.50
CDG[99]	88.90	83.50	97.60	84.90	88.70
ALOFT[100]	89.26	83.11	97.96	84.04	88.59
CCFP[103]	87.50	81.30	96.40	81.40	86.60
SWAD-NU[105]	89.80	82.80	97.70	83.7	88.50
DMDA[104]	87.10	85.20	96.70	83.50	88.10
ERM++[57]	87.23	**85.41**	96.44	83.79	88.22
CLEAR	88.31±0.45	83.94±0.52	97.85±0.20	**85.55**±0.68	**88.91**

从不同目标域上的结果来看，CLEAR 在 ResNet-18 设置下在 Cartoon 域上取得了 81.06%的最高准确率，平均性能也优于其余对比方法；在 Sketch 域上虽然略

低于 LRDG 的 84.65%，但仍达到 83.10%，保持了较强竞争力。对于 Art 和 Photo 两个域，CLEAR 并非单项最优，其中 Art 域最佳结果由 FACT 取得，Photo 域最佳结果由 EFDM 取得，这说明不同方法在不同域偏移模式下各有优势。然而，从平均结果看，CLEAR 在四个目标域上表现更加均衡，没有出现某一域显著拉低整体性能的现象，这也从侧面反映出本章方法在跨域稳定性方面的优势。

在 ResNet-50 设置下，CLEAR 进一步表现出更好的综合性能。虽然 Art 域和 Cartoon 域的最优结果分别由 EFDM 和 ERM++取得，但 CLEAR 在 Photo 域达到 97.85%，在 Sketch 域达到 85.55%，其中 Sketch 域为所有对比方法中的最高结果。尤其值得注意的是，Sketch 域通常具有更强的风格抽象性和更明显的结构失真，对模型的跨域鲁棒性要求更高，而 CLEAR 在该域上的优势说明，本章方法在应对显著外观变化和语义表达简化时，能够更有效地保留与类别相关的稳定判别信息。与此同时，CLEAR 在其余目标域上的结果也始终保持在较高水平，从而使整体平均准确率达到 88.91%，优于所有对比方法。

从方法机制角度看，不同对比方法的性能差异与其处理域偏移的侧重点密切相关。RSC、InfoDrop 等特征正则化方法主要通过抑制高响应区域或高梯度特征，缓解模型对局部显著线索的依赖，但这类方法通常不显式区分域敏感通道与稳定判别通道，因此在风格差异较大的目标域上仍可能保留部分域相关干扰。FACT、MixStyle 和 EFDM 等数据或特征增强方法能够扩展源域风格分布，提高模型对外观变化的适应性，但其主要作用集中在样本或统计扰动层面，对深层特征中的域敏感响应和分类推理过程约束不足。

CLEAR 性能提升的原因主要体现在两个方面。一方面，CMADD 模块通过跨空间多尺度注意力与域鉴别器协同建模，能够更有效地识别并抑制深层特征中对域变化敏感的冗余通道，减少模型对背景纹理、成像风格和局部噪声的依赖；另一方面，MICL 通过引入基于动量更新的推理一致性约束，增强了不同源域下同类样本判别依据的一致性，使模型在训练过程中能够逐步形成更加稳定的分类原型。因此，相较于仅侧重风格增强的方法、仅依赖单层特征抑制的方法或主要强调统计对齐的方法，CLEAR 在域敏感特征抑制和跨域判别稳定性维护两个方面形成了互补优势，从而获得了更好的整体泛化效果。

3.3.2.3 OfficeHome 数据集上对比实验结果

OfficeHome 数据集包含 4 个域和 65 个类别，类别更多、分布更复杂，因此更能反映模型在多类别跨域场景下的泛化能力。表 3.3 和表 3.4 分别给出了不同方法以 ResNet-18 和 ResNet-50 为主干网络在 OfficeHome 数据集上的实验结果。总体来看，本章提出的 CLEAR 方法在两种主干网络设置下均取得了较优的平均准确率，表现出良好的跨域稳定性。

在 ResNet-18 主干网络下，CLEAR 取得了 66.18%的平均准确率，高于 CDG 的 66.00%、LRDG 的 65.75%和 MixStyle 的 65.50%。从各目标域结果来看，CLEAR 在 Clipart 域和 RealWorld 域上分别取得了 55.21%和 76.40%的最高准确率，说明本章方法能够较好地抑制风格差异和环境变化对特征表示的干扰，从而增强模型对跨域共享语义信息的提取能力。在 ResNet-50 主干网络下，CLEAR 进一步取得了 71.58%的平均准确率，优于 SWAD-NU 的 71.30%和 SWAD 的 70.60%。同时，CLEAR 在 Clipart、Product 目标域上分别达到 59.06%、79.66%，均为所有对比方法中的最高结果。这表明，随着主干网络表征能力增强，本章方法在复杂多域场景下的优势进一步体现出来。

表 3.3 以 ResNet-18 为主干网络在 OfficeHome 数据集中对比实验结果

方法	Art	Clipart	Product	RealWorld	平均
RSC[3]	57.70	48.58	72.85	74.39	63.59
MixStyle[7]	58.70	53.40	74.20	75.90	65.50
SagNet[101]	60.20	45.38	70.42	73.38	62.34
LRDG[98]	**61.73**	52.43	72.96	75.89	65.75
CDG[99]	59.20	54.30	**74.90**	75.70	66.00
CLEAR	59.34±0.60	**55.21**±0.54	73.79±0.34	**76.40**±0.65	**66.19**

表 3.4 以 ResNet-50 为主干网络在 OfficeHome 数据集中对比实验结果

方法	Art	Clipart	Product	RealWorld	平均
RSC[3]	57.70	51.40	74.80	75.10	65.50
SagNet[101]	63.40	54.80	75.80	78.30	68.10
SWAD[102]	66.10	57.70	78.40	80.20	70.60
Fishr[9]	63.40	54.20	76.40	78.50	68.20
SWAD-NU[105]	67.50	58.40	78.60	**80.70**	71.30
DMDA[104]	66.10	56.10	77.30	77.90	69.40
ERM++[57]	**68.32**	58.20	76.15	77.32	69.99
CLEAR	67.01±0.20	**59.04**±0.63	**79.61**±0.56	80.67±0.21	**71.58**

3.3.2.4 VLCS 数据集上对比实验结果

VLCS 数据集包含 4 个域和 5 个类别，虽然类别数量相对较少，但不同域之间的数据来源差异明显，因此能够较好地反映模型在跨场景条件下的泛化能力。表 3.5 和表 3.6 分别给出了不同方法以 ResNet-18 和 ResNet-50 为主干网络在 VLCS 数据集上的实验结果。总体来看，本章提出的 CLEAR 方法在两种主干网络设置下均取得了最高的平均准确率，进一步验证了所提方法的有效性。

在 ResNet-18 主干网络下，CLEAR 取得了 78.07%的平均准确率，高于 StableNet 的 77.65%、MMLD 的 76.18%和 RSC 的 75.89%。从各目标域结果来看，CLEAR 在 Caltech 域和 Pascal 域上分别达到 98.45%和 76.69%，表现优于其他对比方法，说明本章方法能够在不同场景分布下保持较强的判别稳定性。

在 ResNet-50 主干网络下，CLEAR 进一步取得了 80.06%的平均准确率，优于 SWAD-NU 的 79.80%、CCFP 和 DMDA 的 79.40%。其中，CLEAR 在 Caltech、LabelMe 和 Pascal 三个目标域上分别达到 99.15%、65.62%和 78.61%，均取得了最优结果。虽然在 Sun 域上的结果略低于部分方法，但 CLEAR 依然凭借更均衡的整体表现取得了最高的平均准确率，说明本章方法在不同域之间具有更好的综合泛化能力。

表 3.5 以 ResNet-18 为主干网络在 VLCS 数据集中对比实验结果

方法	Caltech	LabelMe	Pascal	Sun	平均
RSC[3]	95.83	63.74	71.86	72.12	75.89
StableNet[10]	96.67	**65.36**	73.59	**74.97**	77.65
MMLD[19]	97.01	62.20	73.01	72.49	76.18
CLEAR	**98.42**±0.17	64.74±0.85	**75.56**±0.97	73.56±0.65	**78.07**

表 3.6 以 ResNet-50 为主干网络在 VLCS 数据集中对比实验结果

方法	Caltech	LabelMe	Pascal	Sun	平均
RSC[3]	97.90	62.50	72.30	75.60	77.10
SWAD[102]	98.80	63.30	75.30	79.20	79.10
CCFP[103]	98.90	64.10	74.90	79.90	79.40
SWAD-NU[105]	99.10	63.60	75.90	80.50	79.80
DMDA[104]	98.20	64.30	74.40	**80.80**	79.40
ERM++[57]	98.51	64.66	72.72	80.47	79.09
CLEAR	**99.13**±0.15	**65.69**±0.72	**77.96**±0.52	77.62±0.55	**80.10**

3.3.3 消融实验

3.3.3.1 各模块融合消融实验

为验证 CLEAR 框架中各组成模块的有效性，本节在 PACS 数据集上分别以 ResNet-18 和 ResNet-50 为主干网络开展消融实验，结果如表 3.7 和表 3.8 所示。其中，ResNet-18 和 ResNet-50 表示仅采用标准经验风险最小化（Empirical Risk Minimization，ERM）训练的主干网络基线模型，CMADD 表示仅引入基于跨空间多尺度信息聚合注意力的域鉴别器模块，MICL 表示仅引入基于动量更新的推理一致性约束，CLEAR 表示同时引入上述两个模块后的完整模型。

从 ResNet-18 主干网络下的结果可以看出，两个模块单独引入时均能够显著提升模型性能。相较于基线模型 77.13%的平均准确率，CMADD 和 MICL 分别将平均准确率提升至 85.24%和 84.58%，而完整模型 CLEAR 进一步达到 85.95%，相较基线模型提升了 8.63 个百分点。与此同时，CLEAR 在 Art、Cartoon 和 Sketch 三个目标域上均取得了最优结果，说明本章方法在不同域偏移条件下均具有较好的稳定性。

在 ResNet-50 主干网络下，CLEAR 同样表现出稳定的增益。相较于基线模型 82.13%的平均准确率，CMADD 和 MICL 分别将平均准确率提升至 87.87%和 87.70%，而完整模型 CLEAR 达到 88.91%，相较基线模型提升了 6.96 个百分点。同时，CLEAR 在 Art、Cartoon 和 Sketch 三个目标域上均取得了最优结果，在 Photo 域上也保持了较高水平，表明所提方法在更强主干网络下同样有效。

综合来看，CMADD 和 MICL 分别从域敏感特征抑制和跨域推理一致性约束两个方面提升模型的泛化能力，二者结合后能够进一步增强模型在未知域上的识别性能。消融实验结果表明，CLEAR 的性能提升并非来源于单一模块，而是两个关键模块协同作用的结果。

表 3.7 以 ResNet-18 为主干网络消融实验结果

方法	Art	Cartoon	Photo	Sketch	平均
ERM w/ ResNet-18	71.39±0.56	68.06±0.80	95.58±0.23	74.24±0.62	77.32
CMADD	83.33±0.54	78.86±0.46	**96.15**±0.08	82.60±0.68	85.24
MICL	81.72±0.42	78.77±0.47	95.52±0.14	82.32±0.70	84.58
CLEAR	**83.50**±0.35	**81.06**±0.50	96.13±0.17	**83.10**±0.78	**85.95**

表 3.8 以 ResNet-50 为主干网络消融实验结果

方法	Art	Cartoon	Photo	Sketch	平均
ERM w/ ResNet-50	79.14±0.44	74.12±0.49	98.02±0.22	76.52±0.47	81.95
CMADD	87.57±0.57	83.11±0.46	**98.14**±0.12	82.66±0.74	87.87
MICL	87.30±0.58	82.79±0.38	97.64±0.14	83.07±0.65	87.70
CLEAR	**88.31**±0.45	**83.94**±0.52	97.85±0.20	**85.55**±0.68	**88.91**

3.3.3.2 注意力机制消融实验

为了验证本章所提跨空间多尺度信息聚合注意力机制的有效性，本方法在保持域鉴别器其余结构一致的条件下，将 CMADD 中的注意力模块分别替换为常用注意力机制，包括通道注意力 SE（Squeeze-and-Excitation Networks）[106]，通道与卷积块注意力 CBAM（Convolutional Block Attention Module）[89]和坐标注意力 CA。实验采用 PACS 数据集，并以 ResNet-18 作为主干网络进行对比。实验结果如表 3.9 所示，CMADD w/o Att.表示去除注意力机制后的 CMADD 变体。

从表 3.9 可以看出，引入不同注意力机制后，模型性能均较无注意力版本有所提升，说明注意力建模有助于增强域鉴别器对关键通道和有效空间信息的刻画能力。其中，本章提出的 CMADD 在平均准确率上达到 85.24%，相比去除注意力机

制的 Baseline 提升 1.49 个百分点，并优于 SE、CBAM 和 CA 等常用注意力模块。具体来看，CMADD 在 Cartoon 和 Photo 域上取得最优结果，在 Art 和 Sketch 域上虽略低于 CA，但整体表现更加均衡，说明所提出的跨空间多尺度信息聚合机制能够在不同风格域之间保持更稳定的综合性能。

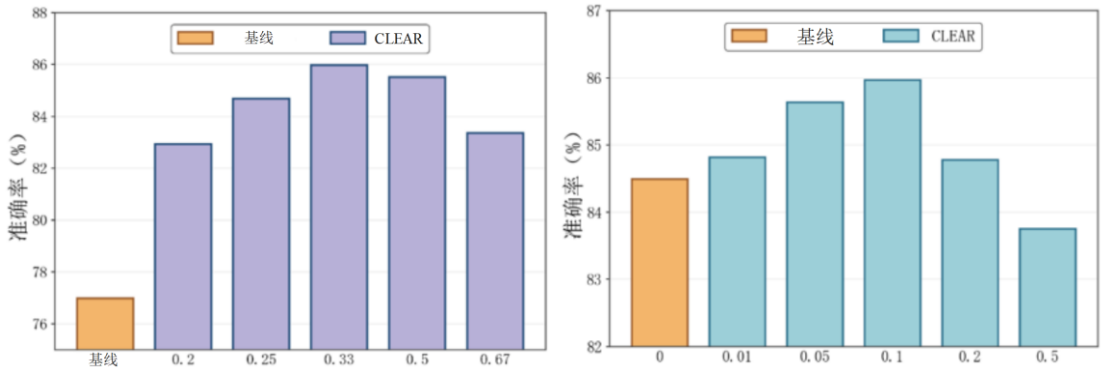
表 3.9 注意力模块对比实验结果

方法	Art	Cartoon	Photo	Sketch	平均
CMADD w/o Att.	79.96±0.43	78.11±0.42	95.39±0.48	81.53±1.18	83.75
CMADD w/ SE	81.61±0.44	79.22±0.46	95.70±0.20	81.84±0.98	84.59
CMADD w/ CBAM	82.24±0.36	**79.55**±0.32	95.98±0.22	81.96±0.72	84.93
CMADD w/ CA	83.06±0.46	78.62±0.40	95.13±0.16	81.67±0.55	84.62
CMADD	**83.33**±0.54	78.86±0.46	**96.15**±0.08	**82.60**±0.68	**85.24**

相比 SE 仅从通道维度进行重标定、CBAM 依次建模通道与空间注意力、CA 侧重编码坐标方向位置信息，CMADD 通过多尺度空间信息聚合与通道响应建模相结合，能够更充分地捕获不同感受野下的局部与全局结构信息，并为后续域敏感通道识别提供更有效的判别依据。因此，该实验进一步验证了本章所提注意力机制在域泛化任务中的有效性。

3.3.4 参数敏感性分析

为进一步分析所提方法中关键超参数对模型性能的影响，本章分别对特征通道去除率P_{drop}和损失权重λ以 ResNet-18 为主干网络在 PACS 数据集上进行了参数敏感性实验，结果如图 3.3(a)和图 3.3(b)所示。



(a) 特征通道去除率　　(b) 损失权重

图 3.3 参数敏感性实验

首先，图 3.3(a)展示了不同特征通道去除率设置下模型的分类性能变化情况。其中，Baseline 模型的平均准确率为 77.0%，而 CLEAR 在不同去除率设置下均取得了明显更优的结果，说明所提出的域敏感通道抑制机制能够有效提升模型的跨

域泛化能力。从具体数值来看，当P_{drop}由 0.2 逐步增加至 0.33 时，模型性能持续提升，准确率由 82.9%提高至 86.0%，表明适当增强对域敏感通道的抑制有助于削弱域相关冗余信息的干扰，促使模型学习更加稳定的判别特征。然而，当P_{drop}继续增大至 0.5 和 0.67 时，模型性能分别下降至 85.5%和 83.3%。这说明过强的通道抑制会不可避免地误伤部分与类别判别相关的有效特征，从而削弱特征表达能力。综合来看，P_{drop}取 0.33 时性能最佳，因此本章后续实验中将该参数固定为 0.33。

其次，图 3.3(b)给出了不同损失权重λ设置下模型性能的变化趋势。可以看出，当λ从 0 增加到 0.1 时，模型准确率由 84.49%逐步提升至 85.97%，表明在训练过程中引入适当强度的一致性约束能够有效增强模型判别依据的稳定性，改善跨域特征表示质量。当λ继续增大至 0.2 时，模型性能有所下降，而当其进一步增大至 0.5 时，准确率下降至 83.75%，说明过大的约束权重会使优化过程过度偏向附加约束项，抑制主分类目标的有效学习，进而影响模型整体性能。因此，λ取 0.1 时取得最佳效果，本章实验中采用该设置。

3.3.5 特征通道稳定性分析

为进一步验证第三章所提出方法在抑制域特定信息敏感通道方面的有效性，本节从特征通道统计的角度，以 ResNet-18 为主干网络在 PACS 数据集上对不同模型在高层特征空间中的跨域响应波动情况进行了分析。具体而言，选取最后一个残差块输出的高层特征图，统计每个通道在不同源域上的平均响应，并计算其跨域标准差，以刻画该通道对域变化的敏感程度。标准差越大，说明该通道在不同域间的响应差异越明显，更容易受到风格、背景、纹理等域特定因素的干扰；反之，则说明该通道具有更强的跨域稳定性，更可能承载与目标类别相关的共享语义信息。结合本章中 CMADD 模块对域敏感通道的识别与抑制机制，这一分析能够从统计层面对所提方法的作用进行更直接的验证。

3.3.5.1 Sketch 目标域下的通道波动分布分析

如图 3.4 所示，在以 Sketch 为目标域的设置下，Baseline 与 CLEAR 的通道跨域波动分布存在较为明显的差异。可以观察到，Baseline 的分布整体更偏向高值区域，且在右侧存在更明显的长尾现象，说明其高层特征中仍包含较多对域变化较为敏感的通道；相比之下，CLEAR 的通道分布整体向低波动区间收缩，高波动尾部显著缩短，表明经过域敏感通道抑制后，模型内部不稳定响应被有效削弱，更多通道能够保持相对一致的跨域响应模式。

从统计结果看，Baseline 在该设置下的平均通道波动为 0.229，中位数为 0.199，而 CLEAR 分别下降至 0.160 和 0.148；同时，最大波动值由 1.169 降低至 0.513，前 20%高波动通道的平均水平由 0.451 降低至 0.291。上述结果表明，CLEAR 不仅

降低了整体特征通道的平均波动水平，还显著压缩了最不稳定通道的尾部分布，使高层表示更加集中于跨域稳定的信息表达。换言之，所提方法能够有效抑制那些对域特定信息高度敏感、容易随外观风格变化而剧烈波动的通道，从而增强模型在跨域识别时所依赖的主体语义表示。

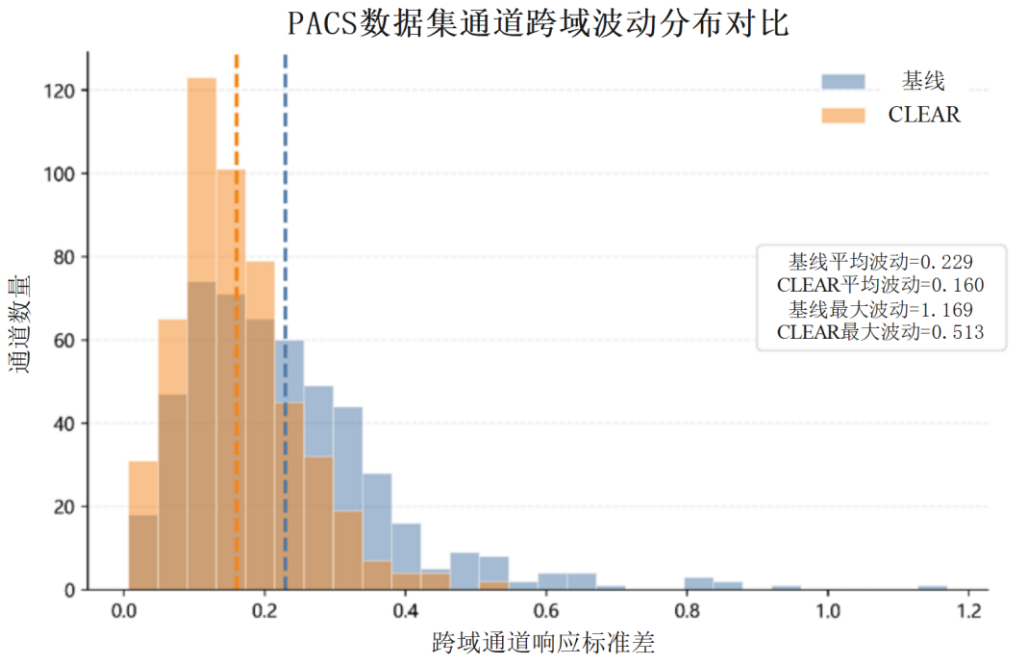


图 3.4　Sketch 域通道跨域波动对比

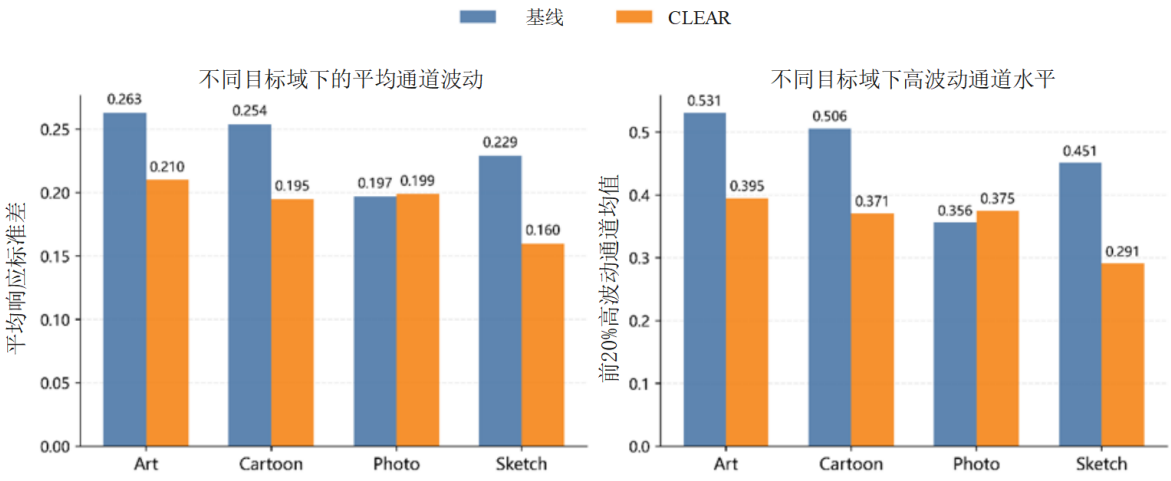
3.3.5.2　不同目标域下关键统计指标对比分析

为了考察该机制在不同目标域设置下的表现，本节进一步统计了四个目标域下的平均通道波动以及前 20%高波动通道的平均水平，结果如图 3.5 所示。整体来看，CLEAR 在不同目标域上的改善趋势较为一致：除 Photo 目标域外，在 Art、Cartoon 和 Sketch 三个目标域设置下，CLEAR 均明显降低了通道跨域波动水平，尤其在高波动通道上的抑制效果更为突出。图中通道波动值由特征响应的跨域标准差计算得到，为无量纲统计量。

从左侧子图可以看出，在平均通道波动这一整体指标上，CLEAR 在 Art、Cartoon 和 Sketch 三个目标域上均优于 Baseline。其中，Art 目标域下平均通道波动由 0.263 下降至 0.210，Cartoon 目标域下由 0.254 下降至 0.195，Sketch 目标域下由 0.229 下降至 0.160，说明所提方法能够在这些域偏移较明显的目标域中有效降低高层特征的整体跨域不稳定性。相比之下，在 Photo 目标域下，两种方法的平均波动接近，模型整体通道波动水平变化不明显。

更值得关注的是右侧子图所展示的前 20%高波动通道均值。该指标能够更直接地反映模型内部最不稳定、最容易编码域特定信息的通道状态。从结果可见，CLEAR 在 Art、Cartoon 和 Sketch 三个目标域上均表现出更低的高波动通道均值，

其中，Sketch 目标域上的下降幅度最为明显，表明 CLEAR 能够更有效地削弱随域变化而显著漂移的强干扰通道，减少高层语义空间中由域特定因素引起的异常波动。



(a) (b)

图 3.5　不同目标域下关键统计指标对比分析

3.3.5.3　不同目标域设置下通道跨域波动统计分析

为进一步从完整统计量和分布形态两个角度验证上述结论，本节将不同目标域下的平均通道波动、最大通道波动以及 20%高波动通道均值整理为 3.10，并绘制对应箱线图，如图 3.6 所示。与图 3.5 侧重展示关键指标变化不同，表 3.10 进一步补充了最大通道波动这一指标，能够反映模型中最不稳定通道的极端响应情况；箱线图则从整体分布角度展示通道波动是否向低值区间收缩。

表 3.10 不同目标域设置下 Baseline 与 CLEAR 的通道跨域波动统计结果

目标域	方法	平均通道波动	最大通道波动	前 20%高波动通道均值
Art	Baseline	0.263	1.252	0.531
Art	CLEAR	0.210	0.820	0.395
Cartoon	Baseline	0.254	1.382	0.506
Cartoon	CLEAR	0.195	0.651	0.371
Photo	Baseline	0.197	0.867	0.356
Photo	CLEAR	0.199	0.895	0.375
Sketch	Baseline	0.229	1.169	0.451
Sketch	CLEAR	0.160	0.513	0.291

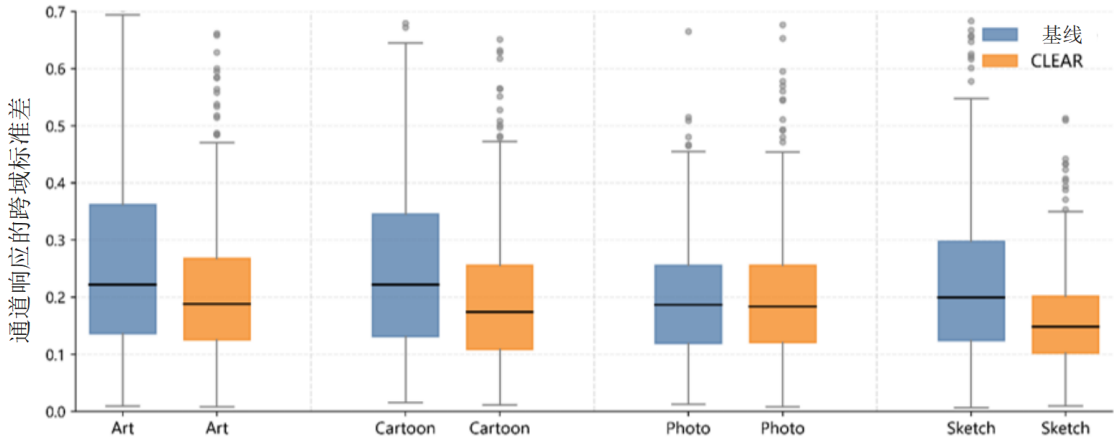


图 3.6　不同目标域设置下两种方法通道跨域波动分布对比

从表 3.10 可以看出，在 Art、Cartoon 和 Sketch 三个目标域设置下，CLEAR 在平均通道波动、最大通道波动和前 20%高波动通道均值上均低于 Baseline，说明所提方法不仅降低了整体通道波动水平，也有效压缩了高波动通道的极端响应。其中，Sketch 目标域下三项指标下降最为明显，表明 CLEAR 在风格差异更强、结构表达更抽象的目标域中，对域敏感通道的抑制作用更加突出。相比之下，Photo 目标域下两种方法的指标较为接近，说明该域与源域之间的外观差异相对较弱，通道稳定性改善不如其他目标域显著。

图 3.6 的箱线图进一步验证了这一趋势。在 Art、Cartoon 和 Sketch 三个目标域中，CLEAR 对应的箱体范围和高值尾部整体收缩，说明经过域敏感通道抑制后，通道跨域波动更加集中于低值区间，异常高波动通道数量减少。综合表 3.10 和图 3.6 可以说明，CLEAR 能够从特征通道层面削弱域相关不稳定响应，使高层表示更加稳定，为后续跨域分类提供更可靠的判别基础。

3.3.6　可视化分析

为进一步从空间响应角度分析本章方法的作用，本节以 ResNet-18 为主干网络，在 PACS 数据集上使用 Grad-CAM 对 Baseline 与 CLEAR 在不同目标域典型样本上的注意力判别区域进行了可视化，结果如图 3.7 所示。

与前文通道跨域波动分析主要从特征统计分布出发不同，热力图能够更直观地反映模型在做出分类决策时所依赖的空间区域，因此可用于验证所提方法是否有效减弱了域特定信息的干扰，并增强了对主体关键语义区域的关注。从图 3.7 可以看出，在不同目标域和不同风格样本上，Baseline 与 CLEAR 的空间响应存在明显差异。Baseline 的高响应区域相对分散，在部分样本中容易覆盖主体外围或背景区域，说明其分类依据仍受到域相关外观信息的影响。相比之下，CLEAR 的响应区域整体更加集中，更多落在目标主体及其关键结构位置，表明所提方法能够在跨

域场景下形成更稳定的空间判别依据。

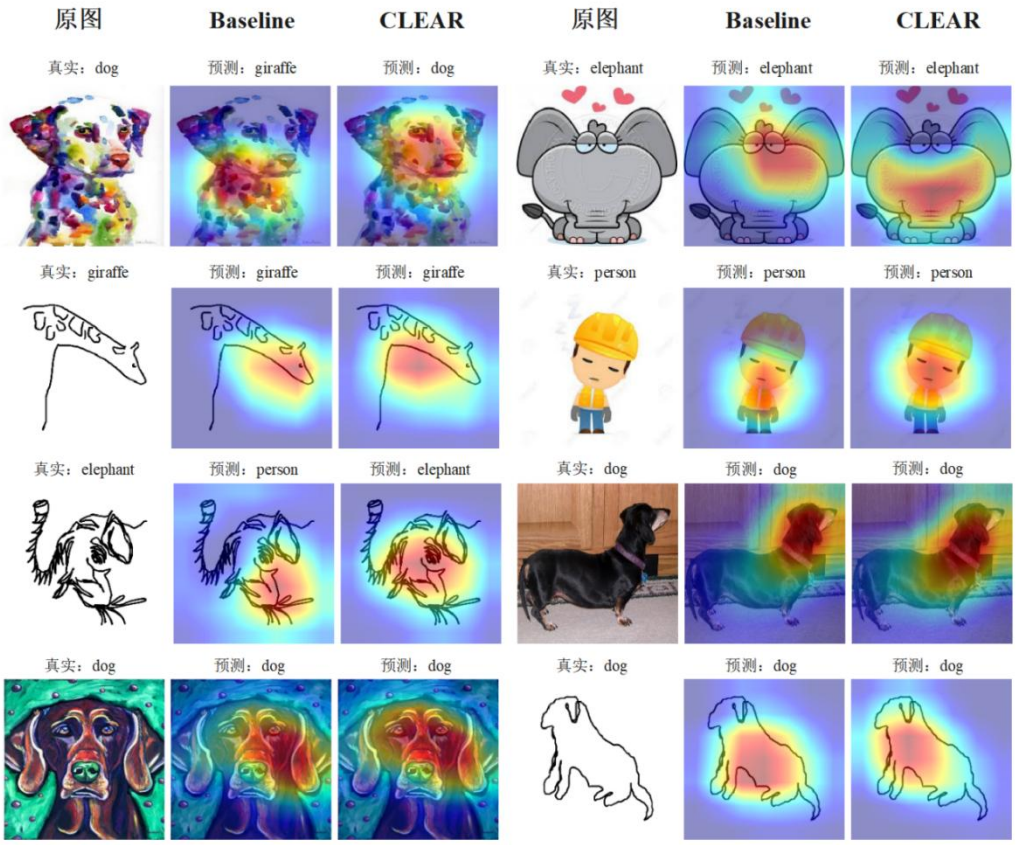


图 3.7　不同目标域典型样本上的 Grad-CAM 可视化总览图

这一结果与 CMADD 的设计目标一致。通过识别并抑制对域变化敏感的特征通道，模型在生成类别判别响应时减少了对背景纹理、成像风格和局部噪声的依赖，从而更倾向于利用跨域共享的语义结构进行分类。结合前文通道稳定性分析可以看出，CLEAR 不仅降低了特征通道层面的跨域波动，也改善了模型在空间维度上的关注模式。

为进一步分析 CLEAR 在困难样本上的作用，本节选取 Baseline 预测错误而 CLEAR 能够正确识别的典型样本进行 Grad-CAM 可视化，结果如图 3.8 所示。可以看到，这些样本通常具有较强的风格变化、轮廓简化或局部结构模糊等特点，Baseline 在此类场景下容易受到非关键区域干扰，导致判别依据偏离目标主体。

相比之下，CLEAR 在这些错误纠正样本中能够形成更加明确的主体响应，使高激活区域更稳定地落在与类别相关的关键部位上。该现象说明，所提方法不仅能够改善整体注意力分布，还能够在部分易混淆样本中修正模型的判别依据，从而提升跨域分类的可靠性。

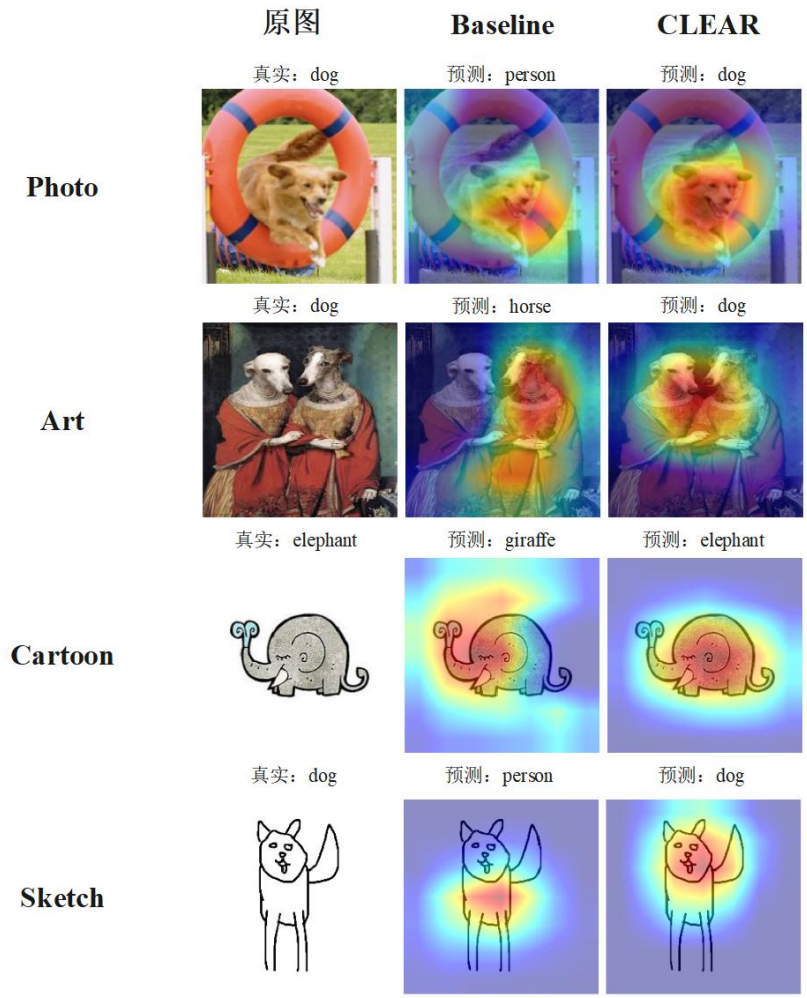


图 3.8　不同目标域典型错误样本上的 Grad-CAM 可视化对比

3.4　本章小结

本章针对复杂环境下域间分布偏移、域敏感特征干扰以及跨域判别依据不稳定等问题，提出了基于多尺度注意力与推理一致性的域泛化方法 CLEAR。该方法通过 CMADD 模块识别并抑制对域变化敏感的特征通道，并利用 MICL 约束同类样本在不同源域中的推理表示一致性，从而增强模型在未知目标域上的判别稳定性。

在 PACS、OfficeHome 和 VLCS 三个公开域泛化基准数据集上的实验结果表明，CLEAR 在 ResNet-18 和 ResNet-50 两种主干网络下均取得了较好的平均分类准确率，整体性能优于多种现有域泛化方法。消融实验进一步验证了 CMADD 和 MICL 两个模块的有效性，二者分别能够从特征抑制和推理约束角度带来稳定增益，结合后可进一步提升模型的跨域泛化能力。参数敏感性分析表明，适度的通道抑制比例和推理一致性约束权重能够在保留类别判别信息与削弱域相关干扰之间取得较好平衡。

此外，特征通道稳定性分析和 Grad-CAM 可视化结果表明，CLEAR 能够降低高层特征通道的跨域波动，并改善模型在不同目标域样本上的空间响应分布。综上，本章方法从特征通道选择和推理过程约束两个方面提升了模型的鲁棒性，为后续进一步开展多阶段分层表示建模提供了基础。

第四章　基于多阶段分层表示建模的域泛化方法

4.1　引言

在第三章中，本文针对复杂环境下域敏感特征干扰和跨域判别依据不稳定的问题，提出了基于多尺度注意力与推理一致性的域泛化方法 CLEAR。该方法通过识别并抑制对域变化敏感的特征通道，同时约束同类样本在不同源域中的推理表示一致性，有效提升了模型在未知目标域上的识别稳定性。上述结果说明，从特征通道层面对域相关响应进行抑制，是缓解跨域分布偏移的一种有效途径。

然而，复杂环境中的域偏移并不仅存在于深层特征通道中，也会体现在输入图像的风格统计、高层表示的内部耦合以及类别判别依据的组织方式上。例如，光照、纹理、背景和成像风格等变化会首先影响输入分布；经过网络逐层传播后，这些环境相关因素仍可能残留在高层特征中，并与类别判别信息发生耦合。仅依靠单一特征层的通道抑制，虽然能够削弱部分域敏感响应，但难以充分覆盖输入风格变化、特征响应偏移和高层表示混杂等多层次问题。

第三章方法主要从特征层出发，通过识别并抑制域敏感通道来提升模型鲁棒性，其约束重点集中在深层特征响应层面。对于复杂环境中的域偏移而言，环境干扰往往并非只体现在单一特征层中，而是会从输入图像的低层风格统计开始，经由网络逐层传播并进一步影响高层语义表示和最终分类依据。因此，仅在特征层进行域敏感通道抑制，虽然能够削弱部分域相关响应，但仍难以充分覆盖输入风格变化、特征响应偏移和高层表示混杂等多层次问题。

基于上述分析，本章在第三章域敏感特征抑制思想的基础上，进一步提出一种基于多阶段分层表示建模的域泛化方法（Multi-Stage Domain-oriented Enhancement，MS-DE）。该方法从输入层、特征层和表示层三个层面分层表示建模模型表示：在输入层扩展源域样本的风格变化范围，在特征层削弱与域变化相关的通道响应，在表示层进一步分离稳定判别成分和环境干扰成分。与第三章主要关注特征层鲁棒建模不同，本章方法试图通过由浅入深的多阶段约束，使模型在面对更复杂的未知域变化时获得更稳定的判别表示。

4.2　方法设计

4.2.1　总体框架介绍

本章提出的 MS-DE 框架如图 4.1 所示，整体由频率自适应傅里叶增强、域敏感通道重标定和对抗性表示解耦三个部分组成。给定来自多个源域的输入样本，模型首先在输入层进行频域风格增强，通过对图像幅度谱进行自适应混合生成风格

扰动样本，从而扩展训练数据的外观分布。随后，原始样本与增强样本共同输入主干网络进行特征提取，得到高层特征表示。

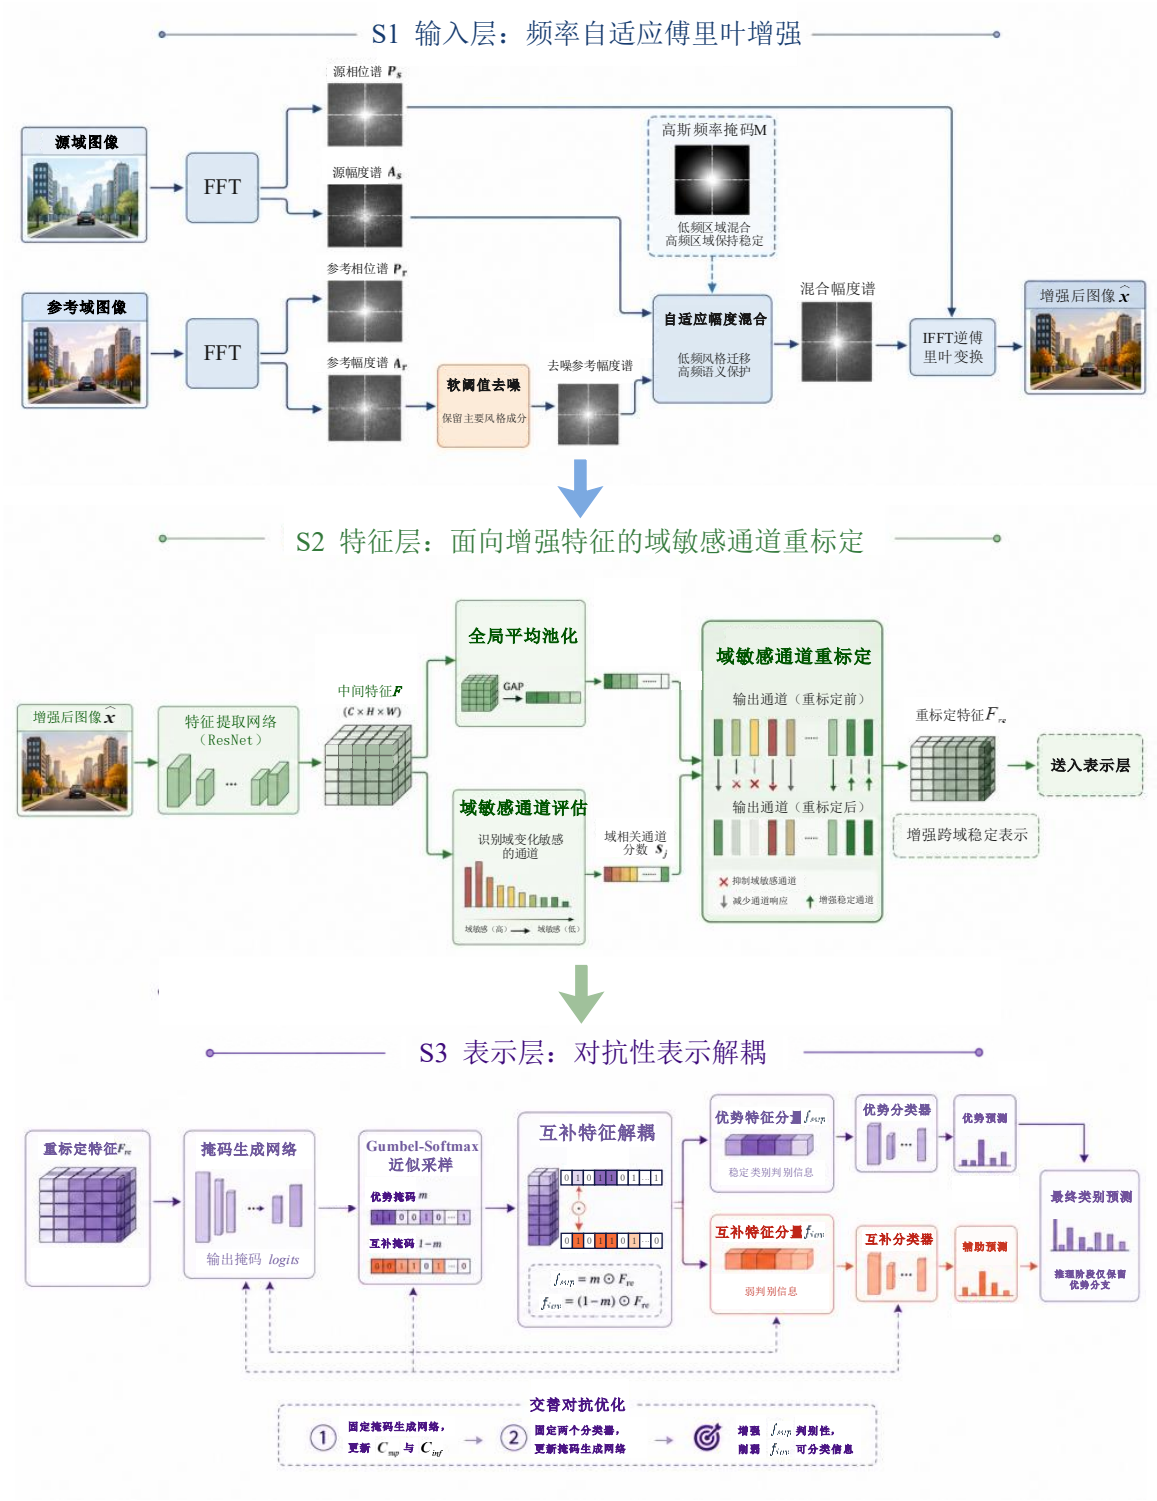


图 4.1　MS-DE 框架

在特征层，MS-DE 进一步计算各特征通道与域信息之间的相关性，并根据域敏感性得分对通道响应进行重标定。与第三章中直接屏蔽部分域敏感通道不同，本

章采用连续权重调制方式削弱域相关响应，使模型在降低环境干扰的同时尽量保留有用的类别判别信息。

在表示层，模型通过可学习掩码将高层特征划分为优势特征分量和互补特征分量，并引入对抗性表示解耦机制，使二者在分类作用上形成差异化分工。优势特征分量用于强化稳定判别信息，互补特征分量则用于承载相对不稳定或辅助性的响应成分。通过这种分解方式，模型能够进一步降低对背景、纹理和风格等伪相关线索的依赖。

训练过程中，MS-DE 联合优化分类损失、通道重标定约束和表示解耦相关损失，使输入扰动、特征调制和高层表示分离形成协同作用。推理阶段，模型仅使用经过训练后的主干网络和分类器进行预测，不需要目标域数据参与。与第三章 CLEAR 方法相比，MS-DE 的增量主要体现在两个方面。第一，CLEAR 主要关注特征层中的域敏感通道抑制，而 MS-DE 将这一思想进一步扩展到输入层、特征层和表示层三个层级，使模型能够从风格扩展、响应调制和语义解耦三个角度共同缓解域偏移。第二，CLEAR 在特征层采用较为直接的通道抑制方式，而 MS-DE 在特征层采用通道重标定，并进一步在表示层引入对抗性解耦机制，以降低过强通道屏蔽可能带来的判别信息损失。通过上述设计，MS-DE 能够在继承第三章域敏感特征建模思想的基础上，更系统地处理复杂环境中多层次域偏移问题。

4.2.2 频率自适应傅里叶增强

在域泛化任务中，训练阶段能够获得的源域样本通常只能覆盖有限的成像条件与环境风格，而测试阶段未知目标域中的光照变化、纹理差异、背景干扰以及设备成像偏差往往更加复杂。若模型在训练过程中对颜色分布、局部纹理、背景统计等低层风格信息形成过强依赖，则在面对未知域时容易出现明显的性能退化。为提升训练样本对潜在域偏移的覆盖能力，并增强模型对复杂风格变化的适应性，本章在输入层设计了一种频率自适应傅里叶增强策略。该方法在保持图像主体语义结构不变的前提下，对风格相关的频域成分进行受控扰动，从而扩展训练分布并降低模型对特定源域外观特征的过拟合。

该方法的基本思想是将图像分解到频域空间，并分别对幅度谱和相位谱进行建模。其中，相位谱主要决定图像的空间结构、边缘轮廓和目标语义信息，而幅度谱更多反映颜色分布、亮度变化、纹理强度以及整体成像风格等低层统计属性。基于这一特性，本方法在增强过程中始终保留源图像的相位信息不变，仅对幅度谱进行跨域混合，使增强样本在维持语义稳定的同时呈现更加丰富的风格变化。进一步地，考虑到幅度谱中不仅包含有助于模拟域偏移的风格统计，也可能混杂背景噪声和无关纹理干扰，本方法在幅度混合前引入软阈值滤波对参考幅度谱进行去噪处理；

同时，为避免高频区域受到过强扰动而破坏局部结构，进一步设计基于高斯分布的自适应频率掩码，对不同频段施加差异化混合强度，形成频率选择性增强机制。

设源域输入图像为$x^s \in \mathbb{R}^{C\times H\times W}$，并从其他源域中随机采样一幅参考图像$x^r \in \mathbb{R}^{C\times H\times W}$。首先对图像进行二维离散傅里叶变换，得到其频域表示：

$$X(u,v) = \mathcal{F}(x)(u,v) = \sum_{h=0}^{H-1}\sum_{w=0}^{W-1} x(h,w)e^{-j2\pi\left(\frac{hu}{H}+\frac{wv}{W}\right)} \tag{4.1}$$

其中，(u,v)表示频率坐标，j为虚数单位。对于多通道图像，各通道独立执行上述变换。经傅里叶分解后，图像的频域表示可进一步写为幅度谱与相位谱的形式，即：

$$A(x)(u,v) = |X(u,v)| \tag{4.2}$$

$$P(x)(u,v) = \angle X(u,v) \tag{4.3}$$

因此，源图像x^s与参考图像x^r的频域分解结果可分别表示为(A^s, P^s)和(A^r, P^r)。为了减弱参考图像幅度谱中背景噪声和弱干扰成分对增强结果的影响，本方法首先对参考幅度谱A^r引入软阈值操作。软阈值函数定义为：

$$\mathrm{S}(z,T) = \mathrm{sign}(z)\cdot max(|z|-T, 0) \tag{4.4}$$

其中z表示输入信号，T为阈值参数。该操作能够压缩小幅值响应并保留显著频率成分，从而降低无关背景和弱纹理扰动在频域混合过程中的影响。将其作用于参考图像幅度谱后，可得去噪后的参考幅度谱为：

$$\tilde{A}^r(u,v) = S(A^r(u,v), T) \tag{4.5}$$

为使阈值具备更好的样本自适应能力，本方法将各通道阈值设置为该通道幅度谱最大值的一定比例，即：

$$T = \alpha\cdot \max(A^r) \tag{4.6}$$

其中，α为阈值比例系数。通过这种方式，软阈值强度能够随不同样本、不同通道的频域能量分布自适应变化，从而在保留主要风格统计的同时，有效抑制参考图像中不稳定的背景干扰成分。

在完成参考幅度谱去噪后，本方法进一步设计频率自适应掩码，以控制不同频率位置上的混合强度。考虑到频谱中心区域对应低频成分，主要表征图像的颜色、亮度和整体风格，而远离中心的高频区域更多包含边缘、轮廓和局部细节信息，因此若对全频范围施加统一强度的混合，容易在增强风格多样性的同时破坏原有语义结构。为解决这一问题，本方法构造一个以频谱中心为峰值、向外逐渐衰减的二维高斯掩码$M(u,v)$：

$$M(u,v) = \exp\left(-\frac{(u-u_c)^2+(v-v_c)^2}{2\sigma^2}\right) \tag{4.7}$$

其中，(u_c, v_c)表示频谱中心位置，σ为高斯分布宽度参数，用于控制低频增强区域的覆盖范围。当频率位置接近中心时，$M(u,v)$的取值较大，表示该区域施加较强

的风格混合；当频率位置远离中心时，$M(u,v)$的取值逐渐减小，表示高频区域更多保留源图像原始幅度信息。由此，本方法将全局混合系数λ_{mix}调制为位置相关的频率自适应系数：

$$\lambda(u,v) = \lambda_{mix} \cdot M(u,v), \qquad \lambda_{mix} \in [0,1] \tag{4.8}$$

在此基础上，将源图像幅度谱A^s与经过软阈值滤波后的参考幅度谱$\tilde{A}^r$进行频率自适应混合，得到增强后的幅度谱：

$$\hat{A}(u,v) = \big(1 - \lambda(u,v)\big)A^s(u,v) + \lambda(u,v)\tilde{A}^r(u,v) \tag{4.9}$$

由上式可以看出，本方法并非对全频幅度谱进行无差别扰动，而是通过频率选择性调制，使低频区域承担主要的风格迁移作用，而高频区域尽可能保持源图像原始细节。这样既能够有效扩展训练样本的风格分布，又能够避免由于高频成分被过度修改而引起目标边缘模糊、局部结构失真等问题。

完成幅度谱混合后，本方法保持源图像相位谱P^s不变，并将其与增强后的幅度谱$\hat{A}$重新组合，得到增强图像的频域表示：

$$\hat{X}(u,v) = \hat{A}(u,v) \cdot e^{jP^s(u,v)} \tag{4.10}$$

随后，通过逆离散傅里叶变换将其映射回空间域，得到最终增强样本：

$$\hat{x} = \mathcal{F}^{-1}\big(\hat{X}\big) \tag{4.11}$$

由于增强过程中始终保留了源图像的相位信息，因此生成样本在目标类别、轮廓结构和空间布局上与原始图像保持一致；同时，幅度谱中的低频风格统计被来自其他源域的频率成分所扰动，使得增强样本呈现出更加多样的外观分布。

从作用机制上看，本方法主要具有以下三方面优势：首先，通过在频域中对幅度谱进行跨域混合，能够直接扩展训练样本的风格分布范围，增强训练分布对未知环境变化的覆盖能力。其次，软阈值滤波能够有效削弱参考图像幅度谱中的弱噪声与背景扰动，使混合过程更加聚焦于稳定且有效的风格成分，降低无关信息被引入增强样本的概率。最后，基于高斯分布的频率自适应掩码显式区分了低频风格信息与高频语义细节的重要性，使得增强过程兼顾风格多样性扩展与语义结构保真，提升了频域增强的可控性与稳定性。

在训练过程中，增强图像$\hat{x}$与原始标签y共同构成新的监督样本，并参与后续分类损失计算。由于增强前后图像的语义类别保持不变，因此无需额外调整标签信息。通过原始样本与增强样本的联合训练，模型被迫在更大范围的风格扰动下维持稳定判别，从而学习到更加鲁棒的底层表征。该输入层增强模块为后续特征层的域敏感通道重标定提供了更加丰富的扰动样本基础，也为表示层进一步解耦稳定判别成分与环境干扰成分创造了更有利的条件。

4.2.3 面向增强特征的域敏感通道重标定

经过前述频率自适应傅里叶增强后，训练样本在成像风格与低频统计层面获得了更丰富的扰动形式，这有助于缓解模型对单一域风格的过拟合。然而，增强后的输入在经过主干网络的多层非线性映射后，仍可能在深层特征空间中重新形成与域属性相关的响应模式。尤其在复杂背景、风格扰动与语义判别共同作用的条件下，部分通道虽对最终分类具有一定贡献，但其激活方式仍与环境变化保持较强相关性。若不对这类通道进行进一步调制，将影响后续表示层对高层结构的进一步优化。

为此，本方法在特征层引入域敏感通道重标定机制，对增强特征中的环境相关响应进行连续抑制。需要指出的是，该模块在思想上与第三章的通道过滤方法一脉相承，二者均利用域判别器估计不同通道对域判别任务的贡献程度。不同之处在于，第三章面向常规分布偏移场景，采用二值掩码对高域敏感通道进行显式删除，其目标是在特征层尽快获得更强的鲁棒表示；而本章更强调多阶段下的分层表示建模，因此不再采用离散丢弃策略，而是引入连续重标定机制，在削弱域相关响应的同时，尽量保留对后续表示优化仍有帮助的判别结构。

沿用第三章中域敏感通道得分的定义方式，可计算第j个通道与域信息之间的相关性得分s_j，不同于第三章中基于二值掩码的通道删除方式，本章根据归一化后的相关性得分构造连续型通道重标定系数：

$$\tilde{s}_j = \frac{s_j - min(s)}{max(s) - min(s) + \epsilon} \tag{4.12}$$

$$r_j = 1 - \gamma \tilde{s}_j, \quad 0 \le \gamma \le 1 \tag{4.13}$$

其中$\tilde{s}_j$为归一化后的相关性得分，γ为重标定强度，ϵ为防止分母为 0 的微小量。由此可见，域敏感性越强的通道，其对应的r_j越小；域特定信息较弱的通道则被更多保留。进一步定义重标定向量：

$$R = [r_1, r_2, \dots, r_C] \in \mathbb{R}^C \tag{4.14}$$

并将其扩展到空间维度后作用于原始特征，得到重标定后的特征表示：

$$F_r = R \odot F \tag{4,15}$$

其中$F \in \mathbb{R}^{C \times H \times W}$为经过主干网络提取得到的特征。通过这一连续调制过程，模型无需对特征通道进行硬性裁剪，便可实现对域相关响应的定向抑制。

采用连续重标定而非离散删除的原因在于，首先，频率增强后的输入同时包含更丰富的风格扰动与潜在判别线索，若直接沿用强二值抑制策略，可能在压制环境相关响应的同时损伤对后续表示优化有价值的语义结构；其次，本章后续表示层需要在更充分的输入表示上进行结构化表示解耦，因此特征层更适合作为一种前置调制机制，而不是一次性完成全部特征处理；最后，连续重标定能够更好地保持通

道间的相对关系，为后续高层表示解耦提供更平滑、更稳定的优化基础。

因此，本模块的作用并不在于直接得到完全的域不变表示，而是通过对域敏感响应进行连续抑制，降低环境相关信息在深层特征中的残留强度，为下一阶段高层表示结构优化提供域相关干扰较少但信息保持较充分的输入基础。

4.2.4 对抗性表示解耦

经过前述输入层增强与特征层调制后，训练样本在风格统计层面得到了扩展，深层特征中的显著域敏感响应也获得了初步抑制。然而，高层表示内部仍可能存在更细粒度的耦合结构，即某些特征维度虽然在训练域中表现出一定判别性，但其响应方式仍容易受到背景纹理、局部外观或上下文共现关系的影响，从而在未知环境中削弱模型决策的稳定性。仅依赖整体特征的一致性优化，难以进一步刻画高层表示内部不同成分在决策过程中的功能差异。

为此，本方法在表示层引入对抗性表示解耦模块，对高层表示进行结构化划分。该模块借鉴因果解耦思想，但本章的目标并非严格恢复完整的因果生成结构，而是通过可学习的解耦机制，进一步区分高层表示中更稳定的判别成分与更易受环境因素影响的干扰成分，从而降低模型在未知域中对表面相关线索的依赖倾向。

设经过域敏感通道重标定后得到的特征表示为$f_r \in \mathbf{R}^D$。其中，D表示特征维度。为了在该表示空间中学习各维度的归属关系，构建一个掩码生成网络$M_\phi(\cdot)$，其输入为特征向量f_r，输出为对应的掩码 logits。考虑到离散二值采样不可导的问题，本方法采用$\mathrm{Gumbel}-\mathrm{Softmax}$技术[107]对掩码进行可微近似采样，得到近似二值的掩码向量：

$$m_g = \mathrm{GumbelSoftmax}\left(M_\phi(f_r)\right) \tag{4.16}$$

其中，$m_g \in [0,1]^D$表示各特征维度被分配到优势分量的程度。相应地，其互补掩码$1-m_g$则用于刻画剩余的干扰分量。基于上述掩码，特征向量f_r被划分为两组互补子表示：

$$f_{sup} = f_r \odot m_g \tag{4.17}$$

$$f_{inf} = f_r \odot (1-m_g) \tag{4.18}$$

其中，$\odot$表示逐元素乘法。这里，f_{sup}表示优势特征分量，期望主要聚合与类别判别更直接相关、在跨域条件下更稳定的语义信息；f_{inf}表示互补特征分量，其内部则更可能吸收与背景、纹理或上下文共现有关的残余干扰信息。

为了分别评估两组子表示的判别能力，本方法进一步构建两个独立分类器：优势分类器C_{sup}和辅助分类器C_{inf}。二者分别作用于f_{sup}和f_{inf}，得到对应的类别预测结果：

$$\hat{y}_{sup} = C_{sup}(f_{sup}) \tag{4.19}$$

$$\hat{y}_{inf} = C_{inf}(f_{inf}) \tag{4.20}$$

据此，可定义两个分支的交叉熵损失为：

$$L_{sup}^{cls} = \mathrm{CE}(\hat{y}_{sup}, y) \tag{4.21}$$

$$L_{inf}^{cls} = \mathrm{CE}(\hat{y}_{inf}, y) \tag{4.22}$$

其中，y为样本真实类别标签。若f_{sup}的确聚合了更稳定、更有判别性的核心语义，则其对应分类器应具备较强分类能力；相反，若f_{inf}主要包含残余干扰或弱判别信息，则其分类性能应受到显式抑制。通过构造这一对互补分支，模型不再仅仅在整体特征上优化单一分类目标，而是在内部表示层面显式形成不同子空间的功能分工。在优化策略上，本方法采用分类器更新与掩码器更新相分离的交替对抗训练机制。首先，在固定掩码生成网络M_{ϕ}的情况下，更新两个分类器参数，使其能够充分挖掘各自输入子空间中的可判别信息。此时分类器的优化目标定义为：

$$L_{cls} = L_{sup}^{cls} + L_{inf}^{cls} \tag{4.23}$$

最小化该目标的目的在于保证两个分类器均具备足够的判别能力，从而为后续掩码学习提供可靠的反馈信号。也就是说，只有当优势分支和辅助分支都由充分训练的分类器进行评估时，掩码器才有可能学习到真正有意义的特征划分，而不是依赖某一分支分类器本身的能力不足来获得表面上的损失差异。

随后，在固定两个分类器参数的情况下，更新掩码生成网络M_{ϕ}，使其在保证优势分支保持良好分类能力的同时，尽可能削弱互补分支中的可分类信息。为此，定义掩码器的优化目标为：

$$\mathcal{L}_{mask} = \mathcal{L}_{sup}^{cls} - \lambda_m \mathcal{L}_{inf}^{cls} \tag{4.24}$$

其中，$\lambda_m > 0$为平衡系数，用于调节对互补分支分类能力的抑制强度。该目标函数包含两层含义：一方面，最小化$\mathcal{L}_{sup}^{cls}$能够促使掩码器将与类别判别密切相关的核心信息优先分配给f_{sup};另一方面，由于损失中对$\mathcal{L}_{inf}^{cls}$施加负号，最小化$\mathcal{L}_{mask}$等价于在训练过程中提高互补分支的分类损失，从而迫使掩码器尽可能减少可直接支持类别决策的信息泄露到f_{inf}中。经过这种对抗博弈，掩码器将逐步学会把更稳定的判别证据集中于优势子空间，而将更环境相关、更具伪相关风险的残余成分压缩到互补子空间内。

在推理阶段，本方法仅保留优势分支用于最终类别预测，即：

$$\hat{y} = \arg max C_{sup}(f_{sup}) \tag{4.25}$$

其原因在于，经过对抗式训练后，f_{sup}已被显式约束为主要承载跨域条件下更稳定的判别信息，而f_{inf}的角色更接近训练阶段的辅助扰动分支，用于帮助掩码器识别并隔离不够稳健的相关线索。仅利用优势分支进行推理，有助于避免模型在测试阶段再次借助环境相关成分进行捷径决策，从而提升其在未知域上的泛化稳定性。

综上，本方法在表示层构建了由掩码生成网络、双分支分类器和交替对抗优化共同组成的表示解耦机制。该模块建立在输入层风格扩展与特征层响应调制的基础之上，进一步从高层表示内部优化不同判别成分的组织方式，使模型能够更集中地利用跨域条件下更稳定的判别信息。由此，第四章所提出的方法实现了从输入层、特征层到表示层的逐级递进建模，为复杂分布变化条件下的域泛化提供了更加系统的表示优化框架。

4.3 实验结果与分析

4.3.1 数据集与实验设置

本章实验沿用第三章的标准域泛化实验协议，包括数据集选择、留一域策略及主干网络配置。实验使用的域泛化数据集与第三章一致，覆盖 PACS、OfficeHome 和 VLCS，每个数据集的源域与目标域划分、训练集与验证集比例以及类别定义均与第三章保持统一，确保可比性。主干网络采用 ResNet-18 和 ResNet-50，Batch size、初始学习率及优化器设置均沿用第三章配置。

为了验证 MS-DE 的有效性，本章在上述基础上针对模型中新增的输入层增强、特征层通道重标定以及表示层对抗性表示解耦模块进行了训练和评估。所有新增模块均保持与主干网络相容，训练过程采用与第三章相同的训练设置，并在验证集上选择最优模型进行评估。本章采用分类准确率（%）作为主要评价指标，并遵循留一域评估策略。

新增参数中，阈值比例系数$\alpha = 0.01$，全局混合系数λ_{mix}固定为 0.5，高斯分布宽度$\sigma = 25$，重标定强度$\gamma = 0.3$，实验结果主要以 Top-1 准确率作为评价指标，同时记录模型在各源域和目标域上的性能变化，以便与第三章方法进行直接对比。为保证实验结果的统计可靠性，所有实验均采用不同随机种子重复 3 次，最终报告的结果为 3 次独立实验的平均值。除特殊说明外，表中加粗结果表示对应列中的最优结果。同时，本章将不引入额外域泛化模块、仅采用 ERM 训练的主干网络记为 Baseline。所有实验均基于 PyTorch 2.2.1 框架实现，在搭载 NVIDIA GeForce RTX 3090 显卡的 Linux 服务器上完成。

4.3.2 对比实验

为验证本文所提出的 MS-DE 方法的有效性，本节在 PACS、OfficeHome 和 VLCS 三个公开域泛化基准数据集上开展对比实验，并分别采用 ResNet-18 和 ResNet-50 作为主干网络。实验采用留一域评估方式，即每次选取一个域作为未知目标域，其余域作为源域进行训练，并以目标域上的 Top-1 分类准确率作为评价指标。为便于整体比较，表 4.1 和表 4.2 分别给出了不同方法在三个数据集上的平均

分类准确率结果。

需要说明的是，CLEAR 和 MS-DE 为本文方法相关实验结果，其余对比方法结果引用自对应原论文或公开报告结果。由于不同工作在训练细节、数据划分、超参数设置等方面可能存在差异，表中结果主要用于相近实验设置下的参考性比较。

由表 4.1 可以看出，在 ResNet-18 主干网络下，本文提出的 MS-DE 方法在 PACS、OfficeHome 和 VLCS 三个数据集上分别取得了 86.50%、66.79%和 78.98%的平均准确率，整体平均准确率达到 77.42%。与 RSC 方法相比，MS-DE 在三个数据集上均取得更高的分类性能，说明 MS-DE 能够有效提升模型在未知目标域上的泛化能力。与第三章提出的 CLEAR 方法相比，MS-DE 在 PACS、OfficeHome 和 VLCS 上分别提升了 0.55、0.60 和 0.91 个百分点，整体平均准确率提升了 0.68 个百分点。这表明，在特征层域敏感响应抑制与推理一致性约束的基础上，进一步引入输入层风格扩展、特征层通道重标定和表示层对抗性解耦，能够进一步增强模型对复杂域偏移的适应能力。

表 4.1 ResNet-18 主干网络下与现有方法的平均准确率对比

方法	PACS	OfficeHome	VLCS	平均
RSC[3]	85.15	63.59	75.89	74.88
CLEAR	85.95	66.19	78.07	76.74
MS-DE	**86.50**	**66.79**	**78.98**	**77.42**

表 4.2 ResNet-50 主干网络下与现有方法的平均准确率对比

方法	PACS	OfficeHome	VLCS	平均
RSC[3]	87.83	65.50	77.10	76.81
SWAD-NU[105]	88.50	71.30	79.80	79.87
DMDA[104]	88.10	69.40	79.40	78.97
ERM++[57]	88.22	69.99	79.09	79.10
CLEAR	88.91	71.58	80.10	80.20
MS-DE	**89.73**	**72.64**	**81.01**	**81.13**

由表 4.2 可以看出，在 ResNet-50 主干网络下，MS-DE 在三个数据集上的平均准确率分别达到 89.73%、72.64%和 81.01%，整体平均准确率为 81.13%，优于 RSC、SWAD-NU、DMDA、ERM++和 CLEAR 等对比方法。与 CLEAR 相比，MS-DE 的整体平均准确率提升 0.93 个百分点，表明该方法在更强主干网络下同样能够带来稳定增益。

进一步比较不同类型方法可以发现，RSC 主要依赖特征抑制机制提升泛化能力，SWAD 和 ERM++更强调训练策略与优化平坦性，DMDA 和 SWAD-NU 则从通道筛选或特征矩阵约束角度削弱不稳定信息。这些方法能够在一定程度上改善模型的跨域鲁棒性，但大多侧重单一层级的特征处理或优化约束。相比之下，MS-DE 在输入阶段通过频率自适应傅里叶增强扩展源域风格分布，在特征阶段通过域

敏感通道重标定削弱不稳定响应，在表示阶段通过对抗性表示解耦分离稳定判别信息与环境相关干扰。与第三章 CLEAR 方法相比，MS-DE 不仅继承了域敏感特征抑制的优势，还进一步将域泛化建模扩展到输入、特征和表示多个阶段，因此在 ResNet-18 和 ResNet-50 两种主干网络下均取得了稳定提升。

4.3.3 消融实验

为了进一步分析所提出 MS-DE 框架中各组成模块的独立贡献及其协同作用，本节在 PACS 数据集上采用 ResNet-18 作为主干网络开展消融实验。实验将不引入 S1、S2、S3 任一模块、仅采用标准 ERM 训练的模型作为 Baseline，并在此基础上分别加入频率自适应傅里叶增强（S1）、域敏感通道重标定（S2）和对抗性表示解耦（S3），以考察各模块对跨域泛化性能的影响。其中 w/表示在 Baseline 基础上加入对应模块。

从单模块结果可以看出，S1、S2 和 S3 均能够在 Baseline 基础上带来明显性能提升。Baseline 的平均准确率为 77.32%，而加入 S1 后平均准确率提升至 84.46%，说明频率自适应傅里叶增强能够通过扩展训练样本的风格分布，有效提升模型对未知域外观变化的适应能力。加入 S2 后平均准确率达到 84.53%，略高于单独加入 S1 的结果，表明域敏感通道重标定能够削弱深层特征中与域变化相关的响应，使模型更加关注稳定的类别判别信息。单独加入 S3 后平均准确率为 84.21%，同样显著优于 Baseline，说明对抗性表示解耦能够在高层表示空间中进一步优化不同特征分量的功能分工，从而改善模型跨域泛化性能。

表 4.3 MS-DE 消融实验

方法	S1	S2	S3	Art	Cartoon	Photo	Sketch	平均
Baseline	-	-	-	71.39±0.56	68.06±0.80	95.58±0.23	74.24±0.62	77.32
Baseline w/ S1	✓			82.11±0.52	79.28±0.47	94.79±0.31	81.66±0.62	84.46
Baseline w/ S2		✓		83.44±0.62	78.37±0.46	94.80±0.24	81.49±0.82	84.53
Baseline w/ S3			✓	82.08±0.75	78.94±0.56	95.46±0.25	80.37±0.53	84.21
Baseline w/o S1		✓	✓	84.23±0.44	80.70±0.54	95.67±0.33	82.71±0.66	85.83
Baseline w/o S2	✓		✓	83.06±0.43	80.02±0.48	96.37±0.14	82.91±0.67	85.59
Baseline w/o S3	✓	✓		83.15±0.61	80.55±0.55	95.31±0.13	80.36±0.71	84.84
MS-DE	✓	✓	✓	**84.36**±0.48	**81.92**±0.61	**96.40**±0.23	**83.30**±0.43	**86.50**

从双模块组合结果来看，不同模块之间具有较好的互补性。Baseline w/o S3 的平均准确率达到 85.93%，相比单独使用 S1 或 S2 进一步提升，说明输入层风格扩展与特征层通道调制能够形成有效协同：前者增加训练分布多样性，后者抑制增强后特征中的域敏感响应。Baseline w/o S3 的平均准确率为 84.84%，相比单独使用

S1 或 S2 有一定提升，但提升幅度相对有限，说明仅依赖输入层增强与特征层调制，仍可能缺少对高层特征的优化。Baseline w/o S1 的平均准确率达到 85.83%，在所有双模块组合中表现最好，表明特征层域敏感响应抑制能够为后续表示层解耦提供更加稳定的输入特征，二者在削弱环境相关信息和强化稳定判别表示方面具有较强互补作用。

完整 MS-DE 同时引入 S1、S2 和 S3 后，在 PACS 四个目标域上的平均准确率达到 86.50%，相比 Baseline 提升 9.18 个百分点，并优于所有单模块和双模块组合结果。具体来看，MS-DE 在 Art、Photo 和 Sketch 域上均取得了最高准确率，在 Cartoon 域上也保持了较高性能，说明三个阶段的联合建模能够在不同类型的域偏移条件下保持较好的稳定性。总体而言，消融实验结果表明，输入层频率增强、特征层通道重标定和表示层对抗性表示解耦均对模型性能提升具有积极作用，三者之间能够形成从数据分布扩展、特征响应调制到高层表示优化的递进互补关系，从而有效提升模型在未知目标域上的泛化能力。

4.3.4 可视化分析

（1）频率自适应傅里叶增强可视化

为直观展示第四章输入层频率自适应傅里叶增强模块的作用，本节选取两组来自不同域的样本对其增强结果进行可视化比较，如图 4.2 所示。根据第四章方法设计，普通幅度混合通过直接替换或插值幅度谱来引入另一域的风格统计，而本章提出的自适应频率增强方法则在保留原图相位信息的基础上，对风格图像的幅度谱进行软阈值处理，并结合低频优先的自适应混合策略，从而实现更加受控的跨域风格扩展。

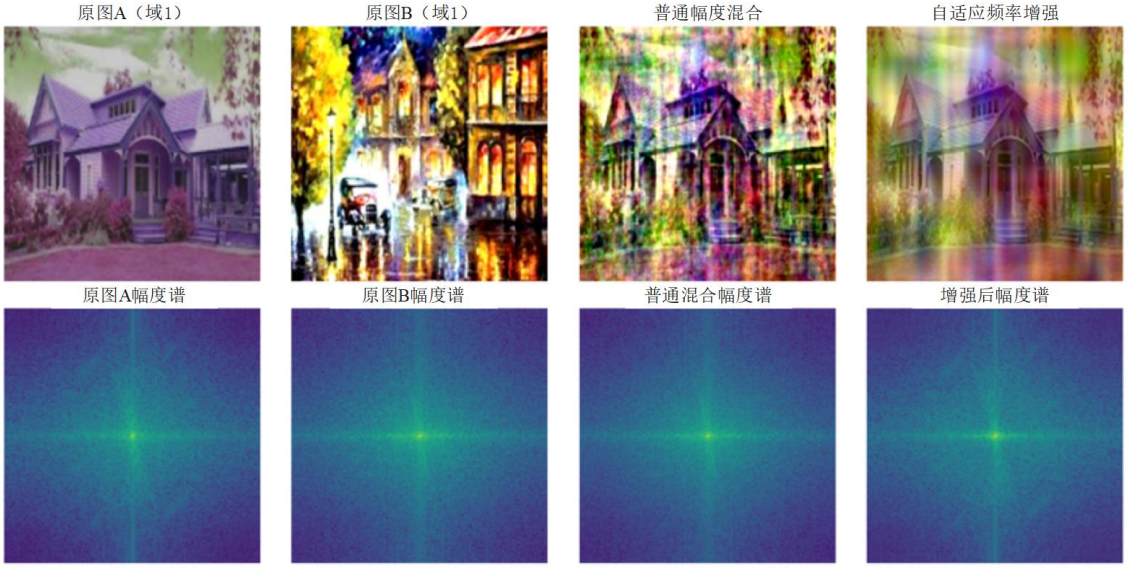


图 4.2 普通幅度混合与本章方法增强结果的可视化比较

从图中可以看出，普通幅度混合虽然能够较明显地引入另一域的外观特征，但同时也容易带来较强的纹理叠加和结构污染，使增强结果在视觉上显得更杂乱，甚至对主体区域的原始语义表达造成一定干扰。相比之下，自适应频率增强后的图像整体更加平滑，原图中的主体结构、空间布局和主要轮廓得到了更稳定的保留，而来自另一域的风格扰动则以较为温和的方式融入图像之中。这说明本方法强调在不破坏主体语义的前提下，对输入分布进行适度的风格扩展。

结合下方的幅度谱可视化结果可以进一步发现，普通混合后的频率分布变化更为直接，而本章方法得到的增强结果在频率空间中表现出更加平滑和收敛的变化趋势。这表明，输入层模块主要作用于与风格统计密切相关的低频成分，同时尽量减少对高频结构信息的破坏，从而使增强样本既具有跨域风格多样性，又能够保持较稳定的主体语义表达。对于域泛化任务而言，这种更加受控的输入扰动方式能够为后续特征层和表示层建模提供更加丰富且可靠的训练分布。

（2）t-SNE 可视化分析

为进一步验证本章方法相对于第三章方法的改进效果，本节在 PACS 数据集上以 ResNet-50 为主干网络对 Baseline、第三章方法 CLEAR 以及本章方法 MS-DE 的特征嵌入分布进行了 t-SNE 可视化比较，如图 4.3 所示。其中，左列为按类别着色的特征分布，右列为按域着色的特征分布。通过同时观察类别结构和域分布，可以更加直观地分析不同方法在特征判别性与跨域一致性方面的差异。

从左列按类别着色的结果可以看出，Baseline 的特征分布仍存在较明显的类别混杂现象，部分类别之间边界不够清晰，类内分布也相对松散，说明模型提取到的表示仍然受到域间差异和无关扰动的影响。引入第三章方法 CLEAR 后，特征分布已经表现出一定程度的收敛，多个类别簇的紧致性有所提升，类别之间的重叠现象得到缓解，表明域相关通道抑制机制能够在一定程度上削弱域敏感信息对特征学习的干扰。在此基础上， MS-DE 进一步改善了特征嵌入结构，不同类别形成了更加清晰和紧凑的聚类分布，类间间隔也更为明显，说明通过输入层频率增强、特征层稳健建模以及表示层解耦优化后，模型获得了更强的判别表示能力。

从右列按域着色的结果来看，Baseline 的特征分布中仍然保留了较强的域偏差信息，不同域样本在特征空间中的组织较为杂乱，且若干区域存在较明显的域聚集趋势。经过第三章方法处理后，域间分布开始出现更多交叠，说明通过抑制域相关通道，模型对域特定信息的依赖有所减弱。进一步 MS-DE 方法后，不同域样本在多个类别相关区域内呈现出更加充分的混合分布，域间边界进一步减弱，表明所学习到的特征表示更加稳定，受到域差异的影响进一步降低。这说明第四章方法不仅继承了第三章在抑制域敏感信息方面的优势，而且通过多阶段协同机制进一步提升了跨域特征的一致性。

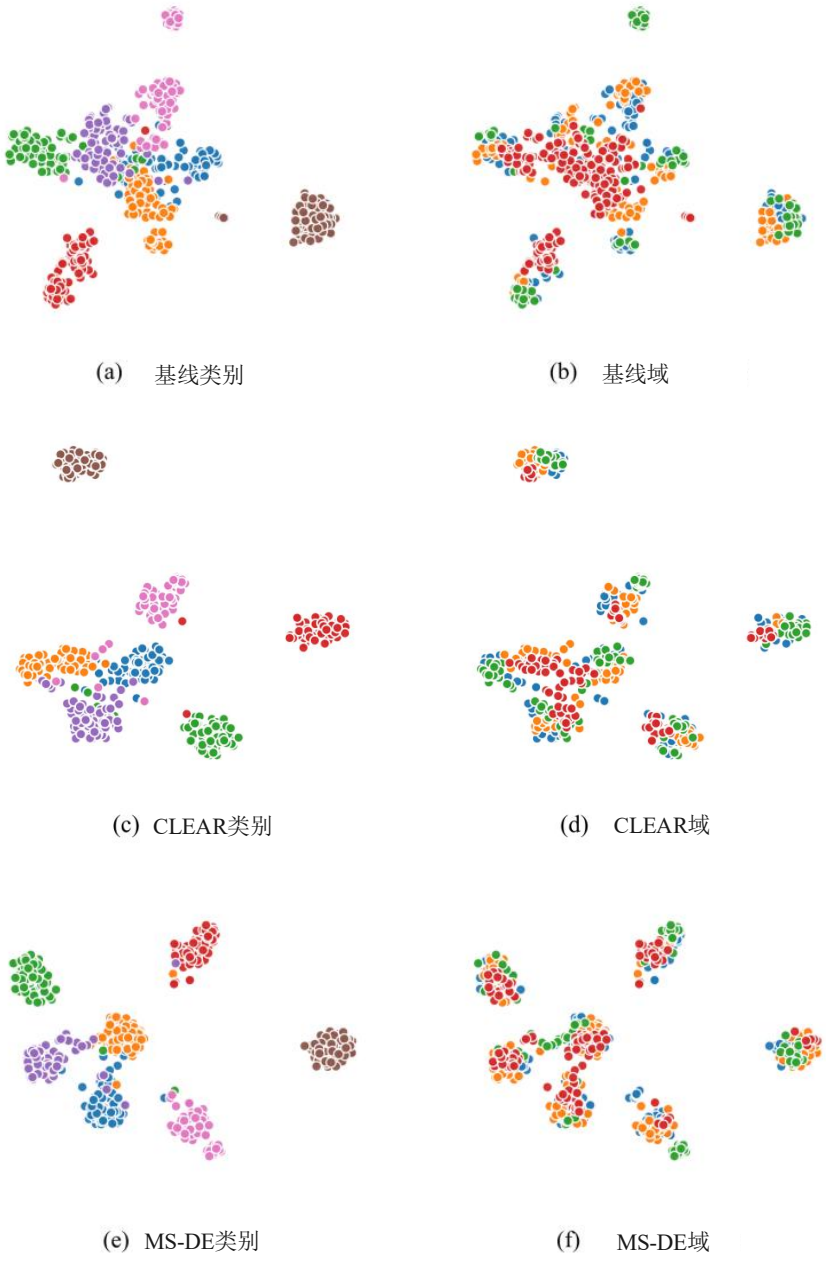


图 4.3 t-SNE 可视化比较

综合来看，图 4.3 较为清晰地展示了从 Baseline 到第三章方法，再到第四章方法的递进式改进过程。第三章方法主要通过削弱域相关通道响应来改善特征纯净性，而第四章方法则在此基础上继续从输入扰动、特征建模与表示解耦三个层面进行联合优化，使得最终特征在类别判别性和跨域稳定性两方面都得到进一步提升。这也从特征分布角度印证了 MS-DE 并非仅在分类准确率上优于前述方法，更重要的是它在类别分布和特征空间组织两个层面均表现出更强的稳定性。这些现象与前述定量实验结果相一致，进一步支持了本方法能够增强复杂分布变化下稳定判别表示学习能力的分析。

4.3.5 特征统计分布分析

为进一步分析不同方法对跨域特征分布对齐的影响，本节对源域与目标域样本在高层特征图上的统计特性进行了可视化分析，结果如图 4.4 所示。其中（a）（b）图为 Baseline 方法的特征统计分布，（c）（d）图为 CLEAR 方法的特征统计分布，（e）（f）为 MS-DE 方法的特征统计分布；其中左列展示特征均值统计分布，右列展示特征标准差统计分布。横轴表示标准化后的特征统计值，纵轴表示该统计值对应的概率密度，曲线之间的重叠程度能够反映源域与目标域在特征统计层面的接近程度。

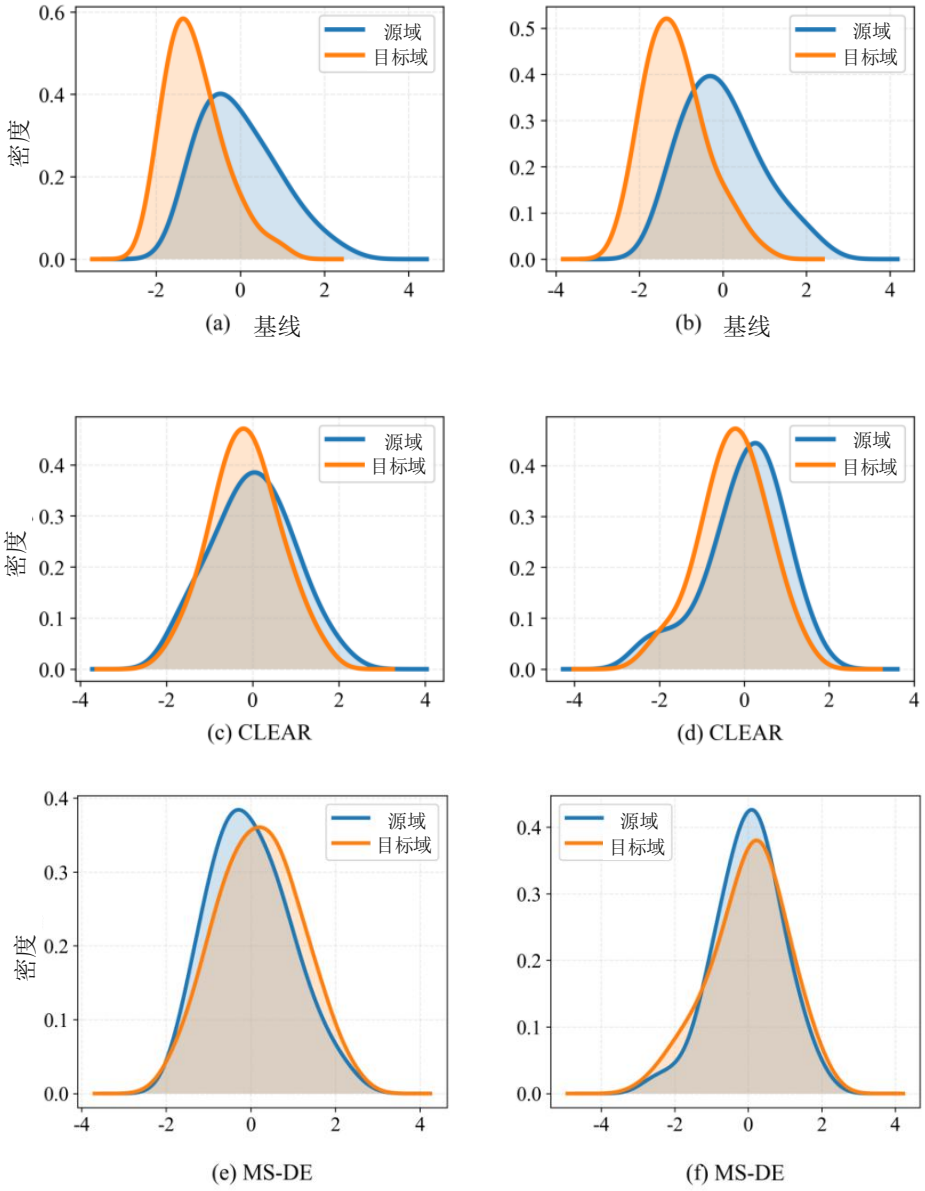


图 4.4 不同方法在源域与目标域上的高层特征统计分布结果

从 MS-DE 方法的可视化结果来看，相较于 Baseline 和 CLEAR，MS-DE 下源域与目标域在均值统计分布和标准差统计分布上均表现出更高的重叠度，主峰位

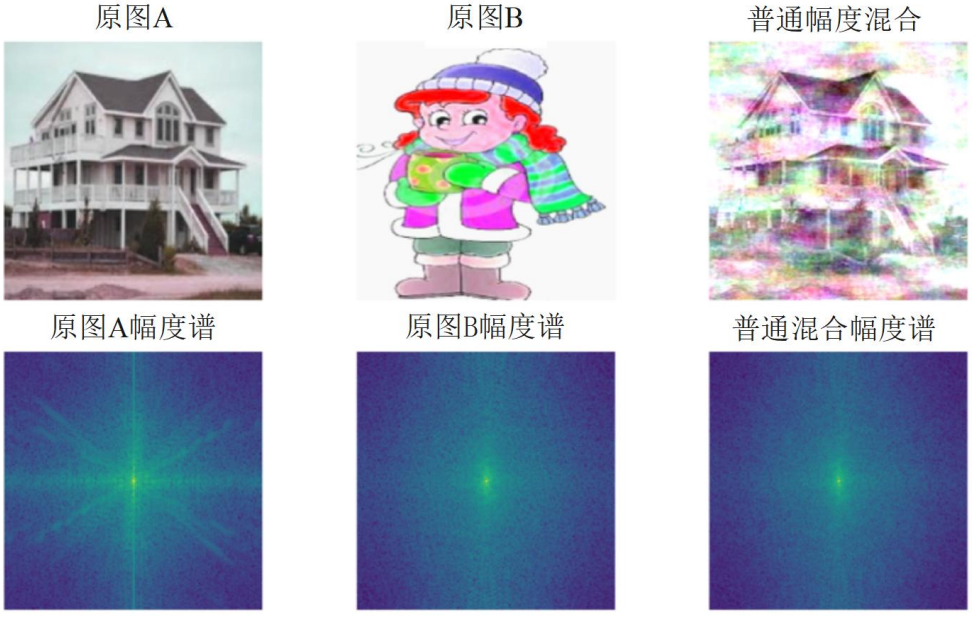
置更为接近，曲线形状也更加一致。这表明本章方法能够更有效地减小源域与目标域之间的高层特征统计偏移，使不同域样本在特征均值水平和波动范围上都趋于一致。其结果说明，通过输入层频率自适应增强、特征层域敏感通道重标定以及表示层对抗性表示解耦的协同作用，MS-DE 能够更充分地削弱域特定因素对特征表示的影响，提升跨域表征的一致性和稳定性。

综合图 4.4 可以看出，随着方法由 Baseline 发展到 CLEAR，再到 MS-DE，源域与目标域在高层特征统计分布上的差异逐步减小。其中，本章所提出的 MS-DE 方法在均值统计和标准差统计两个维度上都表现出更优的分布对齐效果，说明其不仅能够降低跨域场景下特征响应中心位置的偏移，还能够有效缓解特征内部波动模式的不一致性。这一结果从特征统计分布层面验证了本章方法在跨域稳健表征学习方面的有效性，也为其在未知目标域上的性能提升提供了直观支撑。

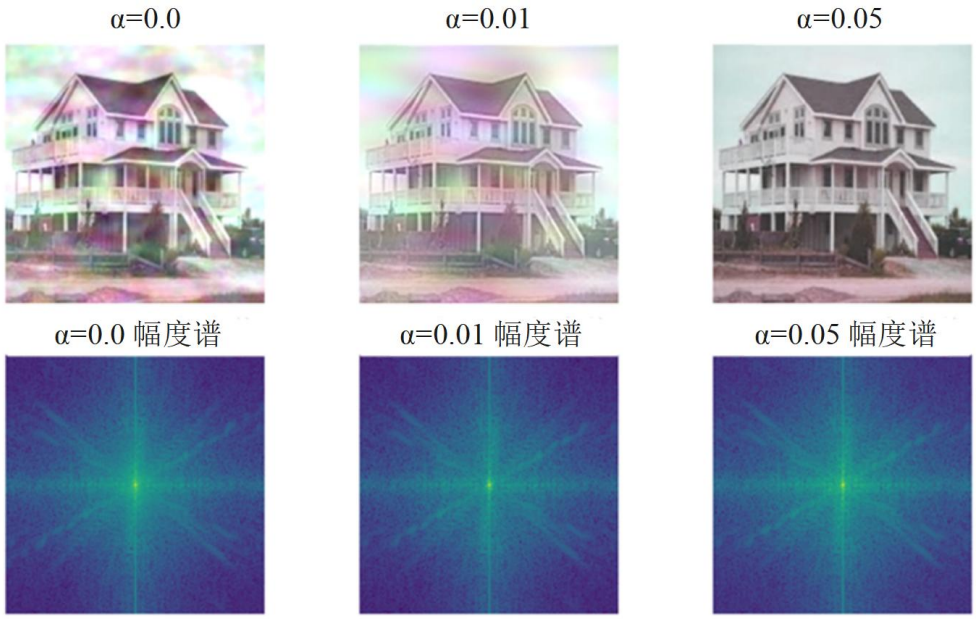
4.3.6 参数敏感性分析

4.3.6.1 频率自适应参数敏感性分析

为进一步分析输入层频率增强模块中阈值比例系数α对增强结果的影响，本节选取固定跨域样本对，在相同σ设置下，对不同α取值对应的增强图像及其幅度谱进行了可视化比较，如图 4.5 所示。根据第四章输入层设计，α主要用于对风格图像的幅度谱进行软阈值处理，其取值越大，被抑制的弱频率分量越多，因而能够直接调节风格注入强度。



(a) 原图增强效果与幅度谱



(b) 不同参数下增强效果与幅度谱

图 4.5　不同参数下频率自适应效果比较

从图中可以看出，普通幅度混合虽然能够较为直接地引入另一域的风格统计，但同时也更容易带来较强的外观扰动，使增强结果出现明显的纹理叠加和结构污染。相比之下，在引入软阈值后，增强图像的风格扩展过程更加平滑。当$\alpha = 0.00$时，增强结果与普通混合较为接近，说明此时风格图像的频率成分保留较多，域风格注入更强；随着α增大到 0.01 和 0.05，增强图像中由第二域引入的外观扰动逐渐减弱，效果也越来越不明显。

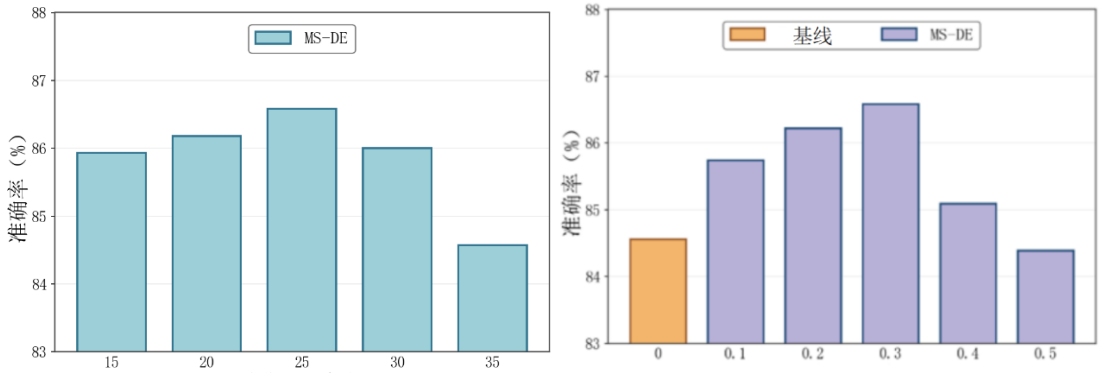
该结果说明，α能够有效控制输入层风格扩展与语义保持之间的平衡：较小取值有利于增强风格扰动的丰富性，而较大取值则更强调主体结构的稳定保留。因此，选择适中的α有助于在不破坏原始语义信息的前提下，引入更加合理的跨域风格变化，从而为后续特征层和表示层学习提供更加丰富且稳定的输入分布。

4.3.6.2　高斯掩膜宽度与重标定强度分析

为了验证输入层频率自适应增强和特征层域敏感通道重标定模块的鲁棒性，本节对高斯频率掩膜宽度σ和重标定强度γ进行了参数敏感性实验，如图 4.5 所示。图中柱状图展示了在 PACS 数据集 ResNet-18 主干网络上，不同参数取值下模型的平均分类准确率。

超参数 σ 控制着进行振幅混合的低频分量的带宽。如图 4.6(a)所示，随着 σ 增大，模型性能呈现先升后降的趋势：当 σ 较小（σ=15）时，低频风格信息混合有限，增强效果不足，分类准确率偏低；随着 σ 增大至 25，更多低频风格扰动被合理引入，同时高频语义保持较好，模型性能达到最高；当 σ 进一步增大到 35 时，准确率开始出现下降，因为过大的 σ 会将混合扩展到更高频的频段，这不可避免

地破坏了保留在相位谱中的语义结构信息。因此，σ=25 在实现风格多样化和保持语义完整性之间取得了最佳平衡。



(a) 高斯掩膜宽度　　(b) 重标定强度

图 4.5　参数敏感性分析

参数γ决定了在训练期间被识别为域相关通道并受到抑制的通道比例。我们在（0.0, 0.1, 0.2, 0.3, 0.4, 0.5）的范围内对γ进行调整。其中$\gamma = 0$时作为 Baseline，相当于不进行域敏感通道重标定，模型对环境相关特征依赖较强，准确率较低；随着γ增大至 0.3，域相关通道得到适度削弱，优势判别通道被保留，准确率达到峰值；若γ继续增大，部分判别信息可能被过度削弱，性能出现下降趋势，甚至在$\gamma = 0.5$时准确率降至 Baseline 以下。该结果验证了连续重标定策略在降低域敏感响应同时保持判别信息方面的有效性。

4.4　本章小结

本章针对复杂环境中输入风格变化丰富、深层特征易受域相关因素影响以及高层表示成分耦合的问题，提出了基于多阶段分层表示建模的域泛化方法 MS-DE。该方法在第三章域敏感特征抑制思想的基础上，进一步从输入扰动、特征调制和表示解耦三个层面分层表示建模模型表示，使模型能够在更复杂的分布变化下学习更加稳定的判别信息。

实验结果表明，MS-DE 在 PACS、OfficeHome 和 VLCS 三个数据集上均取得了稳定提升，在 ResNet-18 和 ResNet-50 两种主干网络设置下均优于 Baseline 和 CLEAR。消融实验进一步说明，频率自适应傅里叶增强、域敏感通道重标定和对抗性表示解耦三个模块均对模型性能提升具有贡献，三者结合后能够获得更好的整体效果。此外，可视化分析和特征统计分布结果表明，MS-DE 能够扩展训练样本的风格覆盖范围，降低高层特征对环境相关信息的敏感性，并改善源域与目标域之间的特征分布一致性。综上，本章方法在第三章特征层鲁棒建模的基础上，进一步提升了模型对复杂未知域变化的适应能力，也为第五章开展高性能域泛化模型的轻量化迁移提供了教师模型基础。

第五章　面向边缘部署的域泛化模型轻量化方法研究

5.1　引言

前两章方法分别从域敏感特征抑制和多阶段分层表示建模两个角度提升了模型在未知目标域上的泛化能力。然而，从实际部署角度看，高性能域泛化模型通常依赖较强的主干网络和较复杂的表示建模过程，虽然能够获得较好的跨域识别效果，但其参数规模、存储开销和推理成本也相对较高。对于无人系统等边缘智能感知平台而言，仅提升模型准确率并不足以满足实际应用需求，模型还需要具备较低的计算复杂度和较好的实时推理能力。

基于此，本章不再继续追求更高容量的域泛化模型，而是进一步研究高性能模型向轻量化模型的知识迁移问题。具体而言，本文以第四章提出的高性能域泛化模型作为教师模型，以轻量化网络作为学生模型，通过跨头知识蒸馏将教师模型中较稳定的高层判别知识迁移至学生模型。该方法的目标是在尽量保持学生模型低复杂度优势的同时，缩小轻量模型与高性能教师模型之间的性能差距，从而提升其在资源受限场景下的部署可行性。

围绕这一目标，知识蒸馏为高性能模型向轻量化模型的迁移提供了一条较为可行的技术路径。知识蒸馏通过构建教师—学生训练框架，将高容量教师模型中蕴含的判别知识迁移到参数规模更小、推理成本更低的学生模型中，使学生模型在保持轻量化结构的同时获得更强的任务表征能力。对于本文所研究的域泛化问题而言，蒸馏的意义不仅在于压缩模型规模，更在于将前述章节中已经学习到的跨域稳定判别知识迁移到更适合低复杂度推理的学生网络中，从而提高轻量模型在未知目标域上的识别能力。

尽管如此，现有知识蒸馏方法直接应用于本任务时仍存在一定局限。传统的输出蒸馏主要依赖教师模型最终预测分布对学生进行监督，虽然实现简单，但其传递的信息相对粗粒度，难以充分体现教师模型在跨域场景下形成的高层判别结构；而基于中间特征的蒸馏虽然能够提供更丰富的监督信号，但当教师模型与学生模型在网络深度、特征维度和表示能力上存在较大差异时，直接对齐中间表示往往会引入额外映射负担，甚至可能削弱学生模型自身的特征适配能力。更进一步地，在轻量化学生模型训练过程中，真实标签监督与教师蒸馏监督之间还可能存在优化方向不一致的问题，即学生一方面需要拟合当前任务目标，另一方面又需要模仿教师模型的判别行为，二者若缺乏有效协调，容易限制蒸馏效果的进一步发挥。

针对上述问题，本章在前述高性能域泛化模型研究基础上，提出一种面向边缘部署的轻量化知识迁移方法。该方法以高性能教师模型为知识源，以轻量化学生网络为部署主体，不直接将蒸馏约束施加于学生模型最终输出，而是将学生任务头中

的中间表示送入教师任务头后续层，构造跨头预测分支，并以此建立蒸馏监督。通过这种方式，可以在不改变学生模型推理结构的前提下，将蒸馏约束作用于更接近高层判别空间的位置，从而在一定程度上缓解原始任务监督与蒸馏监督之间的冲突，提升学生模型对教师高层判别知识的吸收效率。相较于单纯对齐最终输出或直接匹配中间特征，这种跨头知识蒸馏方式更符合本章“低复杂度保留已有跨域判别能力”的研究目标。

5.2 方法设计

5.2.1 总体框架介绍

受 CrossKD 思想启发，本文将跨头蒸馏机制从原有任务场景迁移到域泛化分类与边缘轻量化部署问题中，并结合第四章训练得到的高性能域泛化模型构建教师—学生迁移框架，如图 5.1 所示。该框架以第四章训练得到的高性能域泛化模型作为教师模型，以轻量化网络作为学生模型。其中，教师模型采用 ResNet-50 作为主干网络，用于在训练阶段提供高层判别监督；学生模型采用 ResNet-18 作为主干网络，是本文轻量化迁移框架中的推理主体。训练完成后，仅保留学生模型进行推理，教师模型和跨头蒸馏分支均不参与推理过程。

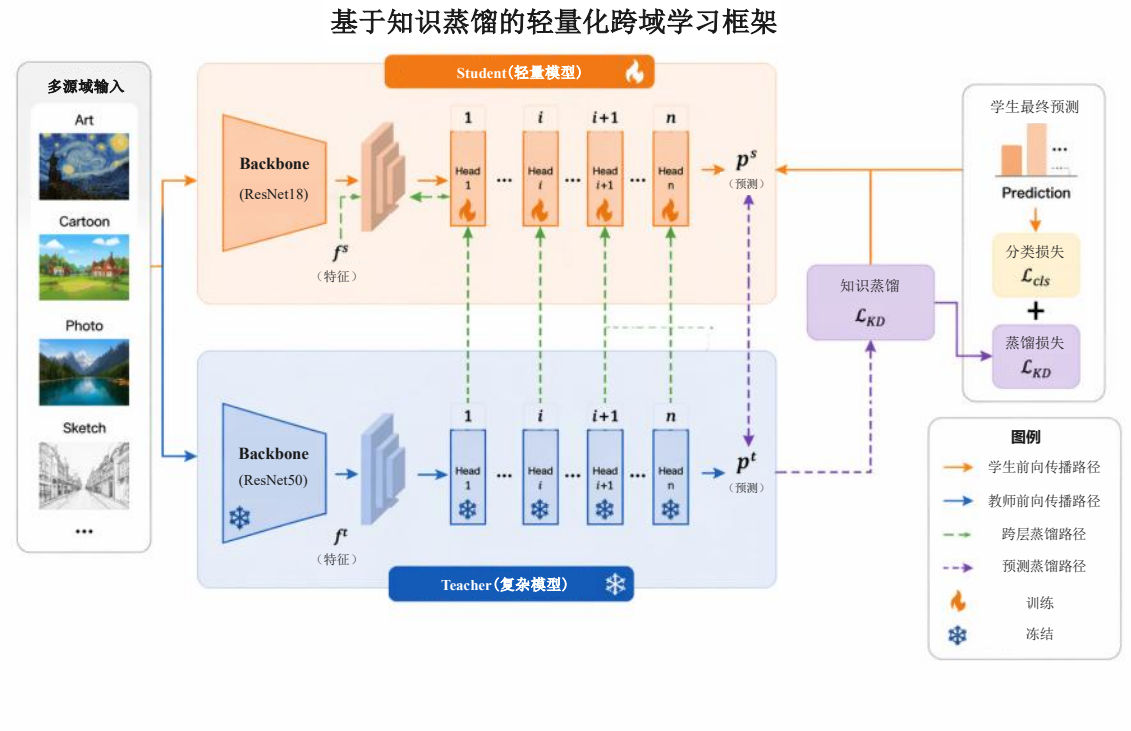


图 5.1 基于知识蒸馏的轻量化跨域学习框架

对于来自多个源域的输入样本，教师分支和学生分支在训练阶段同时进行前向传播。学生分支输出类别预测，并与真实标签计算分类损失，以保证学生模型具

备基本任务学习能力；教师分支输出教师预测结果，用于提供蒸馏监督。在此基础上，本章进一步构造跨头蒸馏路径，将学生任务头中的中间表示输入教师任务头的后续层，生成跨头预测结果，并以其与教师预测之间的差异构建蒸馏损失。

从整体流程上看，该框架包括三部分：学生分类分支、教师监督分支和跨头蒸馏分支。训练阶段，教师模型参数保持冻结，学生模型在分类损失和蒸馏损失的共同约束下更新；推理阶段，仅保留学生模型完成前向计算，教师模型和跨头蒸馏分支均被移除。因此，该框架能够在不改变学生推理结构的前提下，将教师模型的判别能力迁移到轻量学生模型中。跨头预测的具体构造方式和损失函数将在下一节进一步介绍。

需要说明的是，本文并非直接复用 CrossKD 在目标检测任务中的原始形式，而是围绕域泛化分类任务进行了适配。原 CrossKD 主要面向目标检测模型，通过跨检测头预测缓解检测蒸馏中教师监督与真实标注之间的冲突；而本文关注的是目标域不可见条件下的轻量化分类模型训练，重点在于将高性能域泛化教师模型中较稳定的类别判别知识迁移到学生模型中。为此，本文将学生任务头的中间表示送入教师任务头后续层，生成跨头分类预测，并通过温度蒸馏损失与真实标签分类损失联合优化，使学生模型在保持源域分类能力的同时吸收教师模型的跨域判别知识。推理阶段仅保留学生模型，教师模型及跨头蒸馏分支均不参与计算，因此不会增加边缘部署时的额外开销。

5.2.2 基于跨头知识蒸馏的轻量化迁移方法

在轻量化知识蒸馏任务中，传统蒸馏方法通常主要包括两类思路：一类是基于最终输出分布的蒸馏方法，即直接约束学生模型最终预测去拟合教师模型的输出分布；另一类是基于中间特征对齐的蒸馏方法，即通过显式约束教师与学生在隐藏层特征上的一致性来实现知识迁移。前者实现简单、任务关联性较强，但由于蒸馏监督仅作用于最终输出层，所传递的信息相对粗粒度，难以充分刻画教师模型在跨域识别过程中形成的高层判别结构；后者虽然能够提供更加丰富的中间监督，但在教师与学生结构存在差异、尤其学生模型容量受限的情况下，直接进行特征对齐往往会引入额外的适配负担，甚至可能限制学生模型自身表征能力的形成。

针对上述问题，本章提出一种基于跨头知识蒸馏的轻量化迁移方法（Cross-Head Knowledge Distillation, CHKD）。该方法并不直接约束学生最终预测去逼近教师最终预测，也不强制要求教师与学生的中间特征逐层严格对齐，而是将学生任务头中间阶段的表示送入教师任务头的后续层中，生成跨头预测结果，并以此构造蒸馏监督。通过这种方式，蒸馏信号能够作用于更接近高层判别空间的位置，同时又避免直接干扰学生最终分类分支的正常优化，从而提高轻量学生模型对教师高层

判别知识的吸收效率。

设输入样本为x，其真实类别标签为y。学生主干网络与教师主干网络分别记为$B_s(\cdot)$和$B_t(\cdot)$。对于同一样本，学生与教师提取到的高层特征可分别表示为：

$$f^s = B_s(x), \qquad f^t = B_t(x) \tag{5.1}$$

随后，学生特征f^s和教师特征f^t分别输入各自的任务头中，得到学生最终预测p^s与教师最终预测p^t。为便于描述，设学生任务头和教师任务头均由n个顺序堆叠的映射层组成，分别记为：

$$\{H_1^s, H_2^s, \dots, H_n^s\}, \qquad \{H_1^t, H_2^t, \dots, H_n^t\} \tag{5.2}$$

其中，前$n-1$层负责逐步完成高层表示变换，第n层输出最终类别预测。于是，学生和教师模型的常规前向传播过程可以表示为：

$$z_1^s = H_1^s(f^s), z_2^s = H_2^s(z_1^s), \dots, z_{n-1}^s = H_{n-1}^s(z_{n-2}^s) \tag{5.3}$$

$$z_1^t = H_1^t(f^t), z_2^t = H_2^t(z_1^t), \dots, z_{n-1}^t = H_{n-1}^t(z_{n-2}^t) \tag{5.4}$$

两者的最终预测为：

$$p^s = H_n^s(z_{n-1}^s) \tag{5.5}$$

$$p^t = H_n^t(z_{n-1}^t) \tag{5.6}$$

在传统知识蒸馏中，通常直接对学生最终预测p^s与教师最终预测p^t进行分布匹配，即将蒸馏约束直接施加在最终输出层上。然而在本文场景下，学生模型除了要拟合真实标签外，还需尽可能继承教师模型已经学习到的跨域判别知识。若蒸馏监督直接作用于学生最终输出，则学生分类头同时受到真实标签监督与教师预测监督的共同影响，容易造成两种优化信号在输出层互相冲突，使学生模型在轻量结构约束下难以充分学习到更稳定的判别模式。为缓解这一问题，本方法不直接使用p^s参与蒸馏，而是在学生任务头内部选择一个中间层位置i，提取其中间表示z_i^s，并将其送入教师任务头的后续层$\{H_{i+1}^t, \dots, H_n^t\}$中继续传播，生成跨头预测结果$p^s$。具体而言，对于给定的蒸馏位置$i \in \{1,2,\dots,n-1\}$，跨头预测定义为：

$$\tilde{p}^s = H_n^t\Big(H_{n-1}^t(\cdots H_{i+1}^t(z_i^s)\cdots)\Big), \qquad z_i^t, z_i^t \in \mathbb{R}^{d_i} \tag{5.7}$$

其中，d_i表示第i层任务头的输入维度。该式表明，跨头预测$\tilde{p}^s$的输入来自学生任务头的中间表示，但其后续映射过程由教师任务头的高层部分完成。因此，$\tilde{p}^s$在信息来源上保留了学生模型当前已学习到的中间表征，而在判别映射方式上又部分继承了教师模型的高层决策结构。相比直接令p^s去逼近p^t，这种做法使蒸馏过程不再完全依赖学生最终分类层，从而在一定程度上降低了最终输出层上监督冲突的影响，同时增强了蒸馏过程的任务导向性。

在获得跨头预测$\tilde{p}^s$后，本章以其与教师预测p^t之间的差异作为蒸馏约束。考虑到教师输出与跨头输出均可视为类别概率分布，因此本章采用温度缩放后的softmax 分布来构造蒸馏目标。设温度系数为τ，则教师软标签分布q_k^t和跨头预测分

布q_k^s分别为：

$$q_k^t = \frac{\exp\left(\frac{p_k^t}{\tau}\right)}{\Sigma_{j=1}^{C}\exp\left(\frac{p_j^t}{\tau}\right)}, \quad q_k^s = \frac{\exp\left(\frac{p_k^s}{\tau}\right)}{\Sigma_{j=1}^{C}\exp\left(\frac{p_j^s}{\tau}\right)} \tag{5.8}$$

其中，C表示类别数，k表示第k个类别。基于此，蒸馏损失定义为教师软标签分布与跨头预测分布之间的 Kullback-Leibler 散度：

$$\mathcal{L}_{KD} = \tau^2 \sum_{k=1}^{C} q_k^t \log \frac{q_k^t}{q_k^s} \tag{5.9}$$

其中，前面的τ^2为温度缩放带来的标准补偿项，用于保持不同温度下梯度尺度的相对稳定。

除了蒸馏损失外，学生模型仍需通过真实标签监督完成基本分类学习。为此，本文保留学生最终预测p^s与真实标签y之间的分类损失，记为：

$$\mathcal{L}_{cls} = -\sum_{k=1}^{C} \mathrm{S}\,(y = k) \log \sigma(p_k^s) \tag{5.10}$$

其中，$\sigma(\cdot)$表示 softmax 函数，S(·)为示性函数。当样本标签为第k类时，其取值为 1，否则为 0。综合上述两部分监督，本方法的总优化目标定义为：

$$\mathcal{L} = \mathcal{L}_{cls} + \lambda_{KD}\mathcal{L}_{KD} \tag{5.11}$$

其中，λ_{KD}为蒸馏损失权重，用于平衡真实标签监督与教师知识监督之间的作用强度。通过该联合目标，学生模型一方面能够保持对当前任务目标的学习能力，另一方面能够通过跨头蒸馏路径更有效地吸收教师模型中蕴含的高层判别知识。

学生模型前部表示既可以从真实标签监督中学习任务相关信息，又可以通过教师后续任务头获得更加接近高层判别空间的蒸馏指导，从而提高知识迁移效率。推理阶段仅保留学生模型本身，教师模型及跨头蒸馏路径均不参与测试，因此不会带来额外的在线推理开销。这也使得该方法较好地满足了边缘部署场景对低复杂度和高效率的要求。

需要说明的是，虽然学生主干网络与教师主干网络分别采用 ResNet-18 和 ResNet-50，二者主干输出维度不同，但本文在任务头设计中采用相同的隐藏维度。学生特征f^s和教师特征f^t分别经过各自任务头前端映射后，得到维度一致的中间表示。因此，当蒸馏位置i位于任务头内部时，学生中间表示z_i^s与教师任务头后续层的输入维度保持一致，可以直接送入$\{H_{i+1}^t, \ldots, H_n^t\}$生成跨头预测。该跨头路径仅用于训练阶段，推理阶段不参与计算。

5.3 实验结果与分析

5.3.1 实验设置

本节实验基于第四章中训练得到的域泛化模型，旨在评估通过跨头知识蒸馏方法对学生模型性能提升的有效性。教师模型与学生模型的主干网络分别采用 ResNet-50 和 ResNet-18 结构，任务头结构保持一致，确保蒸馏实验中学生模型能够充分接受教师模型的高层判别信息。

训练过程中，学生模型在与第四章相同的数据集划分和留一域策略下进行训练，保持与第三章实验的可比性。源域的数据作为训练集，留出的域作为目标域进行测试。训练批量大小设置为 64，初始学习率为 0.002，优化器采用 Adam 训练周期与第四章保持一致，以便公平对比蒸馏前后的模型性能。为保证实验结果的统计可靠性，所有实验均采用不同随机种子重复 3 次，最终报告的结果为 3 次独立实验的平均值。

在跨头知识蒸馏中，学生任务头的中间表示被送入教师任务头的后续层，构造跨头预测分支以计算蒸馏损失。蒸馏损失权重λ_{KD}和蒸馏层位置i是关键超参数，分别控制蒸馏信号强度和中间特征的选择位置。基于超参数实验结果，本文将λ_{KD}设置为 0.8，将蒸馏层位置设置为$i = 3$，作为后续实验的默认配置。实验采用 Top-1 分类准确率作为评价指标，并遵循留一域评估策略，分别报告不同目标域设置下的平均准确率。所有实验均基于 PyTorch 2.2.1 框架实现，在搭载 NVIDIA GeForce RTX 3090 显卡的 Linux 服务器上完成。

5.3.2 蒸馏层位置分析

在跨头知识蒸馏过程中，学生任务头中选择哪一层的中间表示作为蒸馏输入，对于最终学生模型性能具有重要影响。若选择过浅的中间层，学生模型大部分参数仍然主要受到原始任务损失约束，蒸馏信号无法充分渗透；若选择过深的中间层，则蒸馏过程退化为传统预测模仿，可能再次引入真实监督与蒸馏监督之间的冲突。为探索最佳蒸馏层位置，本实验在学生任务头的不同中间层i处构造跨头预测分支，并测量在目标域上的性能变化。

表 5.1 展示了不同蒸馏层位置下学生模型在 PACS 数据集上的 Top-1 平均准确率。可以观察到，靠后的中间层通常能够在保持学生任务头末端对原始目标的拟合能力的同时，充分接收教师高层判别信息，从而实现最佳性能提升；而过浅或过深的蒸馏位置性能略低，验证了中间层选择对蒸馏效果的重要性。

表 5.1 不同蒸馏层位置下学生模型准确率

蒸馏层位置	Art	Cartoon	Photo	Sketch	平均
第一层	83.52±0.60	81.75±0.57	97.27±0.32	83.54±0.67	86.52
第二层	86.49±0.51	82.49±0.67	97.01±0.23	84.91±0.63	87.73
第三层	86.66±0.43	82.86±0.34	97.72±0.25	85.68±0.51	88.23
第四层	85.16±0.58	81.96±0.67	97.90±0.16	84.93±0.60	87.49

5.3.3 对比实验

为验证跨头知识蒸馏方法在轻量化学生模型上的有效性，本节以第四章提出的 MS-DE 框架为基础开展对比实验。其中，以 ResNet-50 为主干网络的完整 MS-DE 模型作为教师模型，以 ResNet-18 为主干网络且未引入知识蒸馏的 MS-DE 模型作为学生基线模型，记为 MS-DE w/o KD。在此基础上，进一步将本文方法与 PKD、FGD 等典型知识蒸馏方法进行比较，以分析不同蒸馏策略对轻量学生模型泛化性能的影响。实验仍采用 PACS 数据集的留一域评估策略，各学生模型均使用相同的 ResNet-18 主干网络和训练协议，从而保证对比公平性。对于原本面向检测任务的 PKD（Pearson Correlation Coefficient）[108]和 FGD（Focal and Global Knowledge Distillation）[109]，本文仅保留其通用特征蒸馏思想，并将其作用于分类网络高层特征/任务头输出，以保证与本文分类任务设置一致。

表 5.2 PACS 上不同方法对比实验

方法	Art	Cartoon	Photo	Sketch	平均
教师模型	88.86±0.56	84.75±0.63	97.87±0.14	87.47±0.55	89.73
MS-DE w/o KD	84.36±0.48	81.92±0.61	96.40±0.23	83.30±0.43	86.50
MS-DE w/ PKD	85.73±0.61	81.84±0.66	97.31±0.34	84.89±0.53	87.44
MS-DE w/ FGD	85.12±0.59	82.17±0.71	97.43±0.12	86.44±0.64	87.79
MS-DE w/ CHKD	86.66±0.43	82.86±0.34	97.72±0.25	85.68±0.51	88.23

从表 5.2 可以看出，以 ResNet-50 为主干网络的教师模型取得了最高的平均准确率，说明较大容量模型在跨域特征表达和高层判别建模方面具有更强能力，能够为轻量化学生模型提供有效的知识来源。相比之下，未引入知识蒸馏的 ResNet-18 学生模型平均准确率为 86.50%，与教师模型仍存在一定差距，说明在轻量化结构下，学生模型的表征能力和跨域判别能力受到限制，难以仅依靠原始监督训练达到教师模型的性能水平。尤其在 Art、Cartoon 和 Sketch 等风格差异较明显的目标域上，学生模型与教师模型之间的差距更加突出，表明轻量模型在复杂域偏移条件下更容易受到外观风格和背景因素的影响。

引入知识蒸馏后，学生模型整体性能均有所提升。其中，本文提出的 CHKD

方法取得了 88.23%的平均准确率，相比未蒸馏学生模型提升 1.73 个百分点，并优于 PKD 和 FGD 两种对比蒸馏方法，说明跨头蒸馏能够更有效地促进教师模型高层判别知识向学生模型迁移。从各目标域结果来看，CHKD 在 Art、Cartoon 和 Photo 域上均取得蒸馏方法中的较优结果，在 Sketch 域上虽略低于 FGD，但整体平均性能仍最高，表明其在不同域偏移条件下具有较好的综合表现。其原因在于，跨头蒸馏并非直接约束学生最终输出，而是将学生任务头的中间表示送入教师任务头后续层生成跨头预测，使学生模型能够在保持轻量化结构的同时学习教师模型的高层判别映射，从而缓解真实标签监督与蒸馏监督之间的潜在冲突，提升轻量学生模型的跨域泛化能力。

5.3.4 复杂度与部署代价分析

为验证所提方法在边缘部署场景下的应用价值，本节进一步对教师模型、蒸馏前学生模型和蒸馏后学生模型的复杂度与部署代价进行了分析，结果如表 5.3 所示。由于本文采用留一域评估策略，在 PACS 数据集上分别以 Art、Cartoon、Photo 和 Sketch 作为目标域训练得到四个模型，因此表 5.3 中的准确率和部署代价均按照四个目标域设置进行统计。其中，准确率为四个目标域测试结果的平均值；由于四个目标域设置下学生模型结构保持一致，因此参数量、FLOPs 和模型大小基本相同；推理时间受硬件调度和运行波动影响，本文报告四个模型多次测试后的平均结果。

综合参数量、FLOPs、模型大小和推理时间可以看出，教师模型虽然取得了最高的平均准确率 89.56%，但其参数量达到 124.277M，FLOPs 为 4.232G，模型大小为 474.54MB，单张图像推理时间为 155.679ms，部署代价较高。相比之下，学生模型的参数量仅为 17.495M，FLOPs 为 1.830G，模型大小为 66.86MB，推理时间约为 36ms，说明其在模型规模和推理效率方面更适合作为边缘端部署主体。

表 5.3 复杂度与部署代价

模型	参数量(M)	FLOPs (G)	大小(MB)	推理时间(ms/img)	平均
教师模型	124.277	4.232	474.54	137.427	89.73
MS-DE w/o KD	17.495	1.830	66.86	36.108	86.50
MS-DE w/ CHKD	17.495	1.830	66.86	36.251	88.23

进一步比较教师模型与学生模型可以发现，学生模型在参数量上相较教师模型降低了约 85.9%，FLOPs 降低了约 56.8%，模型存储开销降低了约 85.9%，推理时间缩短了 73.7%。这表明采用 ResNet-18 作为学生主干网络后，模型的部署代价得到了显著控制，能够更好地满足资源受限平台对轻量化和实时性的要求。在此基

础上，蒸馏后学生模型的平均准确率由 86.50%提升至 88.23%，提升了 1.73 个百分点，表明所提跨头知识蒸馏方法能够在基本不增加部署代价的前提下，有效增强轻量学生模型对教师判别知识的继承能力。

5.3.5 参数敏感性分析

为分析蒸馏损失权重对学生模型性能的影响，本文进一步对总损失函数中的蒸馏损失权重λ_{KD}进行参数敏感性实验。该参数用于平衡类别监督损失与蒸馏损失之间的相对重要性。当λ_{KD}取值较小时，模型训练过程主要受真实标签监督驱动，学生模型从教师模型中获得的软监督信息相对有限；当λ_{KD}取值过大时，蒸馏约束在优化目标中占比过高，可能削弱学生模型对真实类别标签的拟合能力，进而影响最终分类性能。因此，合理设置蒸馏损失权重对于跨头知识蒸馏方法的稳定训练具有重要影响。

图 5.2 给出了不同蒸馏损失权重下学生模型在 PACS 数据集上的平均准确率和标准差的变化情况，其中柱状图表示多次实验的平均准确率，误差棒表示标准差。可以看出，当λ_{KD}从 0.6 增大到 0.8 时，模型平均准确率逐步提升，说明适当增强蒸馏监督有助于学生模型更充分地吸收教师模型的高层判别知识。其中，当 $\lambda_{KD} = 0.8$时，模型取得最高平均准确率，表明此时真实标签监督与教师知识监督之间达到了较好的平衡。

当λ_{KD}继续增大至 0.9 和 1.0 时，模型性能开始下降。这说明过强的蒸馏约束可能使学生模型过度依赖教师模型输出，限制其对源域真实标签信息的自主学习能力，导致分类判别能力受到一定影响。尤其是在域泛化场景中，学生模型不仅需要模仿教师模型的预测分布，还需要保持对不同源域样本的有效拟合，因此蒸馏损失不宜在总损失中占据过高比例。

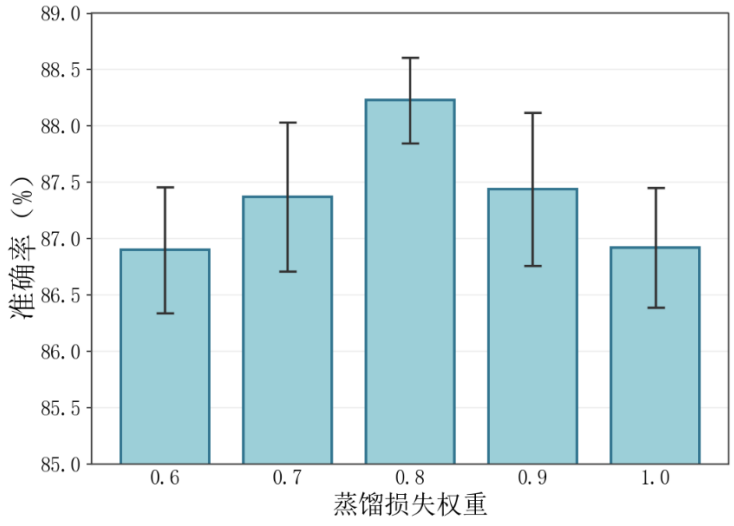


图 5.2 不同蒸馏损失权重下的模型准确率与标准差

综合来看，蒸馏损失权重对模型性能具有一定影响，但在 0.7 至 0.9 范围内整体表现较为稳定，说明本文方法对该参数具有一定鲁棒性。基于实验结果，本文在后续实验中将蒸馏损失权重设置为$\lambda_{KD} = 0.8$，以在教师知识迁移和学生模型自主判别学习之间取得较优平衡。

5.4 本章小结

本章面向资源受限条件下域泛化模型的部署需求，研究了高性能域泛化模型向轻量化学生模型的知识迁移问题，并提出了基于跨头知识蒸馏的轻量化方法。该方法将学生任务头的中间表示送入教师任务头后续层，生成跨头预测结果，并以此构建蒸馏约束，使学生模型能够在训练过程中吸收教师模型的高层判别知识。相较于原 CrossKD 面向目标检测任务的跨检测头蒸馏，本文将该思想适配到域泛化分类任务中，通过分类任务头内部的跨头预测与蒸馏约束，将高性能教师模型中的跨域判别知识迁移至轻量学生模型，并在推理阶段仅保留学生网络，从而兼顾未知域分类性能与边缘部署效率。

实验结果表明，蒸馏层位置会影响学生模型的知识吸收效果，其中任务头较深位置的跨头蒸馏能够取得更好的性能。与直接训练的轻量化学生模型以及常见蒸馏方法相比，本文方法能够进一步提升学生模型在未知目标域上的分类准确率。复杂度分析表明，该方法的蒸馏分支仅在训练阶段使用，推理阶段仍保持学生模型原有结构，因此能够在提升泛化性能的同时维持较低的部署开销。

综上，本章方法为高性能域泛化模型在边缘受限平台上的应用提供了一种有效的轻量化迁移方案，也与前两章的鲁棒特征建模和多阶段分层表示建模共同构成了面向受限场景的完整技术链路。

第六章　总结与展望

6.1　工作总结

本文围绕受限场景下无人系统智能感知面临的未知域泛化能力不足和边缘部署资源受限问题，开展了域泛化迁移与模型轻量化方法研究。与传统视觉识别任务不同，受限场景下的智能感知模型不仅需要在训练阶段无法访问目标域数据的条件下保持对未知环境的适应能力，还需要在部署阶段满足边缘平台对参数量、计算开销和推理效率的约束。针对上述问题，本文从鲁棒特征建模、多阶段分层表示建模和轻量化知识迁移三个层面展开研究，形成了由未知域鲁棒识别到边缘端高效部署的技术路线。全文主要研究工作总结如下。

（1）针对复杂环境中域间分布差异明显、域相关特征干扰较强以及跨域判别依据不稳定的问题，提出了基于多尺度注意力与推理一致性的域泛化方法。该方法从特征通道稳定性角度出发，认为深层特征中部分通道容易编码背景、纹理、风格等域相关信息，当测试环境发生变化时，这类通道可能产生异常响应，进而影响模型的分类决策。为此，本文设计了跨空间多尺度信息聚合注意力机制，辅助域鉴别器识别对域变化敏感的通道，并在训练过程中对其进行抑制，以减少环境相关信息对高层特征表示的干扰。同时，针对不同源域中同类样本判别依据容易发生漂移的问题，引入基于动量更新的推理一致性约束，通过维护跨批次的类别原型表示，增强同类样本在不同域中的推理一致性。实验结果表明，该方法在 PACS、OfficeHome 和 VLCS 等公开域泛化数据集上均取得了较好的分类性能。消融实验、参数敏感性分析、特征通道稳定性分析和 Grad-CAM 可视化结果进一步说明，所提方法能够有效降低模型对非稳健线索的依赖，使模型更加关注与类别相关的稳定判别信息，从而提升未知目标域下的识别鲁棒性。

（2）针对单一特征层约束难以充分应对复杂分布变化的问题，提出了基于多阶段分层表示建模的域泛化方法。第三章方法主要从特征通道层面对域敏感响应进行抑制，但在复杂开放环境中，域偏移往往同时存在于输入风格、深层特征响应以及高层表示结构等多个层面。为进一步提升模型对复杂域变化的适应能力，本文构建了输入层、特征层和表示层分层表示建模的 MS-DE 框架。在输入层，设计频率自适应傅里叶增强方法，通过对图像幅度谱进行自适应混合，扩展源域样本的风格分布，提高训练数据对未知外观变化的覆盖能力；在特征层，引入域敏感通道重标定机制，以连续权重调制方式削弱与域变化显著相关的通道响应，降低环境因素在深层特征中的残留；在表示层，设计对抗性表示解耦机制，将高层特征划分为优势特征分量和互补特征分量，促使模型进一步区分稳定判别成分与环境干扰成分。实验结果表明，MS-DE 在不同主干网络和多个基准数据集上均取得了稳定增益，

相较于 CLEAR 和其他对比方法有进一步提升。消融实验验证了三个模块的有效性，可视化分析和特征统计分布结果表明，该方法能够改善样本风格多样性、增强特征分布稳定性，并提升源域与目标域之间的特征一致性。

（3）针对高性能域泛化模型参数规模较大、推理开销较高、难以直接部署到边缘平台的问题，提出了基于跨头知识蒸馏的轻量化方法。前两项工作提升了模型在未知目标域上的泛化性能，但高性能模型通常依赖较强的主干网络和较复杂的表示建模过程，直接部署到资源受限平台仍存在困难。为此，本文以高性能域泛化模型作为教师模型，以轻量化网络作为学生模型，研究如何将教师模型中的稳定判别知识有效迁移至学生模型。不同于直接对齐教师和学生最终输出的传统蒸馏方式，本文提出跨头知识蒸馏策略，将学生任务头的中间表示送入教师任务头的后续层，生成跨头预测结果，并以其与教师输出之间的差异构建蒸馏约束。该设计能够在一定程度上缓解原始标签监督与教师监督之间的冲突，使学生模型更有效地吸收教师模型的高层判别知识。实验结果表明，跨头蒸馏能够提升轻量学生模型在未知目标域上的分类准确率，并在保持较低参数量和推理开销的同时缩小学生模型与教师模型之间的性能差距。复杂度分析进一步说明，该方法的蒸馏分支仅在训练阶段使用，推理阶段仍保留学生模型原有结构，因此具有较好的边缘部署适用性。

综上，本文针对受限场景下无人系统智能感知中的两类关键约束，即训练阶段目标域不可访问和部署阶段边缘资源受限，分别从特征约束、表示建模和知识迁移三个角度提出了相应方法。第一项工作重点解决域敏感通道干扰和跨域判别不稳定问题，为未知域鲁棒识别提供了特征层面的约束机制；第二项工作进一步将域泛化建模扩展到输入、特征和表示多个层级，增强了模型对复杂环境变化的适应能力；第三项工作面向工程部署需求，将高性能域泛化模型的判别能力迁移到轻量学生模型中，提高了模型在边缘平台上的应用可行性。相关研究构建了从鲁棒感知到轻量部署的完整技术链路，可为复杂环境下无人系统智能感知算法的设计与工程应用提供方法参考。

6.2 研究展望

尽管本文围绕受限场景下的域泛化迁移与轻量化方法开展了较为系统的研究，并从特征层鲁棒表示建模、多阶段分层表示建模以及面向边缘部署的轻量化知识迁移等方面取得了一定进展，但受研究条件、实验范围和任务设定的限制，相关工作仍有进一步深入和扩展的空间。结合当前复杂环境感知与边缘智能发展的实际需求，后续研究可重点从以下几个方面展开。

首先，面向更复杂开放环境的域泛化建模仍有待进一步加强。本文前两项工作主要围绕多源训练域到未知目标域的泛化问题展开，重点关注环境变化、成像风格差异和上下文扰动等因素对模型判别稳定性的影响。然而，真实场景中的分布变化

往往更为复杂，不仅表现为视觉风格偏移，还可能伴随类别分布变化、传感器退化、样本质量波动以及开放类别干扰等多种因素的叠加作用。在此条件下，仅依赖当前的静态多源训练范式，仍难以完全覆盖实际部署中的复杂情况。后续可进一步研究面向开放环境的域泛化建模方法，在更大范围的分布变化条件下增强模型对未知干扰的适应能力，例如结合开放集识别、不确定性估计、域外样本检测等机制，提升模型在复杂动态场景中的安全性与鲁棒性。

跨层级稳定表示建模机制仍可进一步深化。本文第四章从输入层、特征层和表示层出发，提出了多阶段分层表示建模方法，在复杂分布变化条件下增强了模型对稳定判别表示的提取能力。但从更深层次看，当前方法仍然主要基于经验性结构设计和模块分层表示建模，尚未对不同层级之间的信息传递关系、扰动传播机制以及稳定表示形成过程建立更系统的理论解释。未来可在两个方向上继续推进：一方面，可进一步研究输入扰动、特征响应和高层表示之间的耦合关系，探索更统一的跨层级表示优化框架；另一方面，也可结合因果表示学习、信息瓶颈理论或频域—空域协同建模等思想，从理论层面分析稳定判别信息在网络中的形成与保留机制，从而为多阶段分层表示建模方法提供更强的理论支撑。

此外，边缘部署场景下的模型—硬件分层表示建模值得进一步研究。本文的轻量化研究主要聚焦于模型层面的压缩与迁移问题，而在真实工程落地过程中，模型性能往往还受到硬件平台、推理框架、内存访问开销以及并行计算方式等多种因素影响。后续可进一步面向典型边缘设备，如嵌入式 GPU、无人平台处理单元或低功耗 AI 芯片，开展模型结构与硬件执行特性的分层表示建模研究，使轻量化方法不仅在理论复杂度上有效，也能够在真实平台上体现更显著的部署优势。

综上所述，受限场景下的域泛化迁移与轻量化研究仍处于持续发展阶段。未来需要在更复杂环境适应、更深层表示机制建模以及面向真实平台的系统级部署优化等方面继续推进。随着深度学习模型、基础模型和边缘智能技术的不断发展，如何在保证模型泛化鲁棒性的同时实现高效、可靠和可落地部署，将成为该方向长期而重要的研究课题。

致　谢

时光荏苒，转眼间硕士阶段的学习与科研工作已接近尾声。回顾这段求学经历，从课程学习到课题研究，从论文撰写到毕业完成，这一路上凝聚了许多老师、同学、亲友的关心、帮助与支持。值此论文完成之际，谨向所有在我求学和成长过程中给予指导、帮助与鼓励的人致以诚挚的感谢。

首先，我要衷心感谢我的导师项凤涛老师。在整个研究生阶段，导师在学术研究、课题推进和论文写作等方面都给予了我悉心指导与严格要求。无论是研究方向的确定、技术路线的设计，还是论文框架的构建与细节修改，导师都倾注了大量心血。导师严谨求实的治学态度、开阔深刻的学术视野以及认真负责的工作作风，使我受益匪浅，也将成为我今后学习和工作中不断努力的榜样。

其次，感谢课题组各位老师在学习和科研过程中给予我的帮助与指导。各位老师在专业知识、科研思维和工程实践方面给予了我许多宝贵建议，使我能够不断完善自己的研究工作。感谢学院各位任课老师在研究生阶段的悉心授课与培养，你们扎实的学术功底和认真负责的教学态度，为我后续开展研究工作奠定了坚实基础。

感谢实验室和课题组的各位同学。与你们一起学习、讨论和交流，是我研究生阶段一段十分珍贵的经历。在课题推进、实验调试、论文修改以及日常生活中，大家给予了我许多支持与帮助。正是因为有你们的陪伴与鼓励，科研道路上的困难与压力才得以不断克服，这段共同奋斗的时光也将成为我难忘的回忆。

感谢我的家人。感谢你们始终如一的理解、包容和支持。在我求学成长的每一个阶段，你们都给予我最坚定的信任和最温暖的依靠。无论我遇到怎样的困难与挫折，你们始终是我最坚实的后盾。正是因为有你们默默无闻的付出，我才能够心无旁骛地完成学业和论文写作。

最后，感谢在研究生阶段所有给予我关心、帮助和支持的领导、老师、同学和朋友。你们的帮助与鼓励都让我铭记于心。未来无论身处何地，我都将以更加严谨的态度、更加踏实的作风不断前行，不负师长教诲，不负青春韶华。

谨以此文，向所有关心、帮助和支持过我的人致以最诚挚的谢意。

参考文献

[1] Gretton A, Borgwardt K M, Rasch M J, et al. A kernel two-sample test[J]. The Journal of Machine Learning Research, 2012, 13(1): 723-773.

[2] Li H, Pan S J, Wang S, et al. Domain generalization with adversarial feature learning[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 5400-5409.

[3] Huang Z, Wang H, Xing E P, et al. Self-challenging Improves Cross-Domain Generalization[M]. Vedaldi A, Bischof H, Brox T, et al. Computer Vision – ECCV 2020: Vol. 12347. Cham: Springer International Publishing, 2020: 124-140.

[4] Zhang H, Cisse M, Dauphin Y N, et al. mixup: Beyond Empirical Risk Minimization[J/OL]. https://arxiv.org/abs/1710.09412, 2017-10-25/2026-04-20.

[5] Hendrycks D, Mu N, Cubuk E D, et al. Augmix: A simple data processing method to improve robustness and uncertainty[J/OL]. https://arxiv.org/abs/1912.02781, 2019-12-05/2026-04-20.

[6] Xu Q, Zhang R, Zhang Y, et al. A fourier-based framework for domain generalization[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 14383-14392.

[7] Zhou K, Yang Y, Qiao Y, et al. Domain Generalization with MixStyle[J/OL]. https://arxiv.org/abs/2104.02008, 2021-04-05/2026-04-20.

[8] Arjovsky M, Bottou L, Gulrajani I, et al. Invariant Risk Minimization[J/OL]. https://arxiv.org/abs/1907.02893, 2019-07-05/2026-04-20.

[9] Rame A, Dancette C, Cord M. Fishr: Invariant gradient variances for out-of-distribution generalization[C]. International Conference on Machine Learning. PMLR, 2022: 18347-18377.

[10]Zhang X, Cui P, Xu R, et al. Deep stable learning for out-of-distribution generalization[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 5372-5382.

[11]Blanchard G, Lee G, Scott C. Generalizing from several related classification tasks to a new unlabeled sample[J]. Advances in neural information processing systems, 2011, 24(1): 1-9.

[12]Muandet K, Balduzzi D, Schölkopf B. Domain generalization via invariant feature representation[C]. International conference on machine learning. PMLR, 2013: 10-18.

[13]Deshmukh A A, Lei Y, Sharma S, et al. A Generalization Error Bound for Multi-class Domain Generalization[J/OL]. https://arxiv.org/abs/1905.10392, 2019-05-24/2026-04-20.

[14]Blanchard G, Deshmukh A A, Dogan U, et al. Domain generalization by

marginal transfer learning[J]. Journal of machine learning research, 2021, 22(2): 1-55.

[15]Li Y, Tian X, Gong M, et al. Deep domain generalization via conditional invariant adversarial networks[C]. Proceedings of the European conference on computer vision (ECCV). 2018: 624-639.

[16]Motiian S, Piccirilli M, Adjeroh D A, et al. Unified deep supervised domain adaptation and generalization[C]. Proceedings of the IEEE international conference on computer vision. 2017: 5715-5725.

[17]Sicilia A, Zhao X, Hwang S J. Domain adversarial neural networks for domain generalization: When it works and how to improve[J]. Machine Learning, 2023, 112(7): 2685-2721.

[18]Dayal A, KB V, Cenkeramaddi L R, et al. MADG: margin-based adversarial learning for domain generalization[J]. Advances in Neural Information Processing Systems, 2023, 36(1): 58938-58952.

[19]Matsuura T, Harada T. Domain generalization using a mixture of multiple latent domains[C]. Proceedings of the AAAI conference on artificial intelligence. 2020: 11749-11756.

[20]Lin S, Li C T, Kot A C. Multi-domain adversarial feature generalization for person re-identification[J]. IEEE Transactions on Image Processing, 2020, 30(1): 1596-1607.

[21]Deng Z, Ding F, Dwork C, et al. Representation via Representations: Domain Generalization via Adversarially Learned Invariant Representations[J/OL]. https://arxiv.org/abs/2006.11478, 2020-06-20/2026-04-20.

[22]Akuzawa K, Iwasawa Y, Matsuo Y. Adversarial Invariant Feature Learning with Accuracy Constraint for Domain Generalization[M]. Brefeld U, Fromont E, Hotho A, et al. Machine Learning and Knowledge Discovery in Databases: Vol. 11907. Cham: Springer International Publishing, 2020: 315-331.

[23]Rahman M M, Fookes C, Baktashmotlagh M, et al. Correlation-aware adversarial domain adaptation and generalization[J]. Pattern Recognition, 2020, 100: 107124.

[24]Ghifary M, Kleijn W B, Zhang M, et al. Domain generalization for object recognition with multi-task autoencoders[C]. Proceedings of the IEEE international conference on computer vision. 2015: 2551-2559.

[25]倪云昊, 黄雷. 基于数据表示不变性的域泛化研究[J]. 图学学报, 2024, 45(4): 705.

[26]Guo J, Qi L, Shi Y. Domaindrop: Suppressing domain-sensitive channels for domain generalization[C]. Proceedings of the IEEE/CVF international conference on computer vision. 2023: 19114-19124.

[27]刘坤, 王丁, 王静凯, 等. 基于特征过滤与特征解耦的域泛化模型[J]. 浙江

大学学报(工学版), 2024, 58(03): 459-467.

[28]王云亭, 张金艺. 复杂天气条件下道路场景目标检测的域泛化[J]. 上海大学学报(自然科学版), 2025, 31(04): 704-718.

[29]Wei W, Li Z, Yan J, et al. Indirect alignment and relationships preservation for domain generalization[C]. Proceedings of the thirty-fourth international joint conference on artificial intelligence. 2025: 2054-2062.

[30]Zhang Y, Li M, Li R, et al. Exact feature distribution matching for arbitrary style transfer and domain generalization[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 8035-8045.

[31]Zhang C, Bengio S, Hardt M, et al. Understanding deep learning requires rethinking generalization[J/OL]. https://arxiv.org/abs/1611.03530, 2016-11-10/2026-04-20.

[32]Peng Q, Zheng C, Chen C. A dual-augmentor framework for domain generalization in 3d human pose estimation[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 2240-2249.

[33]Cho J, Nam G, Kim S, et al. Promptstyler: Prompt-driven style generation for source-free domain generalization[C]. Proceedings of the IEEE/CVF international conference on computer vision. 2023: 15702-15712.

[34]Lee S, Bae J, Kim H Y. Decompose, adjust, compose: Effective normalization by playing with frequency for domain generalization[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 11776-11785.

[35]Gokhale T, Anirudh R, Thiagarajan J J, et al. Improving diversity with adversarially learned transformations for domain generalization[C]. Proceedings of the IEEE/CVF winter conference on applications of computer vision. 2023: 434-443.

[36]Wang J, Ren H, Shen C, et al. Multi-scale style generative and adversarial contrastive networks for single domain generalization fault diagnosis[J]. Reliability Engineering & System Safety, 2024, 243: 109879.

[37]Fu Y, Xie Y, Fu Y, et al. Styleadv: Meta style adversarial training for cross-domain few-shot learning[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 24575-24584.

[38]Keskes M. Generative adversarial networks for synthetic data generation in deep learning applications[J]. Journal of Artificial Intelligence Research and Innovation, 2025, 1(1): 028-033.

[39]Zhu J Y, Park T, Isola P, et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]. Proceedings of the IEEE international conference on computer vision. 2017: 2223-2232.

[40]Volpi R, Namkoong H, Sener O, et al. Generalizing to unseen domains via adversarial data augmentation[J]. Advances in neural information processing systems,

2018, 31(1): 1-11.

[41]Zhao L, Liu T, Peng X, et al. Maximum-entropy adversarial data augmentation for improved generalization and robustness[J]. Advances in Neural Information Processing Systems, 2020, 33(1): 14435-14447.

[42]Yang L, Zhang Z, Song Y, et al. Diffusion Models: A Comprehensive Survey of Methods and Applications[J]. ACM Computing Surveys, 2024, 56(4): 1-39.

[43]童煜钧, 王荷清, 罗悦恒, 等. 基于扩散模型数据增广的域泛化方法[J]. 智能科学与技术学报, 2023, 5(3): 380-388.

[44]Xu Q, Zhang R, Fan Z, et al. Fourier-based augmentation with applications to domain generalization[J]. Pattern Recognition, 2023, 139: 109474.

[45]Wang Z, Luo Y, Huang Z, et al. Ffm: Injecting out-of-domain knowledge via factorized frequency modification[C]. Proceedings of the IEEE/CVF winter conference on applications of computer vision. 2023: 4135-4144.

[46]Zhou K, Yang Y, Qiao Y, et al. MixStyle Neural Networks for Domain Generalization and Adaptation[J]. International Journal of Computer Vision, 2024, 132(3): 822-836.

[47]孙灿, 胡志刚, 郑浩. 单源域泛化中一种基于域增强和特征对齐的元学习方案[J]. 计算机应用研究, 2024, 41(08): 2392-2397.

[48]Zhang X, He Y, Xu R, et al. Nico++: Towards better benchmarking for domain generalization[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 16036-16047.

[49]Li J, Li Y, Wang H, et al. Exploring explicitly disentangled features for domain generalization[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2023, 33(11): 6360-6373.

[50]Lv F, Liang J, Li S, et al. Causality inspired representation learning for domain generalization[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 8046-8056.

[51]Mahajan D, Tople S, Sharma A. Domain generalization using causal matching[C]. International conference on machine learning. PMLR, 2021: 7313-7324.

[52]Zhou X, Zheng X, Shu T, et al. Information theoretic learning-enhanced dual-generative adversarial networks with causal representation for robust OOD generalization[J]. IEEE Transactions on Neural Networks and Learning Systems, 2023, 36(2): 2066-2079.

[53]Chen J, Gao Z, Wu X, et al. Meta-causal learning for single domain generalization[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 7683-7692.

[54]Liu Z, Liu Y, Lu G, et al. CauRDG: Enhancing Domain Generalization with Causal-Driven Semantic Consistency Reasoning[C]. Proceedings of the 33rd ACM

International Conference on Multimedia. Dublin Ireland: ACM, 2025: 11101-11110.

[55]明水根, 张洪. 基于因果关系和特征对齐的图像分类域泛化模型[J]. 网络安全与数据治理, 2023, 42(08): 59-65.

[56]王祥波, 梁倩, 李明洋, 等. 基于场景不可知学习的时序数据域泛化方法[J]. 西安邮电大学学报, 2025, 30(02): 107-114.

[57] Teterwak P, Saito K, Tsiligkaridis T, et al. Erm++: An improved baseline for domain generalization[C]. Proceedings of the Winter Conference on Applications of Computer Vision. 2025: 8514-8524.

[58] Wen C, Peng Z, Huang Y, et al. Domain generalization in clip via learning with diverse text prompts[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2025: 9559-9569.

[59] Zhang X, Tan R T. Mamba as a bridge: Where vision foundation models meet vision language models for domain-generalized semantic segmentation[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2025: 14527-14537.

[60] Zhao D, Li J, Wang S, et al. Fishertune: Fisher-guided robust tuning of vision foundation models for domain generalized segmentation[C]. Proceedings of the computer vision and pattern recognition conference. 2025: 15043-15054.

[61] Kritikos A, Spanos N, Voulodimos A. CrossFlowDG: Bridging the modality gap with cross-modal flow matching for domain generalization[J]. https://arxiv.org/abs/2604.16892, 2026-04-18/2026-04-20.

[62] Hinton G, Vinyals O, Dean J. Distilling the Knowledge in a Neural Network[J/OL]. https://arxiv.org/abs/1503.02531, 2015-03-09/2026-04-20.

[63] Sun S, Ren W, Li J, et al. Logit standardization in knowledge distillation[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 15731-15740.

[64] Yuan M, Lang B, Quan F. Student-friendly knowledge distillation[J]. Knowledge-Based Systems, 2024, 296: 111915.

[65] Miles R, Mikolajczyk K. Understanding the role of the projector in knowledge distillation: 5[C]. Proceedings of the AAAI conference on artificial intelligence: Vol. 38. 2024: 4233-4241.

[66] Mirzadeh S I, Farajtabar M, Li A, et al. Improved knowledge distillation via teacher assistant[C]. Proceedings of the AAAI conference on artificial intelligence: Vol. 34. 2020: 5191-5198.

[67] Chi Z, Zheng T, Li H, et al. NormKD: Normalized Logits for Knowledge Distillation[J/OL]. https://arxiv.org/abs/2308.00520, 2023-08-01/2026-04-20.

[68] Cui J, Tian Z, Zhong Z, et al. Decoupled kullback-leibler divergence loss[J]. Advances in Neural Information Processing Systems, 2024, 37(1): 74461-74486.

[69] Zagoruyko S, Komodakis N. Paying more attention to attention: Improving the performance of convolutional neural networks via attention transfer[J/OL]. https://arxiv.org/abs/1612.03928, 2016-12-12/2026-04-20.

[70] Heo B, Lee M, Yun S, et al. Knowledge transfer via distillation of activation boundaries formed by hidden neurons[C]. Proceedings of the AAAI conference on artificial intelligence: Vol. 33. 2019: 3779-3787.

[71] Liu Z, Wang Y, Chu X, et al. A simple and generic framework for feature distillation via channel-wise transformation[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 1129-1138.

[72] Mansourian A M, Jalali A, Ahmadi R, et al. Attention-guided Feature Distillation for Semantic Segmentation[J/OL]. https://arxiv.org/abs/2403.05451, 2024-03-08/2026-04-20.

[73] Zhang Y, Huang T, Liu J, et al. Freekd: Knowledge distillation via semantic frequency prompt[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 15931-15940.

[74] Yim J, Joo D, Bae J, et al. A gift from knowledge distillation: Fast optimization, network minimization and transfer learning[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 4133-4141.

[75] Park W, Kim D, Lu Y, et al. Relational knowledge distillation[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 3967-3976.

[76] Tung F, Mori G. Similarity-preserving knowledge distillation[C]. Proceedings of the IEEE/CVF international conference on computer vision. 2019: 1365-1374.

[77] Liu L, Huang Q, Lin S, et al. Exploring inter-channel correlation for diversity-preserved knowledge distillation[C]. Proceedings of the IEEE/CVF international conference on computer vision. 2021: 8271-8280.

[78] Cheng C, Gao W, Bian X. Knowledge distillation via inter-and intra-samples relation transferring[C]. 2024 20th international conference on natural computation, fuzzy systems and knowledge discovery (ICNC-FSKD). IEEE, 2024: 1-7.

[79] Mansourian A M, Ahamdi R, Kasaei S. AICSD: Adaptive inter-class similarity distillation for semantic segmentation[J]. Multimedia Tools and Applications, 2025, 84(29): 35921-35940.

[80] Cho J H, Hariharan B. On the efficacy of knowledge distillation[C]. Proceedings of the IEEE/CVF international conference on computer vision. 2019: 4794-4802.

[81] Zhang H, Chen D, Wang C. Adaptive multi-teacher knowledge distillation with meta-learning[C]. 2023 IEEE International Conference on Multimedia and Expo (ICME). IEEE, 2023: 1943-1948.

[82] Wang J, Chen Y, Zheng Z, et al. Crosskd: Cross-head knowledge distillation

for object detection[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2024: 16520-16530.

[83] Yang C, An Z, Huang L, et al. Clip-kd: An empirical study of distilling clip models[J/OL]. https://arxiv.org/abs/2307.12732, 2023-07-24/2026-04-20.

[84] Nair L. CLIP-Embed-KD: Computationally Efficient Knowledge Distillation Using Embeddings as Teachers[J/OL]. https://arxiv.org/abs/2404.06170, 2024-04-09/2026-04-20.

[85] Jang J, Ma C, Lee B. Vl2lite: Task-specific knowledge distillation from large vision-language models to lightweight networks[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2025: 30073-30083.

[86] Lv C, Zhao D, Wang S, et al. Generalizable knowledge distillation from vision foundation models for semantic segmentation[J/OL]. https://arxiv.org/abs/2603.02554, 2026-03-03/2026-04-20.

[87] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.

[88]Ganin Y, Lempitsky V. Unsupervised domain adaptation by backpropagation[C]. International conference on machine learning. PMLR, 2015: 1180-1189.

[89] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]. Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.

[90] Hou Q, Zhou D, Feng J. Coordinate attention for efficient mobile network design[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 13713-13722.

[91] Efraimidis P S, Spirakis P G. Weighted random sampling with a reservoir[J]. Information processing letters, 2006, 97(5): 181-185.

[92] Li D, Yang Y, Song Y Z, et al. Deeper, broader and artier domain generalization[C]. Proceedings of the IEEE international conference on computer vision. 2017: 5542-5550.

[93] Venkateswara H, Eusebio J, Chakraborty S, et al. Deep hashing network for unsupervised domain adaptation[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 5018-5027.

[94] Carlucci F M, D'Innocente A, Bucci S, et al. Domain generalization by solving jigsaw puzzles[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 2229-2238.

[95] Torralba A, Efros A A. Unbiased look at dataset bias[C]. CVPR 2011. IEEE, 2011: 1521-1528.

[96] Shi B, Zhang D, Dai Q, et al. Informative dropout for robust representation learning: A shape-bias perspective[C]. International Conference on Machine Learning.

PMLR, 2020: 8828-8839.

[97] Chattopadhyay P, Balaji Y, Hoffman J. Learning to Balance Specificity and Invariance for In and Out of Domain Generalization[M]. Vedaldi A, Bischof H, Brox T, et al. Computer Vision – ECCV 2020: Vol. 12354. Cham: Springer International Publishing, 2020: 301-318.

[98] Ding Y, Wang L, Liang B, et al. Domain generalization by learning and removing domain-specific features[J]. Advances in Neural Information Processing Systems, 2022, 35(1): 24226-24239.

[99] Du D, Chen J, Li Y, et al. Cross-Domain Gated Learning for Domain Generalization[J]. International Journal of Computer Vision, 2022, 130(11): 2842-2857.

[100] Guo J, Wang N, Qi L, et al. Aloft: A lightweight mlp-like architecture with dynamic low-frequency transform for domain generalization[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 24132-24141.

[101] Nam H, Lee H, Park J, et al. Reducing domain gap by reducing style bias[C]. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 8690-8699.

[102] Cha J, Chun S, Lee K, et al. Swad: Domain generalization by seeking flat minima[J]. Advances in Neural Information Processing Systems, 2021, 34: 22405-22418.

[103] Li C, Zhang D, Huang W, et al. Cross contrasting feature perturbation for domain generalization[C]. Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 1327-1337.

[104] Long S, Zhou Q, Ying C, et al. Rethinking domain generalization: Discriminability and generalizability[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2024, 34(11): 11783-11797.

[105] Shi Z, Ming Y, Fan Y, et al. Domain generalization via nuclear norm regularization[C]. Conference on Parsimony and Learning. PMLR, 2024: 179-201.

[106] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]. Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.

[107] Jang E, Gu S, Poole B. Categorical reparameterization with gumbel-softmax[J/OL]. https://arxiv.org/abs/1611.01144, 2016-11-03/2026-04-20.

[108] Cao W, Zhang Y, Gao J, et al. Pkd: General distillation framework for object detectors via pearson correlation coefficient[J]. Advances in Neural Information Processing Systems, 2022, 35: 15394-15406.

[109] Yang Z, Li Z, Jiang X, et al. Focal and global knowledge distillation for detectors[C]. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 4643-4652.

作者在学期间取得的学术成果

[1] Xiang F, **Li T**, Chen J, et al. CLEAR: Channel-Filtered Learning With Ensemble Attention and Robustness for Cognitive Domain Generalization[J]. IEEE Transactions on Human-Machine Systems, 2026,56(2):237-246. (SCI Index, WOS:001682805600001, 影响因子：4.4)

[2] **Li T**, Xiang F, Chen J, et al. Improving Model Generalization Across Domains with Multi-Scale Feature Aggregation Filtering and Consistency Loss[C]. Vienna, Austria: 2025 IEEE International Conference on Systems, Man, and Cybernetics (SMC). IEEE, 2025: 4487-4492. (EI Index, Accession number: 20261220305972)

[3] **黎拓新**, 项凤涛, 陈君海, 等. 基于跨空间多尺度信息聚合和推理一致性的域泛化方法[J]. 智能科学与技术学报, 2025, 7(2):200-210.

[4] 项凤涛, **黎拓新**, 陈君海, 张晓博, 罗翔宇, 张万鹏, 谷学强. 基于域不变特征提取的领域泛化方法、装置和计算机设备[P]. 中国专利: ZL202411512609.7, 2024-12-24.

[5] 项凤涛, **黎拓新**, 陈君海, 张晓博, 罗翔宇, 张万鹏. 基于深度条件分布对齐的信息迁移学习方法、装置和设备[P]. 中国专利: ZL202510113738.7, 2025-05-13.

[6] Xiang F, **Li T**, Chen J, et al. Beyond Invariance: A Three-Stage Framework Integrating Adaptive Fourier Enhancement and Causal Disentanglement for Domain Generalization [J]. IEEE Transactions on Emerging Topics in Computational Intelligence. （在投）

[7] **黎拓新**, 陈君海, 赵智秋. 第二十六届中国机器人及人工智能大赛全国二等奖. 2024.

公开评阅信息

序号	评阅人	职称	导师类型	工作单位	评分	答辩建议	熟悉程度	备注
1	张兴龙	副研究员	硕导	国防科技大学	89.35	B	比较熟悉	

说明：

1. 答辩建议选项包括 4 个：“A 同意直接答辩”、“B 同意修改后答辩”、“C 须作较大修改后复评”、“D 不同意答辩”。

2. 熟悉程度选项包括 3 个：“有深入了解”、“比较熟悉”、“一般了解”。

答辩委员会

姓名	职称	工作单位	备注
周宗潭	教授	国防科技大学	主　席
朱庆猛	高工	中国科学院软件研究所	委　员
张万鹏	研究员	国防科技大学	委　员
陈少飞	副教授	国防科技大学	委　员
项凤涛	副教授	国防科技大学	委　员
张远龙	副教授	国防科技大学	秘　书